
ANÁLISIS DE EMOCIONES BÁSICAS MEDIANTE ELECTROENCEFALOGRAFÍAS Y DATOS FISIOLÓGICOS



TRABAJO FIN DE GRADO
CURSO 2023-2024

AUTORES
RODRIGO CABELLO HERNÁNDEZ
JAVIER CANO SALCEDO
DIEGO ROL SÁNCHEZ
JOSÉ MIGUEL VILLACAÑAS DÍAZ-HELLÍN

DIRECTOR
CARLOS LEÓN AZNAR

GRADO EN DESARROLLO DE VIDEOJUEGOS
FACULTAD DE INFORMÁTICA
UNIVERSIDAD COMPLUTENSE DE MADRID

ANALYSIS OF BASIC EMOTIONS THROUGH ELECTROENCEPHALOGRAPHIES AND PHYSIOLOGICAL DATA



BACHELOR'S THESIS
COURSE 2023-2024

AUTHORS
RODRIGO CABELLO HERNÁNDEZ
JAVIER CANO SALCEDO
DIEGO ROL SÁNCHEZ
JOSÉ MIGUEL VILLACAÑAS DÍAZ-HELLÍN

DIRECTOR
CARLOS LEÓN AZNAR

VIDEOGAME DEVELOPMENT DEGREE
FACULTY OF COMPUTER SCIENCE
UNIVERSIDAD COMPLUTENSE DE MADRID

AGRADECIMIENTOS

A nuestro tutor, Carlos León Aznar, por guiarnos durante la realización de este proyecto y facilitarnos el acceso al material y a la zona de trabajo.

A todos los participantes en las sesiones de grabación, por dedicar su tiempo.

“Quiero agradecer a mis padres y mi abuelo por el apoyo diario que muestran hacia mí”. – Diego Rol Sánchez

“Agradezco a mis padres, a mi hermano, a mi familia, a Nuria y a mis amigos por el apoyo que me han dado durante el grado a pesar de la distancia. Dedico este trabajo a mis abuelos, que lo leerán desde el cielo.” - Javier Cano Salcedo

“Este trabajo se lo dedico a mis padres y a mi hermano, sin ellos todo esto no hubiese sido posible. También agradecimientos especiales a Paula y a mis amigos por estar conmigo todos los días dándome ánimos”. - José Miguel Villacañas Díaz-Hellín

“Quiero dar las gracias a mis padres y mis tíos, por estar siempre ahí apoyándome, y a mi hermana, que es mi referente y mi ejemplo a seguir” – Rodrigo Cabello Hernández

“Nada en la vida debe ser temido, solamente comprendido.
Ahora es el momento de comprender más para temer menos” – Marie
Curie

RESUMEN

La electroencefalografía y los sensores biométricos han existido desde hace años. Sin embargo, la gran mayoría de videojuegos todavía no utilizan este tipo de sensores para adaptar su jugabilidad al estado emocional del jugador.

Usando un electroencefalógrafo y sensores fisiológicos, hemos creado un sistema de predicción de emociones que permitiría a un videojuego cualquiera adaptar su estado al estado anímico del jugador en tiempo real.

Se han recogido 48 minutos y 11 segundos de datos EEG y fisiológicos de tres sujetos que han jugado videojuegos distintos, cuya finalidad es evocar emociones distintas con la mayor intensidad posible. Las emociones evaluadas se representan mediante escalas de Likert de cinco valores que enfrentan dos emociones consideradas como opuestas. Estas parejas son relajación-concentración, frustración-diversión, anticipación-sorpresa, seguridad-miedo y distracción-inmersión.

Los datos recogidos se han usado para entrenar un modelo predictivo de aprendizaje automático. Según los resultados obtenidos, el mejor modelo de predicción de emociones es *random forest*. El desempeño de este modelo en tiempo real es similar para los pares de emociones de concentración y diversión, en cambio, para las demás predicciones no es tan preciso. Cabe destacar que la frecuencia de predicción no es un factor significativo para la precisión, pero al comparar los resultados separando los datos EEG y fisiológicos, los datos fisiológicos son prescindibles para todos los pares de emociones a excepción de la diversión.

Palabras clave

EEG, datos fisiológicos, emociones, videojuegos, aprendizaje automático.

ABSTRACT

Electroencephalography and biometric sensors have been around for years. However, the vast majority of video games still do not use this type of sensors to adapt their gameplay to the emotional state of the player.

Using an electroencephalograph and physiological sensors, we have created an emotion prediction system that would allow any video game to adapt its state to the player's mood in real time.

We have collected 48 minutes and 11 seconds of EEG and physiological data from three subjects who have played different video games, the purpose of which is to evoke different emotions with the highest possible intensity. The emotions evaluated are represented by five-value Likert scales that face two emotions considered as opposites. These pairs are relaxation-focus, frustration-amusement, anticipation-surprise, security-fright and distraction-immersion.

According to the results obtained, the best emotion prediction model is *random-forest*, with a mean *RMSE* value for each emotion pair of 0.2545, which is considered slightly inaccurate since a value is acceptable below 0.25. The real-time performance of this model is similar for the concentration and fun emotion pairs, in contrast, for the other predictions it is much worse, raising the mean *RMSE* value to 1.0667. It should be noted that prediction frequency is not a significant factor for accuracy, but when comparing the results by separating EEG and physiological data, physiological data are dispensable for all emotion pairs except for amusement.

Keywords

EEG, physiological data, emotions, videogames, machine learning.

ÍNDICE DE CONTENIDOS

AGRADECIMIENTOS	III
RESUMEN	V
ABSTRACT	VI
ÍNDICE DE CONTENIDOS	VII
ÍNDICE DE ILUSTRACIONES	XI
ÍNDICE DE TABLAS	XIII
CAPÍTULO 1 - INTRODUCCIÓN	1
1.1 MOTIVACIÓN	1
1.2 HIPÓTESIS DE PARTIDA	2
1.3 OBJETIVOS	3
1.4 METODOLOGÍA	4
1.4.1 Herramientas usadas	4
1.4.2 Plan de trabajo	5
1.5 ESTRUCTURA DEL DOCUMENTO	6
CHAPTER - INTRODUCTION	9
MOTIVATION	9
STARTING HYPOTHESES	10
OBJECTIVES.....	11
METHODOLOGY.....	11
Tools used	12
Work plan	12
STRUCTURE.....	13
CAPÍTULO 2 - ESTADO DEL ARTE.....	15
2.1 TRABAJOS RELACIONADOS.....	15
2.2 ASPECTOS RELEVANTES DE LAS ESTRUCTURAS CEREBRALES PARA SISTEMAS DE ELECTROENCEFALOGRAMA	17
2.2.1 Partes del cerebro	17
2.2.2 Las neuronas	17
2.3 LA ELECTROENCEFALOGRAFÍA.....	18
2.3.1 Historia de la electroencefalografía	19
2.3.2 Tipos de electroencefalógrafos	20
2.3.3 Las ondas cerebrales.....	21
2.3.4 Señales no deseadas en los electroencefalogramas.....	22
2.3.4.1 Párpadeos y movimientos de ojos.....	23
2.3.4.2 Actividad muscular	23
2.3.4.3 Actividad cardíaca.....	23
2.3.4.4 Fuentes de ruido ambiental.....	24
2.3.5 Aplicaciones de la electroencefalografía	24
2.3.6 Configuración de medición del electroencefalograma	25
2.3.7 Preprocesamiento de señales del electroencefalograma	26
2.3.7.1 Filtrado de frecuencia	26
2.3.7.2 Eliminación de señales no deseadas.....	28
2.4 SENSORES BIOMÉTRICOS	29
2.4.1 Sensor de temperatura	30
2.4.2 Sensor de actividad electrodermal.....	30

2.4.3 Sensor PPG	30
2.4.4 Magnetómetro	30
2.5 LAS EMOCIONES	30
2.5.1 Definición de las emociones	31
2.5.2 Clasificación de las emociones	31
2.5.2.1 Modelos dimensionales	31
2.5.2.1.1 Modelo de Russell	31
2.5.2.1.2 Modelo de Plutchik	32
2.5.2.2 Modelos discretos	33
2.5.2.2.1 Modelo de Paul Ekman	33
2.5.2.2.2 Modelo de Carroll Izard	34
2.5.2.2.3 Modelo de Parrot	34
2.5.3 Impacto de las emociones en el cerebro	35
2.6 MODELOS DE APRENDIZAJE AUTOMÁTICO	37
2.6.1 Tipos de modelos de aprendizaje	37
2.6.1.1 Modelos de aprendizaje supervisado	37
2.6.1.2 Modelos de aprendizaje no supervisado	39
2.6.2 Redes neuronales	39
2.6.2.1 Redes Neuronales Artificiales (ANN)	39
2.6.2.2 Redes Neuronales Convolucionales (CNN)	40
2.6.2.3 Redes Neuronales Recurrentes (RNN)	40
2.6.2.4 Redes Neuronales Generativas Adversarias (GAN)	40
2.6.2.5 Redes Neuronales Profundas (DNN)	40
2.7 TECNOLOGÍAS USADAS EN EL TRABAJO	41
2.7.1 El electroencefalógrafo BrainAccess MIDI	41
2.7.2 El sensor biométrico EmotiBit	43
CAPÍTULO 3 - ARQUITECTURA GENERAL DEL SISTEMA	45
3.1 REVISIÓN DE LOS MÓDULOS DE TRABAJO	45
3.2 RELACIONES ENTRE LOS MÓDULOS DEL SISTEMA	47
CAPÍTULO 4 - MONTAJE Y PUESTA EN MARCHA DEL ELECTROENCEFALÓGRAFO Y DEL SENSOR BIOMÉTRICO	51
4.1 MONTAJE DEL ELECTROENCEFALÓGRAFO BRAINACCESS MIDI Y EL SENSOR BIOMÉTRICO EMOTIBIT	51
4.2 OBTENCIÓN Y LECTURA DEL ELECTROENCEFALOGRAMA	53
4.3 OBTENCIÓN Y LECTURA DE LOS DATOS FISIOLÓGICOS	54
CAPÍTULO 5 - SESIONES DE GRABACIÓN DE DATOS Y CAPTURA DE DATOS	57
5.1 DISEÑO DE LAS SESIONES DE GRABACIÓN DE DATOS	57
5.1.1 Diseño del esquema de datos orientado a un sistema de aprendizaje automático	57
5.1.2 Elección del sistema de pruebas	58
5.1.3 Simulacro de una sesión de grabación de datos	59
5.1.4 Desarrollo de una aplicación para la recogida de emociones	59
5.1.5 Creación de grupos de sujetos de prueba	61
5.1.6 Preparación de las sesiones de grabación de datos	61
5.2 PROCEDIMIENTO DE LAS SESIONES DE GRABACIÓN DE DATOS	62
5.3 GRABACIÓN A LOS SUJETOS DE PRUEBAS	63
5.3.1 Organización de los datos brutos de EEG	65
5.3.2 Organización de los datos brutos de EmotiBit	65
5.3.3 Organización de los datos brutos de EmotionsApp	66
5.4 GRABACIÓN PROPIA	67
5.4.1 Nueva organización de los datos brutos de EmotiBit	67
CAPÍTULO 6 - PREPROCESAMIENTO DE LOS DATOS Y ENTRENAMIENTO DE LOS MODELOS DE APRENDIZAJE AUTOMÁTICO	69

6.1 PREPROCESAMIENTO DE LOS DATOS	69
6.1.1 <i>Preprocesado de los datos de BrainAccess</i>	69
6.1.1.1 Filtrado de la señal EEG	70
6.1.1.2 Aplicación de la técnica ICA a la señal EEG	70
6.1.2 <i>Preprocesado de los datos de EmotiBit</i>	71
6.1.3 <i>Preprocesado de los datos de EmotionsApp</i>	72
6.1.4 <i>Generación de la tabla preprocesada</i>	73
6.2 ENTRENAMIENTO DE LOS MODELOS DE APRENDIZAJE	74
CAPÍTULO 7 - GRABACIÓN DEL ELECTROENCEFALOGRAMA Y DE LOS DATOS FISIOLÓGICOS Y PREDICCIÓN DE EMOCIONES EN TIEMPO REAL	77
7.1 FUNCIONALIDAD DEL SERVIDOR EN LA GRABACIÓN DE DATOS Y PREDICCIÓN DE EMOCIONES EN TIEMPO REAL	77
7.2 FUNCIONALIDAD DEL CLIENTE EN LA GRABACIÓN DE DATOS Y PREDICCIÓN DE EMOCIONES EN TIEMPO REAL	79
7.3 REENVÍO DE DATOS A UN PROGRAMA EXTERNO	80
CAPÍTULO 8 - EVALUACIÓN	82
8.1 MÉTODO DE EVALUACIÓN	83
8.2 PRIMER PILOTO DE EVALUACIÓN	83
8.3 PROCESO DE EVALUACIÓN	85
8.4 RESULTADOS	87
8.4.1 <i>Resultados del entrenamiento de los modelos</i>	87
8.4.2 <i>Resultados de las predicciones en tiempo real</i>	90
8.5 ANÁLISIS DE LOS RESULTADOS	91
8.5.1 <i>Análisis de los resultados del entrenamiento de los modelos</i>	91
8.5.2 <i>Análisis de los resultados de las predicciones en tiempo real</i>	101
CAPÍTULO 9 - DISCUSIÓN	103
9.1 LIMITACIONES ENCONTRADAS DURANTE EL PROYECTO	103
9.2 VENTAJAS QUE TIENE EL PROYECTO	104
CAPÍTULO 10 - CONCLUSIONES Y TRABAJO FUTURO	107
10.1 CONCLUSIONES	107
10.1.1 <i>Objetivos específicos</i>	107
10.1.2 <i>Objetivos generales</i>	110
10.1.3 <i>Hipótesis general</i>	110
10.2 LÍNEAS DE TRABAJO FUTURO	111
CHAPTER - CONCLUSIONS AND FUTURE WORK	113
CONCLUSIONS	113
<i>Specific Objectives</i>	113
<i>General Objectives</i>	116
<i>General Hypothesis</i>	116
FUTURE WORK	117
CAPÍTULO 11 - CONTRIBUCIÓN	119
11.1 RODRIGO CABELLO HERNÁNDEZ	119
11.2 JAVIER CANO SALCEDO	121
11.3 DIEGO ROL SÁNCHEZ	123
11.4 JOSÉ MIGUEL VILLACAÑAS DÍAZ-HELLÍN	125
BIBLIOGRAFÍA	127
APÉNDICE A - FORMULARIO DE BÚSQUEDA DE SUJETOS DE PRUEBA	133

APÉNDICE B - FORMULARIO DE DEMOGRAFÍA DE LOS PARTICIPANTES.....	135
---	-----

ÍNDICE DE ILUSTRACIONES

ILUSTRACIÓN 1: NOMENCLATURA ESTANDARIZADA DEL SISTEMA 10/10, EXTENDIDA CON ELECTRODOS ANTERIORES Y POSTERIORES DE LA CADENA INFERIOR (SEECK Y OTROS, 2017)	19
ILUSTRACIÓN 2: IRREGULARIDADES CAUSADAS EN LA SEÑAL PRODUCIDAS POR DISTINTAS SEÑALES NO DESEADAS (GUZMÁN ÁLVAREZ, 2015)	23
ILUSTRACIÓN 3: NOMENCLATURA ESTANDARIZADA DEL SISTEMA 10/20 (NEUROTECHNOLOGY)	25
ILUSTRACIÓN 4: MAPA TOPOGRÁFICO DE CADA UNO DE LOS COMPONENTES EN LOS QUE SE HA DIVIDIDO LA SEÑAL EEG ORIGINAL	29
ILUSTRACIÓN 5: MODELO DE EMOCIONES DE RUSSELL	32
ILUSTRACIÓN 6: RUEDA DE EMOCIONES DE PLUTCHIK (ORTIZ BONILLA, 2019)	33
ILUSTRACIÓN 7: ESTRUCTURA EN ÁRBOL PROPUESTA POR PARROT PARA LA CLASIFICACIÓN DE EMOCIONES	35
ILUSTRACIÓN 8: ANATOMÍA DEL CEREBRO Y SISTEMA LÍMBICO (BRIGHTFOCUS® FOUNDATION, 2015)	37
ILUSTRACIÓN 9: DIAGRAMA DEL PROCESO DE ENTRENAMIENTO DEL MODELO DE APRENDIZAJE AUTOMÁTICO	48
ILUSTRACIÓN 10: DIAGRAMA DEL PROCESO DE PREDICCIÓN DE EMOCIONES EN TIEMPO REAL	49
ILUSTRACIÓN 11: DISPOSICIÓN DE ELECTRODOS RECOMENDADA POR BRAINACCESS PARA 16 ELECTRODOS (NEUROTECHNOLOGY)	52
ILUSTRACIÓN 12: DATOS DE LOS ELECTRODOS DE BRAINACCESS DURANTE UNA GRABACIÓN	53
ILUSTRACIÓN 13: DATOS DE LOS SENSORES DE EMOTIBIT DURANTE UNA GRABACIÓN	55
ILUSTRACIÓN 14: CAPTURA DE PANTALLA DE LA INTERFAZ DE EMOTIONSAPP	60
ILUSTRACIÓN 15: ENTORNO CONSTRUIDO PARA LA DEMO TÉCNICA DE PREDICCIÓN DE EMOCIONES, PREPARADO PARA INDUCIR MIEDO....	81
ILUSTRACIÓN 16: MARCADORES DESLIZANTES QUE REPRESENTAN LOS VALORES DE LAS EMOCIONES PREDICHAS	81
ILUSTRACIÓN 17: EDAD Y GÉNERO DE LA MUESTRA	84
ILUSTRACIÓN 18: EXPERIENCIA JUGANDO A VIDEOJUEGOS DE LA MUESTRA	84
ILUSTRACIÓN 19: TIEMPO DE JUEGO SEMANAL Y FAMILIARIDAD DEL SUJETO CON EL GÉNERO DE TERROR EN LOS VIDEOJUEGOS DE LA MUESTRA	85
ILUSTRACIÓN 20: <i>RMSE</i> DE LOS MODELOS RANDOM FOREST SEGÚN EL TAMAÑO DE LOS FRAGMENTOS	97
ILUSTRACIÓN 21: <i>RMSE</i> DE LOS MODELOS RANDOM FOREST SEGÚN LOS DISPOSITIVOS UTILIZADOS	99

ÍNDICE DE TABLAS

TABLA 1: HERRAMIENTAS USADAS EN ESTE PROYECTO	5
TABLA 2: PLAN DE TRABAJO SEGUIDO DURANTE LA REALIZACIÓN DEL PROYECTO	6
TABLA 3: TOOLS USED IN THIS PROJECT	12
TABLA 4: WORK PLAN FOLLOWED DURING PROJECT EXECUTION	13
TABLA 5 COLUMNAS DE LOS DATOS RECOGIDOS POR BRAINACCESS	54
TABLA 6: NOMBRE Y DESCRIPCIÓN DE LOS CAMPOS PROPORCIONADOS POR EMOTIBIT	55
TABLA 7: REPRESENTACIÓN DE LAS EMOCIONES UTILIZADA EN ESTE PROYECTO.....	57
TABLA 8: COLUMNAS DE LOS DATOS DEMOGRÁFICOS.....	64
TABLA 9: MSE Y R^2 DE LOS MODELOS SVM CON FRAGMENTOS DE 10 SEGUNDOS CON BRAINACCESS Y EMOTIBIT	87
TABLA 10: MSE Y R^2 DE LOS MODELOS MLP CON FRAGMENTOS DE 10 SEGUNDOS CON BRAINACCESS Y EMOTIBIT	88
TABLA 11: MSE Y R^2 DE LOS MODELOS DECISION TREE CON FRAGMENTOS DE 10 SEGUNDOS CON BRAINACCESS Y EMOTIBIT.....	88
TABLA 12: MSE Y R^2 DE LOS MODELOS RANDOM FOREST CON FRAGMENTOS DE 10 SEGUNDOS CON BRAINACCESS Y EMOTIBIT	88
TABLA 13: MSE Y R^2 DE LOS MODELOS KNN CON FRAGMENTOS DE 10 SEGUNDOS CON BRAINACCESS Y EMOTIBIT	88
TABLA 14: MSE Y R^2 DE LOS MODELOS RANDOM FOREST CON FRAGMENTOS DE 20 SEGUNDOS CON BRAINACCESS Y EMOTIBIT	89
TABLA 15: MSE Y R^2 DE LOS MODELOS RANDOM FOREST CON FRAGMENTOS DE 30 SEGUNDOS CON BRAINACCESS Y EMOTIBIT	89
TABLA 16: MSE Y R^2 DE LOS MODELOS RANDOM FOREST CON FRAGMENTOS DE 10 SEGUNDOS CON BRAINACCESS.....	89
TABLA 17: MSE Y R^2 DE LOS MODELOS RANDOM FOREST CON FRAGMENTOS DE 20 SEGUNDOS CON BRAINACCESS.....	89
TABLA 18: MSE Y R^2 DE LOS MODELOS RANDOM FOREST CON FRAGMENTOS DE 30 SEGUNDOS CON BRAINACCESS.....	90
TABLA 19: MSE Y R^2 DE LOS MODELOS RANDOM FOREST CON FRAGMENTOS DE 10 SEGUNDOS CON EMOTIBIT.....	90
TABLA 20: MSE Y R^2 DE LOS MODELOS RANDOM FOREST CON FRAGMENTOS DE 20 SEGUNDOS CON EMOTIBIT.....	90
TABLA 21: MSE Y R^2 DE LOS MODELOS RANDOM FOREST CON FRAGMENTOS DE 30 SEGUNDOS CON EMOTIBIT.....	90
TABLA 22: MSE Y R^2 DE LOS MODELOS RANDOM FOREST CON FRAGMENTOS DE 10 SEGUNDOS CON BRAINACCESS Y EMOTIBIT AL PREDECIR DATOS EN TIEMPO REAL	91
TABLA 23: $RMSE$ PARA CADA MODELO Y EMOCIÓN	92
TABLA 24: ESTADÍSTICA T ENTRE MODELOS DISTINTOS PARA LA EMOCIÓN FOCUS	93
TABLA 25: P-VALOR ENTRE MODELOS DISTINTOS PARA LA EMOCIÓN FOCUS	93
TABLA 26: ESTADÍSTICA T ENTRE MODELOS DISTINTOS PARA LA EMOCIÓN AMUSEMENT	93
TABLA 27: P-VALOR ENTRE MODELOS DISTINTOS PARA LA EMOCIÓN AMUSEMENT.....	94
TABLA 28: ESTADÍSTICA T ENTRE MODELOS DISTINTOS PARA LA EMOCIÓN SURPRISE	94
TABLA 29: P-VALOR ENTRE MODELOS DISTINTOS PARA LA EMOCIÓN SURPRISE.....	94
TABLA 30: ESTADÍSTICA T ENTRE MODELOS DISTINTOS PARA LA EMOCIÓN FRIGHT	95
TABLA 31: P-VALOR ENTRE MODELOS DISTINTOS PARA LA EMOCIÓN FRIGHT.....	95
TABLA 32: ESTADÍSTICA T ENTRE MODELOS DISTINTOS PARA LA EMOCIÓN IMMERSION	95

TABLA 33: P-VALOR ENTRE MODELOS DISTINTOS PARA LA EMOCIÓN IMMERSION	96
TABLA 34: ESTADÍSTICA T ENTRE MODELOS RANDOM FOREST ENTRENADOS CON DISTINTOS TAMAÑOS DE FRAGMENTOS.....	97
TABLA 35: P-VALOR ENTRE MODELOS RANDOM FOREST ENTRENADOS CON DISTINTOS TAMAÑOS DE FRAGMENTOS	98
TABLA 36: ESTADÍSTICA T ENTRE MODELOS RANDOM FOREST ENTRENADOS CON DISTINTOS DISPOSITIVOS.....	100
TABLA 37: P-VALOR ENTRE MODELOS RANDOM FOREST ENTRENADOS CON DISTINTOS DISPOSITIVOS	100
TABLA 38: GRUPO ESTÁNDAR DE MODELOS AL PREDECIR NUEVOS DATOS EN TIEMPO REAL.....	101
TABLA 39: PRUEBA T DE STUDENT COMPARANDO LAS PREDICCIONES DE LOS DATOS DE VALIDACIÓN Y DE LOS NUEVOS DATOS EN TIEMPO REAL.....	101

Capítulo 1 - Introducción

El uso de la psicología para conseguir evocar sentimientos en videojuegos es cada vez más importante en el desarrollo moderno. La mente humana es un sistema extremadamente complejo que todavía se comprende del todo. La experiencia de juego sucede exclusivamente en el cerebro de los jugadores, y entender su funcionamiento es de vital importancia para los diseñadores.

Los sensores fisiológicos son capaces de brindar información sobre el estado fisiológico del usuario. El pulso cardíaco puede ser útil para determinar el grado de nerviosismo de los sujetos, y de esta manera comprobar que el juego transmita correctamente las emociones deseadas. El electroencefalógrafo es otro sensor que proporciona información sobre la actividad cerebral del jugador. Estos datos son más difíciles de interpretar, debido a la subjetividad de las emociones y a que no existen estados cerebrales asignados a cada emoción.

Este proyecto propone combinar el electroencefalograma con los datos fisiológicos para así obtener una imagen más completa del estado del jugador, con la que se pueda intentar predecir unas emociones de interés para el diseñador. Se pretende entrenar un modelo de aprendizaje automático para realizar esta tarea. Estos datos, además de poder ser utilizados para corroborar la experiencia de juego, pueden ser recogidos por el juego. Esto abre una nueva posibilidad a los diseñadores de videojuegos, permitiendo adaptaciones al estado del jugador durante la ejecución del videojuego.

1.1 Motivación

La motivación detrás de este proyecto radica en la creciente complejidad y sofisticación de los videojuegos. A medida que la tecnología avanza y los presupuestos destinados al desarrollo de videojuegos aumentan, la industria busca no solo entretener, sino también evocar emociones profundas y significativas en los jugadores. Los diseñadores de videojuegos invierten considerablemente en crear experiencias que resuenen emocionalmente con su audiencia. Sin embargo, el proceso de validar estas emociones a través de sesiones de juego puede ser limitado debido a la variabilidad en las respuestas emocionales de los usuarios. La neurociencia, la psicología y la fisiología juegan un

papel crucial en entender estas diferencias y, por tanto, desarrollar un sistema que pueda capturar y modelar las emociones de los jugadores tiene un valor inestimable.

Desde una perspectiva científica, este proyecto tiene el potencial de contribuir significativamente al campo de la neurociencia aplicada y la psicología experimental. La combinación de datos obtenidos de electroencefalogramas y otros sensores fisiológicos proporciona una oportunidad única para explorar cómo se manifiestan y varían las emociones durante la experiencia de juego. Este enfoque multidisciplinario puede ofrecer nuevas perspectivas sobre la relación entre la actividad cerebral, las respuestas fisiológicas y las emociones humanas. Al entrenar un modelo de aprendizaje automático para predecir emociones basadas en estos datos, no solo se avanza en la comprensión científica de las emociones, sino que también se sientan las bases para futuras investigaciones en interfaces cerebro-computadora y en el diseño de experiencias personalizadas en tiempo real.

Desde el punto de vista social, la implementación de este proyecto puede tener un impacto positivo en la experiencia del jugador y en la industria del entretenimiento digital en general. Los videojuegos no solo son una forma de ocio, sino también una herramienta educativa, terapéutica y de conexión social. La capacidad de adaptar dinámicamente un videojuego al estado emocional del jugador puede mejorar la inmersión y la satisfacción del usuario, haciendo que las experiencias sean más atractivas y significativas. Además, puede ayudar a identificar y mitigar respuestas emocionales negativas, mejorando la salud mental y el bienestar de los jugadores. En resumen, este proyecto no solo tiene el potencial de revolucionar el diseño de videojuegos, sino también de promover el bienestar emocional a través de experiencias de juego más personalizadas y empáticas.

1.2 Hipótesis de partida

Nuestro trabajo se inicia con la siguiente hipótesis:

Es posible predecir las emociones del jugador de forma robusta a partir de su electroencefalograma y sus datos biométricos.

La hipótesis expuesta implica, por una parte, una definición de emociones cuantitativa, con la que poder probar la eficacia de la predicción. Por la otra parte, sugiere

que, al combinar el electroencefalograma con los datos biométricos, se puede construir un modelo que prediga con precisión las emociones del jugador. La predicción robusta implica que este modelo sería fiable y consistente, capaz de manejar la variabilidad inherente en los datos fisiológicos de diferentes jugadores y en diferentes contextos de juego.

1.3 Objetivos

A partir de la motivación y la hipótesis de partida, este trabajo propone los siguientes objetivos generales:

- 1. Entrenar un modelo capaz de predecir las emociones a partir del electroencefalograma y los datos biométricos de un usuario.*
- 2. Ofrecer un sistema de predicción de datos que una aplicación o un videojuego puedan utilizar para reaccionar al estado anímico del usuario en tiempo real.*

Más en detalle, estos objetivos generales comprenden los siguientes objetivos específicos:

- A. Comprender el funcionamiento del electroencefalógrafo y el sensor biométrico y estudiar sobre modelos de aprendizaje automático.*
- B. Diseñar una representación de los grados de emociones que deseamos predecir.*
- C. Llevar a cabo sesiones de grabación en las que obtengamos los datos del electroencefalógrafo y el sensor biométrico y las asociemos a las emociones detectadas.*
- D. Entrenar distintos modelos de aprendizaje automático para predecir las emociones dados los datos del electroencefalógrafo y el sensor biométrico.*
- E. Aplicar el mejor modelo para predecir las emociones de un jugador en tiempo real.*

1.4 Metodología

Durante el proyecto hemos utilizado metodologías ágiles de producción y diversas herramientas, lo que ha permitido estructurar el trabajo para alcanzar los objetivos de manera efectiva.

En primer lugar, se detallan las herramientas utilizadas, que van desde dispositivos de recolección de datos biométricos hasta software de desarrollo y gestión de versiones. A continuación, se presenta el plan de trabajo que ha guiado el progreso del proyecto, distribuyendo las tareas a lo largo de los meses mediante un diagrama de Gantt.

Para la evaluación se ha contado con una zona específica de la biblioteca donde poder trabajar en el proyecto y una sala en la misma zona donde poder realizar las grabaciones de capturas de datos. Como se explica en el 0el procedimiento de evaluación ha sido: realizar las grabaciones de capturas de datos junto con los cuestionarios, preprocesar los datos y entrenar un modelo de aprendizaje automático con el que poder predecir las emociones de otras grabaciones que se hagan en tiempo real.

1.4.1 Herramientas usadas

En este proyecto se han utilizado diversas herramientas, cada una con un propósito específico que ha contribuido al desarrollo y ejecución del mismo. A continuación, se enumeran las herramientas y sus respectivos usos:

Herramienta	Uso
BrainAccess MIDI	Electroencefalógrafo de 16 canales
EmotiBit	Pulsera dotada de sensores biométricos
Unity 2022.3.20f1	Motor utilizado para crear una aplicación para el apunte de las emociones observadas en los sujetos
Unreal Engine	Motor utilizado para la demo técnica de predicción de emociones en tiempo real
OBS	Herramienta de código abierto para la grabación de las sesiones de captura de datos
GitHub	Plataforma de control de versiones usada durante el desarrollo
Visual Studio Code	Programa de edición de código Python
Visual Studio 2022 Community	Programa de edición de código C++
Anaconda Navigator	Entorno de ejecución de Python
Google Drive	Servicio utilizado para el almacenamiento de datos y vídeos
Google Forms	Plataforma para recabar datos de los sujetos
Microsoft Word	Herramienta utilizada para la confección de este documento
Udemy	Plataforma de aprendizaje utilizada para aprender sobre EEG

Tabla 1: Herramientas usadas en este proyecto

1.4.2 Plan de trabajo

El plan de trabajo seguido durante la realización del proyecto ha permitido una organización eficiente y una correcta gestión del tiempo. Las tareas han sido distribuidas de manera estratégica a lo largo de los meses, y se han recogido en un diagrama de Gantt, el cual ha sido una guía fundamental para asegurar el cumplimiento de los objetivos establecidos en cada fase del proyecto.

Objetivo	Septiembre	Octubre	Noviembre	Diciembre	Enero	Febrero	Marzo	Abril	Mayo
A									
B									
C									
D									
E									

Tabla 2: Plan de trabajo seguido durante la realización del proyecto

1.5 Estructura del documento

Este documento se estructura de la siguiente manera:

- En el primer capítulo, esta introducción, se presentan brevemente la motivación e hipótesis de partida que dan razón a esta investigación, así como los objetivos propuestos para cumplir durante la misma, las herramientas utilizadas y el plan de trabajo.
- El segundo capítulo revisa otros trabajos similares al nuestro y estudia extensivamente el conocimiento previo que hay con relación a la electroencefalografía y los sensores biométricos y su aplicación a la predicción de emociones. También examina los conceptos básicos para el entendimiento de esta investigación y revisa los dispositivos utilizados para capturar el electroencefalograma y los datos biométricos.
- En el tercer capítulo se presenta la arquitectura general del sistema para poder formar una visión de mapa completa del proyecto.
- En el cuarto capítulo se describe el proceso de captura de datos del electroencefalógrafo y los sensores biométricos.
- En el quinto capítulo se diseña el procedimiento de las sesiones de grabación de datos con las que pretendemos obtener los datos necesarios para

entrenar los modelos de aprendizaje automático y se describe su puesta en marcha. Este finaliza con la generación del archivo de datos en bruto a partir de los archivos generados por el electroencefalógrafo, los sensores biométricos y una aplicación con la que se registran las emociones manualmente durante las sesiones de grabación,

- En el sexto capítulo está dedicado al proceso del preprocesado de los datos y al entrenamiento de los distintos modelos de aprendizaje automático.
- El séptimo capítulo desarrolla un proceso de comunicación entre el electroencefalógrafo y los sensores biométricos en tiempo real, utiliza el modelo para predecir las emociones en caliente y repasa el proceso de comunicación de un motor de videojuegos con el electroencefalógrafo y los sensores biométricos.
- En el octavo capítulo se presenta el sistema de evaluación, los resultados obtenidos y se analizan las predicciones de los modelos.
- En el noveno capítulo se discuten desde un punto de vista técnico, las ventajas y limitaciones de nuestro trabajo.
- En el décimo capítulo presenta las conclusiones más importantes recogidas del desarrollo de esta investigación, y esboza posibles puntos que futuras investigaciones podrían mejorar.
- El undécimo capítulo detalla la contribución de cada miembro de este TFG.

Los capítulos 1 y 12 están disponibles en inglés tras su contraparte en español.

Finalmente, se presenta la bibliografía completa referenciada por el trabajo.

Chapter - Introduction

The use of psychology to evoke feelings in video games is becoming increasingly important in modern development. The human mind is an extremely complex system that is still only superficially understood. Game feel happens exclusively in the players' brains, and understanding how they work is of vital importance to designers.

Physiological sensors are capable of providing information about the user's physiological state. The cardiac pulse can be useful to determine the degree of nervousness of the testers, and thus check that the game correctly conveys the desired emotions. The electroencephalograph is another sensor that provides information about the player's brain activity. These data are more difficult to interpret, due to the subjectivity of emotions and the fact that there are no brain states assigned to each emotion.

This project proposes to combine the electroencephalogram with physiological data in order to obtain a more complete picture of the player's state, with which we can try to predict emotions of interest to the designer. We intend to train a machine learning model to perform this task. This data, in addition to being used to corroborate the game feel, can be collected by the game. This opens a new possibility for game designers, allowing adaptations to the state of the player during the execution of the game.

Motivation

The motivation behind this project lies in the increasing complexity and sophistication of video games. As technology advances and videogame development budgets increase, the industry seeks not only to entertain, but also to evoke deep and meaningful emotions in players. Game designers invest heavily in creating experiences that resonate emotionally with their audience. However, the process of validating these emotions through playtesting can be limited due to the variability in users' emotional responses. Neuroscience, psychology, and physiology play a crucial role in understanding these differences, and thus, developing a system that can capture and model player emotions is invaluable.

From a scientific perspective, this project has the potential to contribute significantly to the field of applied neuroscience and experimental psychology. The combination of data obtained from electroencephalograms and other physiological sensors provides a unique opportunity to explore how emotions manifest and vary during the gaming experience. This multidisciplinary approach may offer new insights into the relationship between brain activity, physiological responses and human emotions. By training a machine learning model to predict emotions based on these data, we not only advance the scientific understanding of emotions, but also lay the groundwork for future research in brain-computer interfaces and the design of personalized real-time experiences.

From a social point of view, the implementation of this project can have a positive impact on the gamer experience and on the digital entertainment industry in general. Video games are not only a form of entertainment, but also an educational, therapeutic and social connection tool. The ability to dynamically adapt a video game to the emotional state of the player can enhance immersion and user satisfaction, making experiences more engaging and meaningful. In addition, it can help identify and mitigate negative emotional responses, improving the mental health and well-being of players. In short, this project not only has the potential to revolutionize video game design, but also to promote emotional well-being through more personalized and empathetic gaming experiences.

Starting hypotheses

Our work starts with the following hypothesis:

It is possible to predict player emotions robustly from their electroencephalogram and biometric data.

The stated hypothesis implies, on the one hand, a quantitative definition of emotions, with which to test the effectiveness of the prediction. On the other hand, it suggests that, by combining EEG and biometric data, a model can be constructed that accurately predicts player emotions. Robust prediction implies that this model would be reliable and consistent, capable of handling inherent variability in physiological data from different players and in different game contexts.

Objectives

Based on the motivation and the starting hypothesis, this work proposes the following general objectives:

1. *To train a model capable of predicting emotions from the electroencephalogram and biometric data of a user.*
2. *To provide a data prediction system that an application or a videogame can use to react to the user's mood in real time.*

In more detail, these general objectives comprise the following specific objectives:

- A. *To understand the operation of the electroencephalograph and the biometric sensor and to study on machine learning models.*
- B. *To design a representation of the degrees of the emotions we desire to predict.*
- C. *Conduct recording sessions in which we obtain the data from the electroencephalograph and the biometric sensor and associate them with the detected emotions.*
- D. *Train different machine learning models to predict emotions given the electroencephalograph and biometric sensor data.*
- E. *Apply the best model to predict a player's emotions in real time.*

Methodology

During the project we have used agile production methodologies and various tools, which has allowed us to structure the work to achieve the objectives effectively.

First, the tools used are detailed, ranging from biometric data collection devices to development and version management software. Next, the work plan that has guided the progress of the project is presented, distributing the tasks over the months by means of a Gantt chart.

For the evaluation, there was a specific area of the library where the project could be worked on and a room in the same area where the data capture recordings could be made. As explained in Chapter 8, the evaluation procedure consisted of: recording the data captures together with the questionnaires, preprocessing the data and training

a machine learning model with which to predict the emotions of other recordings made in real time.

Tools used

Several tools have been used in this project, each with a specific purpose that has contributed to the development and execution of the project. The tools and their respective uses are listed below:

Tool	Usage
BrainAccess MIDI	16 channels electroencephalograph
EmotiBit	Wristband with biometric sensors
Unity 2022.3.20f1	Engine used to create an application for recording emotions observed in subjects
Unreal Engine	Engine used for real-time emotion prediction tech demo
OBS	Open source tool for experiment recording
GitHub	Version control platform used during development
Visual Studio Code	Python code editing software
Visual Studio 2022 Community	C++ code editing software
Anaconda Navigator	Python runtime environment
Google Drive	Service used for data and video storage
Google Forms	Platform used to collect data from subjects
Microsoft Word	Tool used for the preparation of this document
Udemy	Learning platform used to learn about EEG

Table 3: Tools used in this project

Work plan

The work plan followed during the execution of the project has allowed for efficient organization and proper time management. The tasks have been distributed strategically throughout the months, and have been collected in a Gantt chart, which has been a fundamental guide to ensure the fulfilment of the objectives established in each phase of the project.

Objectives	September	October	November	December	January	February	March	April	May
A									
B									
C									
D									
E									

Table 4: Work plan followed during project execution

Structure

This document is structured as follows:

- The first chapter, this introduction, briefly presents the motivation and starting hypotheses that give reason for this research, as well as the proposed objectives to be met during the research, the tools used and the work plan.
- The second chapter reviews other works similar to ours and extensively studies the previous knowledge about electroencephalography and biometric sensors and their application to emotion prediction. It also examines the basic concepts for understanding this research and reviews the devices used to capture electroencephalogram and biometric data.
- The third chapter presents the overall architecture of the system in order to form a complete map view of the project.
- The fourth chapter describes the data capture process of the electroencephalograph and the biometric sensors.
- In the fifth chapter we design the procedure of the data recording sessions with which we intend to obtain the necessary data to train the machine learning models and describe their implementation. It ends with the gener-

ation of the raw data file from the files generated by the electroencephalograph, the biometric sensors, and an application with which the emotions are recorded on a monthly basis during the recording sessions,

- The sixth chapter is dedicated to the data preprocessing process and the training of the different machine learning models.
- The seventh chapter develops a communication process between the electroencephalograph and biometric sensors in real time, uses the model to predict hot emotions and reviews the communication process of a video game engine with the electroencephalograph and biometric sensors.
- The eighth chapter presents the evaluation system, the results obtained and analyzes the predictions of the models.
- The ninth chapter discusses the advantages and limitations of our work from a technical point of view.
- The tenth chapter presents the most important conclusions drawn from the development of this research and outlines possible points that future research could improve.
- The eleventh chapter details the contribution of each member of this dissertation.

Chapters 1 and 12 are available in English after their Spanish counterparts.

Finally, the complete bibliography referenced by the work is presented.

Capítulo 2 - Estado del arte

En este capítulo se revisan otros trabajos similares al nuestro y estudia extensivamente el conocimiento previo que hay con relación a la electroencefalografía y los sensores biométricos y su aplicación a la predicción de emociones. También examina los conceptos básicos para el entendimiento de esta investigación: el cerebro humano y los distintos modelos de aprendizaje automático. Finalmente, se revisan los dispositivos utilizados para capturar el electroencefalograma y los datos biométricos.

2.1 Trabajos relacionados

Se han utilizado previamente redes neuronales profundas con EEG-Inception para analizar y clasificar señales EEG extraídas de la base de datos SEED (Zamora García, 2023). En este trabajo, los sujetos ven vídeos de 4 minutos de duración asociados a emociones negativas, positivas y neutras. Sus electroencefalogramas se clasifican por una parte en los multiclases "triste", "neutral" y "feliz" y, por otra parte, de forma binaria, en "felicidad" o "tristeza". Sus resultados fueron una precisión del 51,58% en la clasificación multiclase y un 77,49% en la clasificación binaria.

Una investigación ha utilizado previamente SVM para clasificar del 1 al 9 la felicidad, la excitación, la dominancia y el agrado de señales EEG extraídas de la base de datos DEAP, en la que los sujetos ven vídeos de 1 minuto de YouTube y proporcionaron su nivel de felicidad, excitación, dominancia y agrado en una escala del 1 al 9 al terminar cada vídeo; y probaron distinto número de canales, distintos métodos de transformación de señal, distintas representaciones de características y distintas técnicas de transformación de características para dar con los mejores resultados (Wichakam & Vateekul, 2014). Concluyeron que la mejor extracción de características se daba con 1 minuto de datos EEG de 10 canales usando filtro de potencia de banda.

Otro estudio también ha utilizado SVM para clasificar datos EEG en tiempo real en emociones alegres e infelices suscitadas por imágenes y música clásica (Jatupaiboon, 2013). La precisión media del modelo dependiente del sujeto es de aproximadamente 75,62% y la precisión media del modelo independiente de los sujetos es de aproximadamente 65,12%. Este trabajo destaca que los canales temporales (T7 y T8)

dan mejores resultados que otras áreas, que las frecuencias altas (Beta y Gamma) dan mejores resultados que las frecuencias bajas y que suscitar las emociones en periodos de 30 o 60 segundos no tienen diferencias significativas. Basándose en sus resultados, los investigadores implementan el sistema de detección de felicidad usando solo un par de canales. Cabe destacar que, en este trabajo, se desarrollan dos videojuegos que reaccionan a la predicción de la felicidad en tiempo real: uno que muestra la expresión facial del jugador en tiempo real y reproduce música acorde a su nivel de felicidad, y otro en el que el avatar corre automáticamente a una velocidad dependiente del nivel de felicidad del jugador.

Se ha utilizado C4.5 para estimar los valores que los sujetos sienten en las emociones de alegría, tristeza, relajación y estrés en una escala de Likert de 5 valores al escuchar una colección de 121 canciones MIDI de estilo japonés y occidental que inducen emociones. El experimento se llevó a cabo en dos fases: primero, los sujetos escucharon todas las canciones y calificaron manualmente las emociones sentidas usando la escala de Likert. Después, los diez temas más relajantes y los diez más estresantes fueron seleccionados para la grabación de datos de EEG. Los datos obtenidos de los sensores de EEG se transformaron en anotaciones emocionales continuas utilizando el método de análisis de espectro emocional (ESAM). Los modelos de emoción creados utilizando el algoritmo C4.5 mostraron resultados prometedores, con un error absoluto relativo promedio del 6,54% en la validación cruzada de 10 iteraciones. Las conclusiones sugieren que este enfoque no solo permite clasificar la música por emociones inducidas de manera precisa, sino que también podría aplicarse en sistemas de recomendación de música personalizados, mejorando significativamente la precisión de las recomendaciones basadas en el estado emocional del usuario.

Ya se ha utilizado únicamente las señales EEG para controlar directamente al avatar del videojuego Elden Ring mapeando patrones EEG relacionados a una cierta acción preentrenada a un comando específico del videojuego (Perrikaryal, 2023). Los patrones entrenados fueron "imaginarse a uno mismo empujando un objeto pesado", "imaginar la sensación de una fuerte fuerza centrífuga" y "imaginar un objeto hundiéndose lentamente en el agua". Para el movimiento del avatar, se utilizó el giroscopio de 3 ejes proporcionado por el electroencefalógrafo.

2.2 Aspectos relevantes de las estructuras cerebrales para sistemas de electroencefalograma

Antes de leer este documento, es necesario comprender cómo funciona el cerebro humano, qué partes de este realizan cada función y qué papel desempeñan las neuronas y sus conexiones entre ellas.

2.2.1 Partes del cerebro

Se encuentran 3 secciones en las que se divide en encéfalo, el cerebro, el cerebelo y el tronco cerebral. El primero, a su vez, se divide en dos hemisferios, izquierdo y derecho, y se encuentra rodeado de una superficie llamada corteza. El cerebro se encarga de controlar todo tipo de funciones motoras y emocionales, y de realizar funciones cognitivas como la conciencia o la memoria entre otras. El cerebelo, por su parte, se encarga de coordinar el movimiento voluntario de los músculos, así como mantener el equilibrio del cuerpo. Por último, el tronco cerebral se encarga de movimientos involuntarios, como el de los pulmones o el corazón. (Netsky, 1986).

2.2.2 Las neuronas

La lectura EEG es un método no invasivo que se puede realizar repetidas veces. Cuando se activan las neuronas, se producen flujos de corriente eléctrica, que son la fuente que se mide con esta lectura (Kirschstein & Köhling, 2009).

Para entender estos flujos de corriente eléctrica, antes debemos entender la estructura de dichas células. Se componen de un gran cuerpo celular y de fibras nerviosas, una prolongación alargada denominada axón para enviar impulsos y habitualmente muchas ramificaciones denominadas dendritas para recibirlos. Los impulsos procedentes del axón cruzan una sinapsis (la unión entre dos células nerviosas o neuronas) hacia la dendrita de otra célula.

Cada axón está rodeado por oligodendrocitos en el encéfalo y en la médula espinal y por células de Schwann en el sistema nervioso periférico. Las membranas de estas células están compuestas por una sustancia grasa denominada mielina, que se

asemeja a un aislante. Los impulsos nerviosos viajan mucho más rápido a través de los nervios recubiertos con una vaina de mielina que a través de los que carecen de ella.

Las diferencias de potenciales eléctricos detectados por el dispositivo son causadas por potenciales graduados postsinápticos sumados de células piramidales que crean dipolos eléctricos entre el soma (el cuerpo de la neurona) y las dendritas apicales.

La corriente eléctrica cerebral consiste principalmente en iones Na^+ , K^+ , Ca^{++} y Cl^- que se bombean a través canales en las membranas neuronales en la dirección gobernada por el potencial de membrana.

La actividad eléctrica sólo es detectada en grandes poblaciones de neuronas activas. Las señales eléctricas débiles detectadas por los electrodos del cuero cabelludo se amplifican masivamente y luego se muestran y/o se almacenan en la memoria de la computadora.

2.3 La electroencefalografía

La electroencefalografía es una técnica utilizada para registrar y medir la actividad eléctrica del cerebro. Es una prueba neurofisiológica que mide la función de las neuronas desde el punto de vista eléctrico, mediante la fijación de unos sensores llamados electrodos en la cabeza.

La parte más influenciada sobre el EEG es la corteza cerebral, debido a su proximidad bajo el cuero cabelludo. Existe una notación estándar para la localización de los electrodos sobre el mismo. Los puntos se etiquetan por las áreas del cerebro: F (frontal), C (central), T (temporal), P (posterior) y O (occipital); y números impares para el lado izquierdo y pares para el derecho desde el punto de vista del sujeto (Teplan, 2002).




Ilustración 1: Nomenclatura estandarizada del sistema 10/10, extendida con electrodos anteriores y posteriores de la cadena inferior (Seeck y otros, 2017)

2.3.1 Historia de la electroencefalografía

La electroencefalografía fue inventada por el neurólogo y psiquiatra alemán Hans Berger, apodado como “padre de la encefalografía y de la psicofisiología” en el año 1924. 1770 el italiano Luigi Galvani publicó sus observaciones sobre la electricidad animal. Con esta publicación demostró la existencia de “electricidad animal intrínseca” pero estas no tuvieron mucho impacto a pesar de que su sobrino, Luigi Giovanni Aldini las confirmara en 1774 (Palacios Sánchez, 2002).

El interés por el fenómeno eléctrico intrínseco motivó al científico alemán Emil du Bois Raymond, quien publicó el primer volumen de un libro llamado “Investigaciones sobre la electricidad animal” en 1848 y un año después el siguiente volumen.

Las primeras descripciones sobre la existencia de actividad eléctrica cerebral fueron de la mano del fisiólogo inglés Richard Caton gracias a las influencias por parte de los investigadores Edouard Hitzig y Gustav Theodor Fritsch. En 1874, Caton confirmó su hipótesis de que los estímulos periféricos podían evocar respuestas eléctricas cerebrales focales. Finalmente, en 1875 hizo una publicación donde demostraba respuestas motoras discretas y locales en perros. Además, en esta publicación fue el primero en observar la actividad eléctrica cerebral, continua y espontánea (Palacios Sánchez, 2002).

Unos 15 años después de los descubrimientos de Caton, Adolf Beck y su mentor Cybulsky, inspirados por los trabajos de Hitzig y Fritsch realizaron nuevas propuestas para intentar otros métodos de localización funcional en el cerebro. En su tesis doctoral de 1891, Beck investigó la existencia y posibles modificaciones de corrientes eléctricas en el cerebro y la médula espinal. Su última publicación conjunta fue en 1895.

Por otro lado, Fleisch Von Marxow, confirmó la actividad eléctrica rítmica en la superficie cerebral de perros mediante electrodos impolarizables.

A comienzos del siglo XX, los rusos Pavel Kaufman y Pradvich Neminski establecieron que los potenciales eléctricos cerebrales pueden ser registrados a través del cráneo intacto. Realizaron experimentos con perros, en los cuales se les realizaban craneotomías y se colocaban electrodos sobre la corteza cerebral para registrar actividad electroencefalográfica epileptiforme, siendo además la primera vez que se registraba fotográficamente. Kaufman observó dos períodos bioeléctricos durante la anestesia: un aumento inicial de potenciales (fase de excitación) y una posterior disminución (fase de depresión). Por su parte, Neminski utilizó un galvanómetro de cuerda para describir los distintos ritmos cerebrales captados en cerebros de perro según su frecuencia (10 a 15, 20 a 32 ciclos por segundo), creando el término "electrocerebrograma" para estas oscilaciones.

2.3.2 Tipos de electroencefalógrafos

Existen varios tipos de EEG: los de gel, los secos, que son el tipo usado en el proyecto, y los de solución salina. Los EEG de gel conductivo se emplean para mejorar el contacto con el cuero cabelludo, mantienen una baja impedancia, generalmente por debajo de los 10 k Ω , y representan el estándar en grabaciones clínicas. Aunque ofrecen

mediciones más precisas que los electrodos secos, presentan ciertas desventajas asociadas con la preparación requerida para su uso. Los EEG de gel demandan la preparación de la piel, la aplicación del gel, la optimización de la impedancia a cargo de personal especializado, y la limpieza posterior a la grabación. Además, durante sesiones prolongadas, la calidad de la señal puede deteriorarse a medida que el gel se seca. Por consiguiente, el empleo de los EEG de gel conlleva costes técnicos y temporales adicionales, lo que dificulta su aplicación en entornos domésticos.

En contrapartida, los EEG secos no requieren ninguna preparación ni limpieza posterior al uso, lo que los convierte en la opción más conveniente para nuestro propósito, especialmente durante la ejecución de videojuegos. Este tipo de EEG facilita el cambio ágil de sujetos de prueba y permite una mayor participación, ya que la aplicación de gel no es deseable para los participantes en un experimento de ocio, no clínico, como es nuestro caso.

Respecto a la calidad de las grabaciones, los EEG secos pueden obtener resultados comparables a los EEG de gel. Encontraremos más señales no deseadas en los EEG secos, pero estos también son menos sensibles a las interferencias electromagnéticas de 50 Hz (Hinrichs y otros, 2020).

Por último, se encuentran los EEG de solución salina. En este tipo de EEG se moja el cuero cabelludo con una solución salina para mejorar la conductividad, lo que permite una señal más clara y precisa que los secos, pero menos que los de gel. Además, son menos invasivos que los de gel y son más fáciles de aplicar y limpiar. Al igual que ocurre con los de gel, la solución salina puede secarse con el tiempo, necesitando aplicarla nuevamente durante sesiones largas.

2.3.3 Las ondas cerebrales

Las ondas cerebrales son oscilaciones o ritmos eléctricos que se observan en los registros de EEG. Diversas oscilaciones pueden reflejar el estado de ánimo de la persona como cansancio, relajación, concentración, etc. Existen oscilaciones asociadas a diferentes etapas del sueño por lo que se puede utilizar para estudiarlas y determinarlas. Las ondas cerebrales se clasifican en diferentes bandas de frecuencia, cada una asociada

con estados mentales, actividades o funciones cognitivas específicas (Neurotechnology).

- **Ondas Delta (0,5 – 4 Hz):** Asociadas con el sueño profundo, la inconsciencia y ciertos estados cerebrales anormales.
- **Ondas Theta (4 – 8 Hz):** Asociadas con los sueños, la creatividad, la meditación y la relajación profunda.
- **Ondas Alfa (8 – 13 Hz):** Asociadas con la relajación al estar despierto, el soñar despierto y un estado mental tranquilo.
- **Ondas Beta (13 – 30 Hz):** Asociadas con la conciencia normal de vigilia, la concentración y las tareas cognitivas.
- **Ondas Gamma (30 – 100 Hz):** Asociadas con funciones cognitivas superiores, percepción y conciencia.

2.3.4 Señales no deseadas en los electroencefalogramas

Las grabaciones de EEG capturan la actividad neuronal del cerebro y otras señales eléctricas de fuentes más poderosas. Estos se denominan señales no deseadas y pueden dificultar la interpretación visual de las señales o incluso pueden confundirse con la actividad EEG real. Normalmente, se busca minimizar las señales no deseadas de las grabaciones de EEG con diversas técnicas de procesamiento para tener una señal de EEG limpia de señales no deseadas (Cohen, 2019).

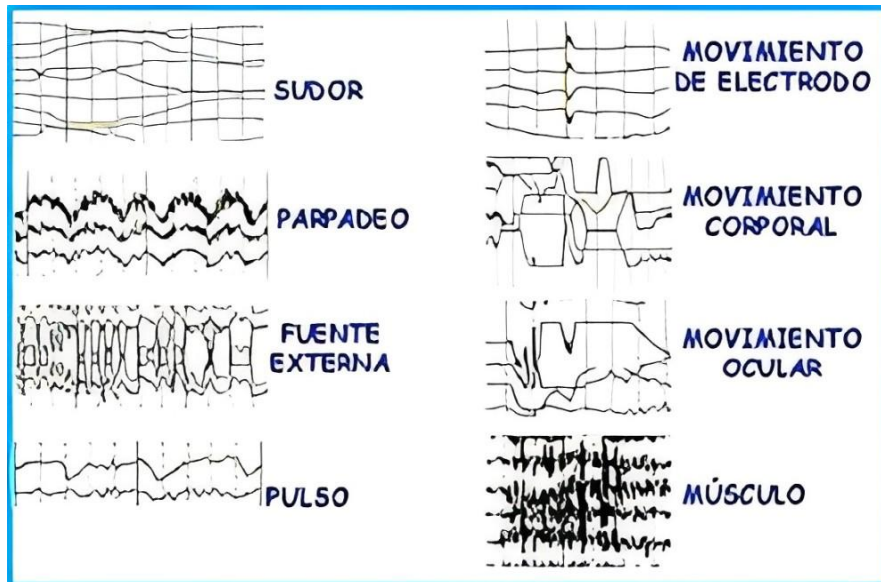


Ilustración 2: Irregularidades causadas en la señal producidas por distintas señales no deseadas (Guzmán Álvarez, 2015)

2.3.4.1 Parpadeos y movimientos de ojos

Se trata de señales de alta amplitud que se observan en los registros de EEG, especialmente en la frente y los lóbulos frontales. Se pueden detectar fácilmente y ahora existen muchos algoritmos que intentan abordar su eliminación automática de señales de EEG como ASR.

2.3.4.2 Actividad muscular

El movimiento del cuello, la mandíbula y la lengua genera señales eléctricas debido a contracciones musculares que son relativamente grandes y, por lo tanto, son captadas por los electrodos de EEG que se encuentran en un lugar cercano. Las señales eléctricas asociadas con la actividad muscular son de banda ancha y se encuentran en el rango de las ondas Beta y Gamma, lo que hace que su eliminación sea una tarea desafiante.

2.3.4.3 Actividad cardíaca

El potencial de actividad cardíaca también se puede detectar en el registro EEG. Esto es particularmente visible si se coloca un electrodo en algún vaso sanguíneo impor-

tante. El ruido de las señales cardíacas se puede eliminar, por ejemplo, registrando simultáneamente un electrocardiograma (ECG) y utilizando esta información para eliminar las señales no deseadas de las señales de EEG.

2.3.4.4 Fuentes de ruido ambiental

Esto suele ser causado por equipos eléctricos alimentados por la red eléctrica principal y se manifiesta como ruido de frecuencia de 50 Hz o 60 Hz en las grabaciones de EEG. Esto se puede minimizar eliminando las fuentes del entorno de grabación o usando electrodos activos, un mejor blindaje del equipo de medición, un mejor contacto de los electrodos con el cuero cabelludo, etc. Si el ruido de la red no es extremadamente grande, se puede eliminar de las señales con técnicas de filtrado convencionales.

2.3.5 Aplicaciones de la electroencefalografía

Existen muchas aplicaciones para las mediciones de la electroencefalografía y los casos de uso seguirán creciendo a medida que siga aumentando la accesibilidad de sus dispositivos. Los principales usos de la electroencefalografía están ligados al campo de la medicina, en aspectos clínicos. Se utiliza entre otros grandes aspectos para diagnosticar epilepsia, comas, muertes cerebrales (Ramos-Argüelles, 2009), trastornos del sueño (Guadamuz, 2022), accidentes cerebrovasculares, encefalitis y otros trastornos cerebrales (Grave-de Peralta, 2004).

La electroencefalografía se utiliza ampliamente como herramienta en neurociencia cognitiva, neurociencia clínica, psicología, neurolingüística y otras. También se utiliza para investigar los mecanismos neuronales implicados en la consolidación y recuperación de la formación de la memoria, además de proporcionar información sobre la plasticidad neuronal y los procesos de aprendizaje.

Como método accesible y no invasivo, el EEG se utiliza con bastante frecuencia para medir la actividad cerebral en los sistemas *BCI*. Los sistemas *BCI* tienen como objetivo transferir la intención/comando de una persona a una computadora u otro dispositivo.

2.3.6 Configuración de medición del electroencefalograma

El sistema 10/20 es un enfoque estandarizado utilizado para la notación de la colocación de electrodos. Garantiza que los electrodos con el mismo nombre se colocarán en la misma ubicación relativa con respecto a otros electrodos, independientemente del tamaño del cabezal o la cantidad de electrodos utilizados por el sistema de medición. En la siguiente figura se muestra un ejemplo de colocación de 19 electrodos y su denominación. La notación estándar ayuda a los médicos, investigadores y otras personas a comparar fácilmente sus mediciones sabiendo exactamente la ubicación topográfica sobre la que se realizó la medición.




Ilustración 3: Nomenclatura estandarizada del sistema 10/20 (Neurotechnology)

En el montaje secuencial, las mediciones de EEG se realizan entre pares de electrodos, normalmente colocados relativamente cerca uno del otro. Sin embargo, un enfoque más popular es utilizar un electrodo de referencia común, donde se mide una diferencia de voltaje entre cualquier electrodo y este electrodo de referencia. Sin embargo, la colocación del electrodo de referencia no está estandarizada y algunas configuraciones colocan el electrodo de referencia en la oreja, otras en la frente o alguna

otra ubicación, lo que produce mediciones directamente incomparables entre diferentes configuraciones. No obstante, las señales se pueden volver a calcular en el preprocesamiento para utilizar una referencia promedio o *REST* (técnica de estandarización de electrodos de referencia) que estandarice estos registros de EEG de referencia comunes.

Como hemos mencionado en el apartado 2.3.2, usamos el tipo de EEG seco, sin embargo, este tipo de electrodos son menos estables que los electrodos a base de gel y requieren más procedimientos de preprocesamiento para garantizar registros de buena calidad.

Hay dos tipos de electrodos en términos de amplificación de señal que se utilizan en las grabaciones de EEG. Electrodos pasivos, donde los electrodos se conectan con cables al dispositivo de medición donde se realiza la amplificación y digitalización de la señal. Los electrodos activos tienen preamplificadores integrados en el electrodo que amplifican la señal de EEG antes de enviarla al dispositivo de medición. Esto ayuda a reducir el ruido eléctrico ambiental captado por los cables, que puede reducir la calidad de las grabaciones de EEG medidas. Sin embargo, los electrodos activos añaden más complejidad y son más costosos en comparación con los electrodos pasivos.

2.3.7 Preprocesamiento de señales del electroencefalograma

2.3.7.1 Filtrado de frecuencia

El filtrado de frecuencia es un proceso utilizado en el procesamiento de señales para modificar o eliminar ciertas frecuencias de una señal de entrada. Esto se logra mediante el uso de filtros, que son dispositivos electrónicos o algoritmos que pueden atenuar o amplificar diferentes componentes de una señal según su frecuencia .

El filtrado de frecuencia se aplica en una amplia variedad de campos, como el procesamiento de señales de audio, imágenes, radar, telecomunicaciones y electrónica en genera, además de señales electroencefalográficas, que es nuestro caso. Es una herramienta fundamental para mejorar la calidad y la utilidad de las señales en numerosas aplicaciones.

Se distinguen varios tipos de filtros, los clasificados por su tipo de frecuencia, por tecnología, por el comportamiento en la frecuencia, por estructura, por implementación y por aplicación.

Según el tipo de frecuencia, encontramos los filtros de paso bajo, que permiten el paso de frecuencias por debajo de cierto valor de corte y atenúan las frecuencias por encima de este valor. Son útiles para eliminar ruido de alta frecuencia en una señal; los filtros de paso alto, que permiten el paso de frecuencias por encima de cierto valor de corte y atenúan las frecuencias por debajo de este valor. Se utilizan, por ejemplo, para eliminar el ruido de baja frecuencia; los filtros de paso de banda, que solo permiten el paso de frecuencias dentro de un rango específico y atenúan las frecuencias fuera de ese rango. Son útiles para aislar una parte específica de una señal; y, por último, los filtros de rechazo de banda, que bloquean un rango específico de frecuencias y permiten el paso de todas las demás. Se usan, por ejemplo, para eliminar interferencias específicas.

En cuanto a los clasificados por tecnología, tenemos dos tipos, los digitales, y los analógicos. Los clasificados por estructura se distinguen en pasivos y activos. Los filtros de implementación son o filtros *IIR* (Infinite Impulse Response), que utilizan retroalimentación y son eficaces a nivel computacional, o los *FIR* (Finite Impulse Response), que tienen una respuesta al impulso finita, sin retroalimentación. Por aplicación, encontramos los filtros de audio, usados por ejemplo en ecualización o eliminación de ruido, los filtros de *Anti-aliasing*, usados antes del muestreo de una señal, los de reconstrucción, empleados tras la conversión digital a analógica, para suavizar la señal, y los filtros de radiofrecuencia, utilizado en sistemas de comunicación. (Manjit Sandhu, 2016)

Por último, tenemos los filtros clasificados según su comportamiento con la frecuencia, en ellos encontramos los filtros de Butterworth, de Chebyshev, de Bessel, y los filtros elípticos. Los filtros Butterworth, se caracterizan por un resultado de frecuencia lo más plana posible en la banda de paso, es decir, evitando las ondulaciones. Los de Chebyshev, se diferencian en dos tipos, de Tipo I, o de Tipo II, los del primer tipo tienen ondulaciones en la banda de paso y una atenuación rápida fuera de esta, y, por lo contrario, el del segundo tipo, no tiene estas ondulaciones en la banda de paso, pero las tiene en la banda de rechazo (Anju, 2012).

2.3.7.2 Eliminación de señales no deseadas

En el apartado 2.3.4 se han discutido distintos tipos de señales no deseadas que pueden afectar a la señal EEG y por tanto a realizar una interpretación precisa. Por ello se deben contar con algunas técnicas capaces de eliminar señales no deseadas durante la etapa de preprocesamiento.

Existen diferentes tipos de técnicas para la supresión de señales no deseadas en los datos, por ejemplo, tenemos la eliminación basada en umbrales, esta técnica consiste en establecer umbrales para algunas características de la señal como pueden ser la amplitud, la variabilidad temporal o presencia de eventos específicos, como por ejemplo picos. Por otra parte, tenemos la técnica de Regresión Lineal, esta técnica consiste en establecer umbrales para algunas características de la señal como pueden ser la amplitud, la variabilidad temporal o presencia de eventos específicos, como por ejemplo picos. Lo que se busca es identificar segmentos de datos que contienen actividad no deseada y eliminarlo. Sin embargo, a pesar de ser relativamente sencilla de implementar hay que tener en cuenta que se pueden eliminar segmentos que contienen buena calidad de datos por lo que hay que establecer los criterios de rechazo con cuidado.

Y por último tenemos el Análisis de Componentes Independientes o *ICA*, esta es una avanzada técnica de procesamiento de señales EEG que separa las fuentes de señales cerebrales de las señales no deseadas.

El objetivo de la técnica yace en descomponer la señal en una serie de componentes independientes que representan actividad cerebral pura y ruido de origen tanto ambiental como biológico. (G. Trejo Alcantara, 2017)

El proceso *ICA* tiene los siguientes pasos:

- 1) Realizar un primer preprocesamiento con filtrado.
- 2) Aplicar *ICA* a los datos preprocesados para descomponer la señal en componentes independientes.
- 3) Tras el paso anterior tendremos que mostrar los componentes en algún formato por ejemplo el topográfico para identificar los componentes que representan ruido y otras interferencias.

4) Una vez identificados las señales que se consideren ruido, se eliminan.




Ilustración 4: Mapa topográfico de cada uno de los componentes en los que se ha dividido la señal EEG original

2.4 Sensores biométricos

Los sensores biométricos son dispositivos electrónicos que se utilizan para medir y analizar características físicas o comportamentales únicas de los seres vivos. Estos dispositivos pueden capturar datos biométricos, como huellas dactilares, iris, voz, patrones faciales, entre otros, y luego utilizar estos datos para verificar la identidad de una persona o para autenticar su acceso a ciertos sistemas o dispositivos. Los sensores biométricos se utilizan en una variedad de aplicaciones, desde la seguridad en dispositivos móviles y computadoras hasta el control de acceso en edificios y sistemas de pago biométricos. (Acuña Llamas y otros, 2018)

2.4.1 Sensor de temperatura

Un sensor de temperatura mide la temperatura de la piel del sujeto, lo cual nos permite tener información sobre la condición ambiental del usuario o sobre cambios fisiológicos.

2.4.2 Sensor de actividad electrodermal

Detecta cambios en la conductividad de la piel, que varía con la cantidad de sudor del sujeto en la piel. Esta sudoración está controlada por el sistema nervioso simpático, por lo que los cambios en la conductancia pueden indicar la activación de este sistema debido a estímulos emocionales o estrés.

2.4.3 Sensor PPG

Los sensores PPG miden la cantidad de luz absorbida por los tejidos corporales, especialmente la piel, para detectar cambios en el volumen sanguíneo. Los tres tipos de luz, infrarrojo, rojo y verde son utilizados en diferentes configuraciones para medir la frecuencia cardíaca, la saturación de oxígeno en la sangre y otros parámetros fisiológicos.

2.4.4 Magnetómetro

Es un sensor utilizado para medir la intensidad y la dirección del campo magnético en su entorno. Este tipo de sensor es esencial en varias aplicaciones, desde la navegación hasta la investigación científica y el monitoreo ambiental.

2.5 Las emociones

En el estudio de la psicología y la neurociencia, las emociones son un fascinante campo de investigación que ha generado una amplia gama de teorías y modelos de clasificación. En este apartado, exploramos la complejidad y la diversidad de las emociones humanas, así como los distintos enfoques utilizados para comprenderlas y categorizarlas (Cacioppo, 1993).

2.5.1 Definición de las emociones

Las emociones son respuestas psicofisiológicas complejas que experimentamos como reacciones a estímulos internos o externos. Estas respuestas pueden manifestarse a través de cambios en el estado de ánimo, expresiones faciales, cambios en la conducta, respuestas fisiológicas como el ritmo cardíaco y la actividad hormonal, entre otros (Kreibig, 2010).

Las emociones pueden variar en intensidad y duración, y desempeñan un papel fundamental en la forma en que percibimos y nos relacionamos con el mundo que nos rodea. Ejemplos comunes de emociones incluyen la felicidad, la tristeza, el miedo, la ira, la sorpresa y el disgusto, aunque existen muchas más emociones que forman parte del espectro emocional humano.

2.5.2 Clasificación de las emociones

A la hora de clasificar las emociones, existen múltiples modelos para clasificar y representar las emociones. Sin embargo, se pueden diferenciar todos estos en dos tipos: los modelos dimensionales y los modelos discretos. (Abeer Al-Nafjan, 2017)

2.5.2.1 Modelos dimensionales

Este tipo de clasificación fue defendido en primer lugar por Wundt (Wundt, 1896), y desarrollado posteriormente por otros autores. Estos dicen que las dimensiones se configuran en un carácter bipolar definido por tres ejes, estos ejes son el eje de valencia afectiva, el eje de activación y el eje de control.

2.5.2.1.1 Modelo de Russell

Propone que las emociones se distribuyen en un espacio circular bidimensional compuesto por activación y valencia. La activación se sitúa en el eje vertical, mientras que la valencia se encuentra en el eje horizontal. El centro del círculo denota una valencia neutral y un nivel de activación medio, con las emociones clasificadas en términos de valencia positiva o negativa y de activación alta o baja (Russell, 1980).

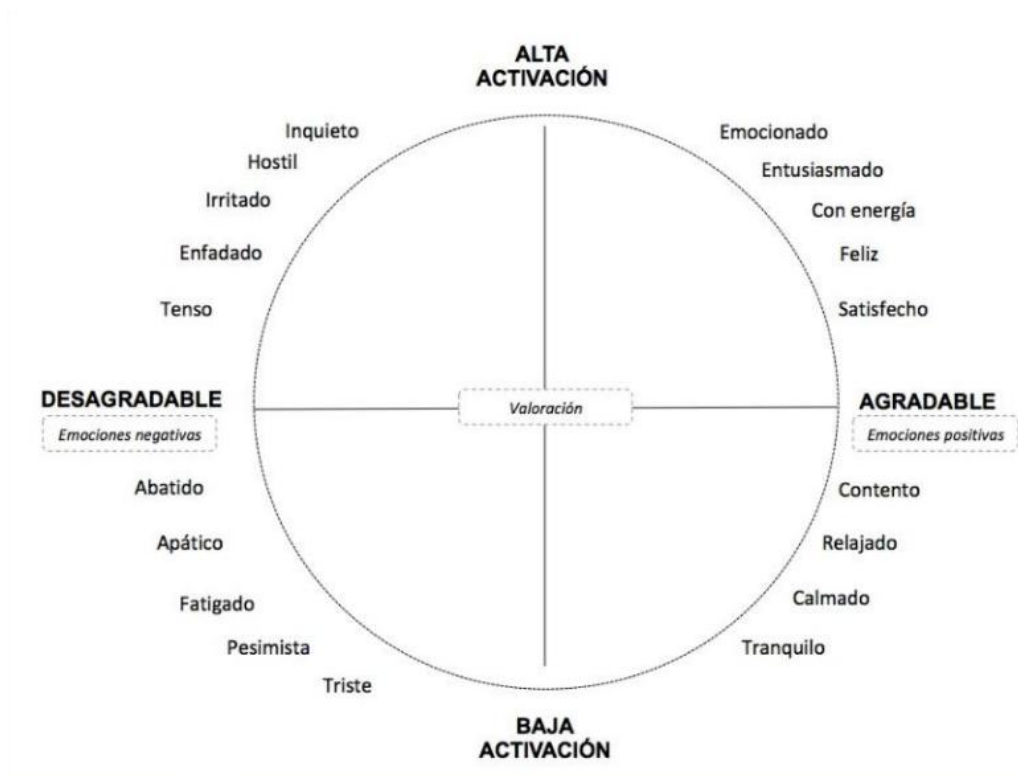


Ilustración 5: Modelo de emociones de Russell

2.5.2.1.2 Modelo de Plutchik

El modelo de Plutchik es otro enfoque para clasificar las emociones, propuesto por el psicólogo Robert Plutchik en la década de 1980. Plutchik identificó ocho emociones primarias básicas que consideraba como las más fundamentales y universales en la experiencia humana. Estas emociones primarias son la alegría, la tristeza, la ira, el miedo, la sorpresa, el disgusto, la confianza y la anticipación. (Manshad & Petrovich, 2019)

Además de estas ocho emociones primarias, Plutchik también propuso que cada una de ellas puede combinarse para formar emociones secundarias y terciarias. Por ejemplo, la combinación de alegría y confianza puede dar lugar a la emoción de amor. (Plutchik, 2001)

Plutchik representó su modelo de emociones en forma de un círculo llamado "Rueda de Emociones", donde las emociones primarias se encuentran ubicadas en posiciones opuestas. Esto sugiere que las emociones opuestas pueden ser percibidas como extremos de un continuo emocional.

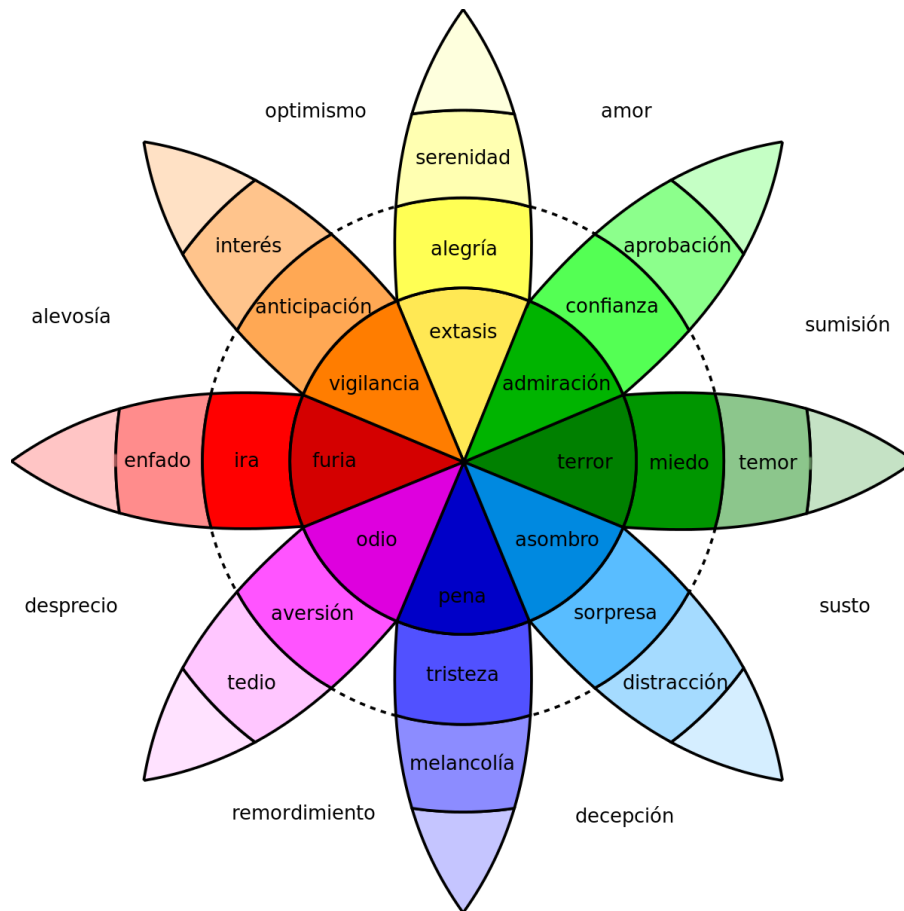


Ilustración 6: Rueda de emociones de Plutchik (Ortiz Bonilla, 2019)

2.5.2.2 Modelos discretos

Los modelos discretos para clasificar las emociones se basan en la premisa de que existe un conjunto limitado y específico de emociones básicas y universales que son intrínsecamente distintas entre sí. Estos modelos definen categorías concretas de emociones que se diferencian claramente unas de otras.

2.5.2.2.1 Modelo de Paul Ekman

Ekman identificó un conjunto de emociones básicas que son universales y reconocibles a través de expresiones faciales consistentes en todas las culturas humanas. Estas emociones son felicidad, tristeza, miedo, ira, sorpresa y disgusto (Ekman, 1992).

2.5.2.2.2 Modelo de Carroll Izard

El modelo discreto de emociones de Carroll Izard, también conocido como la Teoría Diferencial de las Emociones, identifica una serie de emociones básicas y fundamentales que son innatas y universales. Izard propuso que estas emociones básicas son componentes esenciales de la experiencia emocional humana y están presentes desde el nacimiento. Dichas emociones básicas son la alegría, interés-excitación, sorpresa, tristeza, ira, disgusto, desprecio, miedo, vergüenza y culpa. (Izard, 1977)

2.5.2.2.3 Modelo de Parrot

El modelo discreto de Parrot de las emociones es una categorización de las emociones humanas en un sistema estructurado. Este modelo fue propuesto por el psicólogo W. Gerrod Parrott, quien organizó las emociones en una estructura jerárquica que se asemeja a un árbol genealógico. En este modelo, las emociones se agrupan en categorías primarias, secundarias y terciarias (Parrott, 2001).

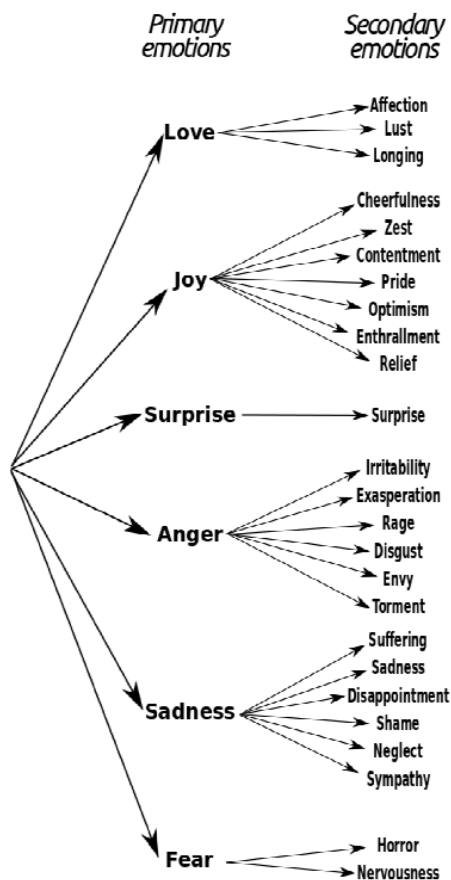


Ilustración 7: Estructura en árbol propuesta por Parrot para la clasificación de emociones

2.5.3 Impacto de las emociones en el cerebro

Las emociones impactan directamente en la actividad cerebral, en concreto, en el sistema límbico, que es una de las partes del cerebro encargadas de procesar las emociones. La red de neuronas de este sistema se ve complementada por otras partes del cerebro como el hipotálamo o el hipocampo. La amígdala también forma parte de este proceso y del sistema límbico, pues está vinculada a la respuesta emocional que despiertan las situaciones experimentadas (Rodríguez Álvarez, 2020).

La amígdala tiene una gran importancia en el procesamiento emocional, en la anatomía de las emociones. Este núcleo cerebral juega un papel central en las reacciones emocionales básicas. Se sitúa al lado de cada hipocampo: hay una en cada hemisferio. Esta zona está relacionada con la respuesta emocional aprendida por lo que es una de las zonas involucradas en el aprendizaje emocional.


La amígdala es el principal núcleo cerebral relacionado e implicado en las respuestas de miedo, tanto innatas como aprendidas. El hipocampo está implicado en procesos mentales relacionados con la memoria, tanto en la memorización de experiencias e informaciones abstractas como en la recuperación de recuerdos. El cerebelo está localizado en la parte posterior del cerebro en el área del tronco encefálico, tiene una forma redondeada como el cerebro y es la encargada de regular y controlar los movimientos correctos de los seres humanos.

En último lugar se identifica la corteza cerebral, que ocupa la mayor parte del órgano y está formada por dos hemisferios, el izquierdo y el derecho. Se encarga de controlar el pensamiento consciente. Si se analiza la corteza cerebral en mayor profundidad, ésta se divide en cuatro áreas llamadas lóbulos, que corresponden con el occipital, temporal, parietal y frontal (de la Rosa Centella, 2019).

La evidencia científica muestra que las estructuras prefrontales son las principales encargadas de organizar el comportamiento y la toma de decisiones. Estas estructuras se encargan del control de la regulación emocional, la comprensión de situaciones complejas y el comportamiento social adaptativo. En condiciones normales ambos hemisferios cerebrales trabajan de forma complementaria en la regulación y control de las emociones.

Sin embargo, investigaciones como la de Canli y otros , sugieren que cada hemisferio muestra una vinculación diferencial con las reacciones emocionales de valencia positiva y negativa. El hemisferio derecho es dominante en el control del tono emocional, con un mayor procesamiento de las emociones negativas como el miedo o la ira, sin embargo, el hemisferio izquierdo es dominante en la interpretación de las emociones positivas como la alegría.

Anatomía del cerebro



© 2000 BrightFocus Foundation

Ilustración 8: Anatomía del cerebro y sistema límbico (BrightFocus® Foundation, 2015)

2.6 Modelos de aprendizaje automático

Un modelo de aprendizaje automático es un algoritmo que permite a una computadora aprender a realizar tareas específicas sin necesidad de ser programada explícitamente para cada una de esas tareas. En lugar de seguir un conjunto fijo de reglas, como en la programación tradicional, los modelos de aprendizaje automático aprenden a través de la experiencia y los datos.

Estos modelos pueden realizar una variedad de tareas, como reconocimiento de patrones, clasificación, predicción, y mucho más. Utilizan técnicas estadísticas y matemáticas para identificar patrones en los datos y luego generalizar esos patrones para hacer predicciones o tomar decisiones sobre nuevos datos.

2.6.1 Tipos de modelos de aprendizaje

Los modelos de aprendizaje automático se pueden clasificar en varias categorías según el tipo de aprendizaje y la forma en que se estructuran.

2.6.1.1 Modelos de aprendizaje supervisado

Los algoritmos deducen la información a partir de datos a los que se les han asignado valores. Estos datos sirven para entrenar un modelo, mientras que un segundo conjunto de datos de prueba permite determinar hasta qué punto es eficaz el modelo creado. Algunos de los modelos que hay dentro de este tipo son:

En primer lugar, *SVM*, o *Support Vector Machines*, son un tipo de algoritmo de aprendizaje supervisado utilizado tanto para clasificación como para regresión. Su objetivo principal es encontrar un hiperplano en un espacio N-dimensional (donde N es el número de características) que mejor separe las clases de los datos (Cortes & Vapnik, 1995).

En segundo lugar, se encuentran los árboles de decisión o *Decision Tree* que son modelos de aprendizaje que utilizan una estructura de árbol para representar decisiones y sus posibles consecuencias. Cada nodo interno del árbol representa una característica de los datos, cada rama representa el resultado de una prueba y cada nodo hoja representa una etiqueta de clase. El modelo toma decisiones basadas en la estructura del árbol, evaluando características y siguiendo las ramas correspondientes hasta llegar a una decisión final (S. W. Loh, 2003).

Por otro lado, está *random forest* que es un algoritmo de aprendizaje automático supervisado, que se utiliza tanto para problemas de clasificación como de regresión. Se basa en la idea de ensamblar múltiples árboles de decisión, modelo visto en el apartado anterior, durante el proceso de entrenamiento y hacer predicciones basadas en la mayoría de los votos o promedio de los resultados individuales de estos árboles (Random forests, 2001).

Por último, *KNN* es un modelo utilizado para problemas de clasificación y regresión. Aunque es más comúnmente conocido como un algoritmo de clasificación, también puede adaptarse para tareas de regresión. Es un algoritmo basado en instancias, lo que significa que no aprende explícitamente un modelo durante la fase de entrenamiento. En cambio, almacena todos los ejemplos de entrenamiento y hace predicciones basadas en la similitud entre las nuevas instancias de datos y los ejemplos de entrenamiento almacenados (Aha, 1991).

2.6.1.2 Modelos de aprendizaje no supervisado

Los datos de entrenamiento se utilizan sin etiquetar. Los algoritmos detectan agrupaciones de datos o patrones ocultos sin que se precise intervención humana. Resultan muy útiles para descubrir semejanzas y diferencias en la información, de manera que se pueden aplicar a procesos como la segmentación de clientes o el reconocimiento de imágenes.

2.6.2 Redes neuronales

Una red neuronal es una técnica de inteligencia artificial que enseña a las computadoras a procesar datos de una manera inspirada en el funcionamiento del cerebro humano. Esta técnica pertenece al ámbito del aprendizaje automático, específicamente al aprendizaje profundo, y se basa en la interconexión de nodos o neuronas en capas, imitando la estructura del cerebro.

Al emplear este enfoque, se crea un sistema adaptable que permite a las computadoras aprender de errores pasados y mejorar de forma continua. De esta manera, las redes neuronales artificiales se utilizan para abordar desafíos complejos, como la síntesis de resúmenes de documentos o el reconocimiento facial, con una mayor precisión.

Las redes neuronales pueden ayudar a las computadoras a tomar decisiones inteligentes con asistencia humana limitada. Esto se debe a que pueden aprender y modelar las relaciones entre los datos de entrada y salida que no son lineales y que son complejos. Por ello, se usan en un amplio campo de trabajos, entre los que destacan algunos como el reconocimiento visual y reconocimiento de voz, predicción y análisis de datos, o procesamiento del lenguaje natural.

Existen varios tipos de redes neuronales, cada una diseñada para abordar diferentes tipos de problemas y datos.

2.6.2.1 Redes Neuronales Artificiales (ANN)

Las redes neuronales artificiales son el tipo más básico y general de red neuronal. Están compuestas por una o más capas de neuronas, que están interconectadas mediante conexiones ponderadas. Cada neurona en una capa está conectada a todas

las neuronas de la capa siguiente. Estas redes son adecuadas para una amplia gama de aplicaciones, incluyendo clasificación, regresión y reconocimiento de patrones.

2.6.2.2 Redes Neuronales Convolucionales (CNN)

Son especialmente efectivas en tareas de visión por computadora y reconocimiento de imágenes. Las CNN están diseñadas para procesar matrices de datos bidimensionales, como imágenes, y son capaces de capturar patrones espaciales a través de capas convolucionales. Son ampliamente utilizadas en aplicaciones como el reconocimiento facial, la clasificación de objetos y la detección de características en imágenes médicas.

2.6.2.3 Redes Neuronales Recurrentes (RNN)

Diseñadas para trabajar con secuencias de datos, como texto, audio o series temporales. Las RNN tienen conexiones retroalimentadas que les permiten recordar información de pasos anteriores en la secuencia. Esto las hace adecuadas para tareas como el análisis de sentimientos en texto, la traducción automática, la generación de texto y el reconocimiento de voz.

2.6.2.4 Redes Neuronales Generativas Adversarias (GAN)

Consisten en dos redes neuronales en competencia: el generador y el discriminador. El generador crea muestras de datos falsas, mientras que el discriminador intenta distinguir entre datos reales y falsos. Este proceso de competencia impulsa al generador a mejorar continuamente, generando datos cada vez más realistas. Las GAN se utilizan en la generación de imágenes, la superresolución de imágenes, la síntesis de voz y la generación de texto, entre otros.

2.6.2.5 Redes Neuronales Profundas (DNN)

Se refiere a cualquier red neuronal con múltiples capas ocultas. Las DNN son capaces de aprender representaciones de datos altamente abstractas y complejas, lo que las hace adecuadas para una amplia gama de aplicaciones, desde el procesamiento del lenguaje natural hasta la visión por computadora y el análisis de datos.

Un tipo de modelo de aprendizaje profundo es *MLP*, o perceptrón multicapa, que específicamente una arquitectura de red neuronal artificial. Se utiliza principalmente para problemas de clasificación y regresión. El *MLP* consiste en múltiples capas de neuronas. Estas capas están organizadas en una estructura de capa de entrada, una o más capas ocultas y una capa de salida. Cada neurona en una capa está conectada a todas las neuronas de la capa siguiente (Haykin, 1999).

2.7 Tecnologías usadas en el trabajo

Para poder comprender el funcionamiento de nuestro trabajo y como lo hemos llevado a cabo, es necesario conocer qué dos dispositivos hemos usado para las sesiones de captura de datos, a continuación, explicamos el electroencefalógrafo utilizado, llamado, BrainAccess MIDI, y el aparato biométrico, llamado EmotiBit.

2.7.1 El electroencefalógrafo BrainAccess MIDI

Para medir la actividad cerebral se consideraron diversas opciones disponibles en el mercado. La búsqueda fue ardua debido a los altos precios y la reducida oferta. Finalmente, con el presupuesto disponible, se optó por la herramienta BrainAccess MIDI.

BrainAccess MIDI es un electroencefalógrafo seco de 16 canales con un canal común de referencia. La herramienta está formada por varias partes. La pieza principal es la pila que contiene la batería y donde se conectan electrodos. Para conectarlos, se utilizan 16 cables agrupados en 4 sobres. Cada uno de estos sobres contiene 4 cables de una longitud específica. Los hay de 10 centímetros, de 15 centímetros, de 20 centímetros y de 25 centímetros. La pila principal es muy sencilla. Tiene un botón de encendido y con una luz LED, que se vuelve roja cuando está encendido, parpadea cuando la batería está por debajo del 10%, y se vuelve azul cuando se conecta vía Bluetooth 4.2 (Neurotechnology).

BrainAccess MIDI incluye BrainAccess CAP, el propio casco, hecho de un tejido flexible que se ajusta al cráneo con 34 agujeros que permiten al usuario una gran variedad de disposición de los electrodos. Gracias a ello, el usuario puede decidir si medir zonas específicas del cerebro, o medir una grabación más general. Está disponible en tres tallas que cubren un rango de diámetros del cráneo específico.

La batería de BrainAccess MIDI se puede cargar a través de un puerto Micro-USB utilizando cargadores estándar de 5 V. El cargador debe ser capaz de proporcionar al menos 800 mA de corriente. El dispositivo se puede utilizar mientras se carga, pero no es recomendable.

El hardware se compone por las entradas de EEG, la entrada de referencia y la entrada de polarización. Las entradas EEG deben conectarse a electrodos que miden la actividad del EEG con respecto al electrodo de referencia. La entrada de referencia que debe conectarse a un electrodo de referencia común. En las configuraciones del kit BrainAccess, normalmente se coloca un electrodo en la ubicación Fp1. La conexión se indica como 'R' en el dispositivo. La entrada de polarización debe conectarse a un electrodo de polarización. En las configuraciones del kit BrainAccess, normalmente se coloca un electrodo en la ubicación Fp2. La conexión se indica como 'B' en el dispositivo. Es un sesgo impulsado que reduce el ruido de modo común, como el ruido proveniente de la red eléctrica. La señal de polarización se deriva de cualquiera de las entradas de EEG que se pueden elegir en el software.

El dispositivo tiene una entrada digital adicional que se muestra al mismo ritmo que las señales de EEG y se trata como un canal de entrada adicional en el software. Se puede utilizar para conectar sensores externos o para sincronizar múltiples dispositivos MIDI BrainAccess.

Por último, el dispositivo tiene un acelerómetro de 3 ejes integrado. Se puede utilizar, por ejemplo, para registrar cualquier movimiento del cuerpo o la cabeza cuando está conectado al hardware EEG. Los datos del acelerómetro vienen como tres canales de entrada adicionales en el software.

Para poder unir el hardware de BrainAccess MIDI con BrainAccess CAP, se utiliza una cinta de velcro en la parte trasera del mismo, permitiendo grabaciones muy cómodas en cualquier posición.

Además, el kit contiene un adaptador Bluetooth para conectarlo a ordenadores que no lo tengan integrado.

2.7.2 El sensor biométrico EmotiBit

Adicionalmente para este proyecto, contamos con una pulsera EmotiBit que nos proporciona más datos de cada sesión de grabación sobre cómo se encontraba el sujeto a nivel cardiovascular. De esta manera podemos correlacionar los datos generados por el cerebro y el corazón para poder encontrar, posiblemente, patrones en las emociones que sientan los usuarios más precisos.

EmotiBit es un módulo sensor portátil para capturar datos emocionales, fisiológicos y de movimiento de alta calidad. Permite transmitir datos de forma inalámbrica a cualquier plataforma o de la grabación local de datos a la tarjeta microSD integrada. Además, cuenta con software abierto (EmotiBit).

El dispositivo cuenta con diferentes características: Adafruit Feather M0 WiFi o Adafruit Feather ESP32 Huzzah, batería de iones de litio de 400mAh, tarjeta microSD de alta velocidad, lector de tarjetas microSD, cable micro USB para la carga, 3 correas Emoti-stretch de diferentes longitudes para usar EmotiBit en casi cualquier parte del cuerpo, desde la muñeca de un niño hasta la cabeza de un adulto y Spudger de plástico que se utiliza para alternar fácilmente el interruptor de hibernación y el botón EmotiBit.

EmotiBit cuenta con diferentes sensores para su captura de datos, entre ellos se encuentran algunos de los nombrados anteriormente en el apartado de sensores biométricos, como son el PPG, el sensor de temperatura, el magnetómetro, y el de actividad electrodermal.

Además, lleva incorporados dos sensores inerciales como son el acelerómetro, que se encarga de medir la aceleración del movimiento del usuario en varias direcciones, con esto se puede rastrear la actividad física, luego tenemos el giroscopio, que complementa al sensor anterior, midiendo la orientación y los movimientos de rotación, proporcionando datos más precisos sobre la actividad del usuario.

Capítulo 3 - Arquitectura general del sistema

Este capítulo detalla la arquitectura general del sistema desarrollado en el proyecto, proporcionando una visión completa y estructurada de los componentes involucrados y sus interacciones. La comprensión de esta arquitectura es fundamental para entender el flujo desde la captura de datos hasta la predicción de emociones en tiempo real.

3.1 Revisión de los módulos de trabajo

Los objetivos generales de este proyecto son entrenar un modelo de aprendizaje automático capaz de predecir emociones de un usuario a partir de su electroencefalograma y sus datos biométricos y desarrollar una plataforma experimental que use el modelo para obtener las emociones en tiempo real. Estos se dividen en los objetivos específicos A, B, C, D y E. Con ellos en mente, el proyecto divide el trabajo en los siguientes módulos:

4. Montaje y puesta en marcha del electroencefalógrafo y del sensor biométrico
5. Sesiones de grabación de datos y captura de datos
6. Preprocesamiento de los datos y entrenamiento de los modelos de aprendizaje automático
7. Grabación del electroencefalograma y de los datos fisiológicos y predicción de emociones en tiempo real

El Capítulo 4 - describe el proceso inicial de instalación y configuración de los dispositivos BrainAccess MIDI y EmotiBit, utilizados para la captura del electroencefalograma y de los datos fisiológicos respectivamente. Comienza con el montaje del electroencefalógrafo, detallando la colocación de electrodos y la configuración de conexiones Bluetooth. Luego, explica el montaje y la configuración del sensor biométrico EmotiBit, que incluye el montaje de las placas y la conexión Wi-Fi. Se detalla la obtención y lectura de datos tanto del electroencefalógrafo como del sensor biométrico, incluyendo el proceso de grabación de datos de prueba y la conversión de archivos para

facilitar su lectura. Finalmente, se proporciona una visión general de los datos recolectados y sus formatos, destacando la precisión y la estructura de los datos capturados por ambos dispositivos, lo que facilita su posterior análisis y preprocesamiento. Este capítulo corresponde al objetivo A.

En el Capítulo 5 - se describe el proceso completo de las pruebas de captura de datos con sujetos, enfocadas en obtener datos emocionales a través de dispositivos como electroencefalógrafos y sensores biométricos. Se detalla el diseño de las sesiones, donde los sujetos juegan videojuegos mientras se registran sus emociones utilizando una escala de Likert para medir diferentes estados emocionales, centrando el análisis principalmente en el miedo. También se explica la elección de videojuegos de terror para inducir estas emociones, la realización de simulacros previos, y el desarrollo de una aplicación específica para la recolección de datos emocionales. Finalmente, se abordan aspectos logísticos de las sesiones, como la organización de los datos y la preparación de los equipos, además de destacar los ajustes y retos encontrados durante el preprocesamiento de los datos recopilados. Este capítulo corresponde a los objetivos B y C.

En el Capítulo 6 - se describe el proceso de preprocesamiento de datos y el entrenamiento de modelos de aprendizaje automático para predecir emociones en tiempo real utilizando datos de BrainAccess, EmotiBit y EmotionsApp. Se eliminan valores nulos y se aplican técnicas como el filtrado de señales EEG con un filtro de pasa baja Butterworth y la técnica ICA. Para los datos de EmotiBit, se eliminan los valores no numéricos y se ajusta la frecuencia a 250 Hz. Los datos de emociones se reescalan y se estructuran en fragmentos de 10 segundos. Finalmente, se entrenan varios modelos (*random forest*, *SVM*, *KNN*, *MLP*, *decision tree*) con los datos preprocesados, evaluando su rendimiento con métricas como MSE y R^2 . El modelo *random forest* se identifica como el más eficaz y se entrena en profundidad con diferentes configuraciones de datos. Este capítulo corresponde al objetivo D.

En el Capítulo 7 - se describe la implementación de una estructura basada en hilos para la grabación y procesamiento en tiempo real de datos de BrainAccess y EmotiBit, con el fin de predecir emociones. Se detalla cómo el servidor controla la captura, preprocesa los datos, y realiza las predicciones utilizando modelos de aprendizaje automático. Los datos se agrupan en fragmentos de diez segundos y se envían desde el cliente al servidor. Después del preprocesamiento y la predicción, los resultados pueden reenviarse a programas externos como una demo técnica en Unreal Engine 5, donde los valores de las emociones predichas afectan dinámicamente el entorno del juego. Esta infraestructura puede ser aplicada a diversos contextos, incluidos videojuegos y entornos de entrenamiento de alta tensión. Este capítulo corresponde al objetivo E.

3.2 Relaciones entre los módulos del sistema

Para entrenar la red, los sujetos de prueba juegan a un juego utilizando el electroencefalógrafo y los sensores fisiológicos, que recogen los datos EEG y fisiológicos durante la partida, respectivamente. Estos datos se corresponden con la entrada del modelo. Después de jugar, el usuario revisa la grabación del juego y la cámara y utiliza la aplicación de anotación de emociones para cuantificar sus distintas emociones durante la partida. Estos datos se corresponden con la salida del modelo. Al combinar los datos EEG, los datos fisiológicos y las emociones correspondientes a esos datos, según el usuario, se obtiene la tabla de datos en bruto. Esta tabla se preprocesa para entrenar modelos de aprendizaje automático.

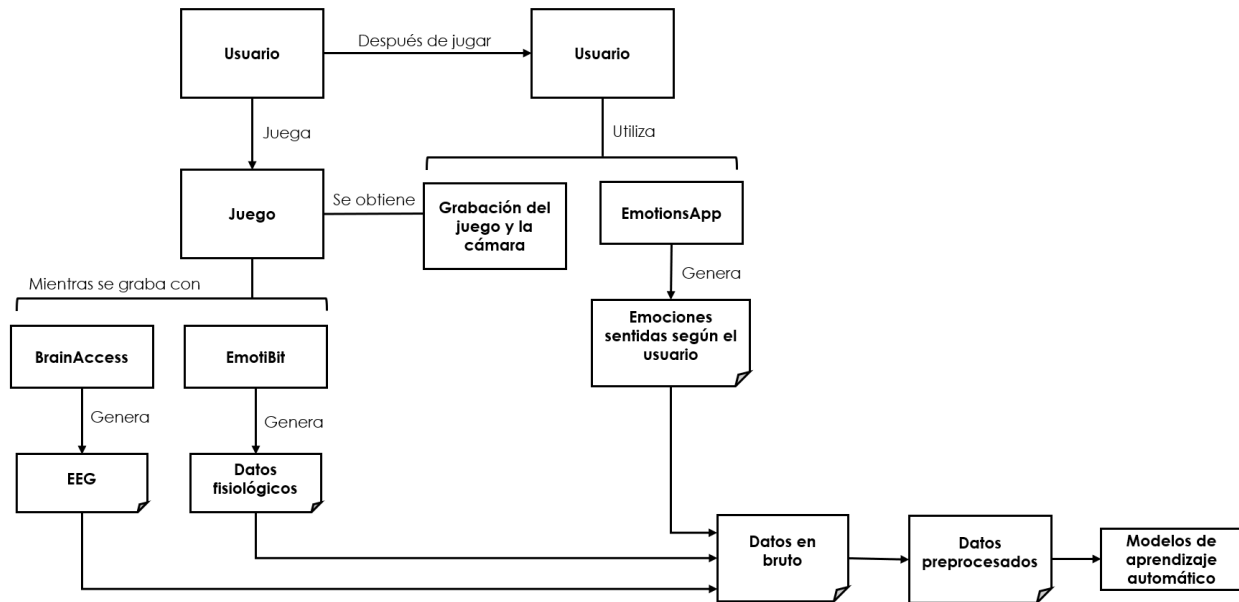


Ilustración 9: Diagrama del proceso de entrenamiento del modelo de aprendizaje automático

Cuando el modelo de aprendizaje automático está entrenado, se puede utilizar por nuestro sistema de predicción de emociones en tiempo real, que está formado por dos *scripts* que tienen una estructura de cliente-servidor. Mientras el usuario juega al juego, el sistema recoge los datos EEG y fisiológicos y cada cierto tiempo, crea una tabla de datos en bruto, con la que se predicen las emociones tras su preprocesado. Las emociones predichas se mandan de vuelta al videojuego para que éste pueda reaccionar como se desee.

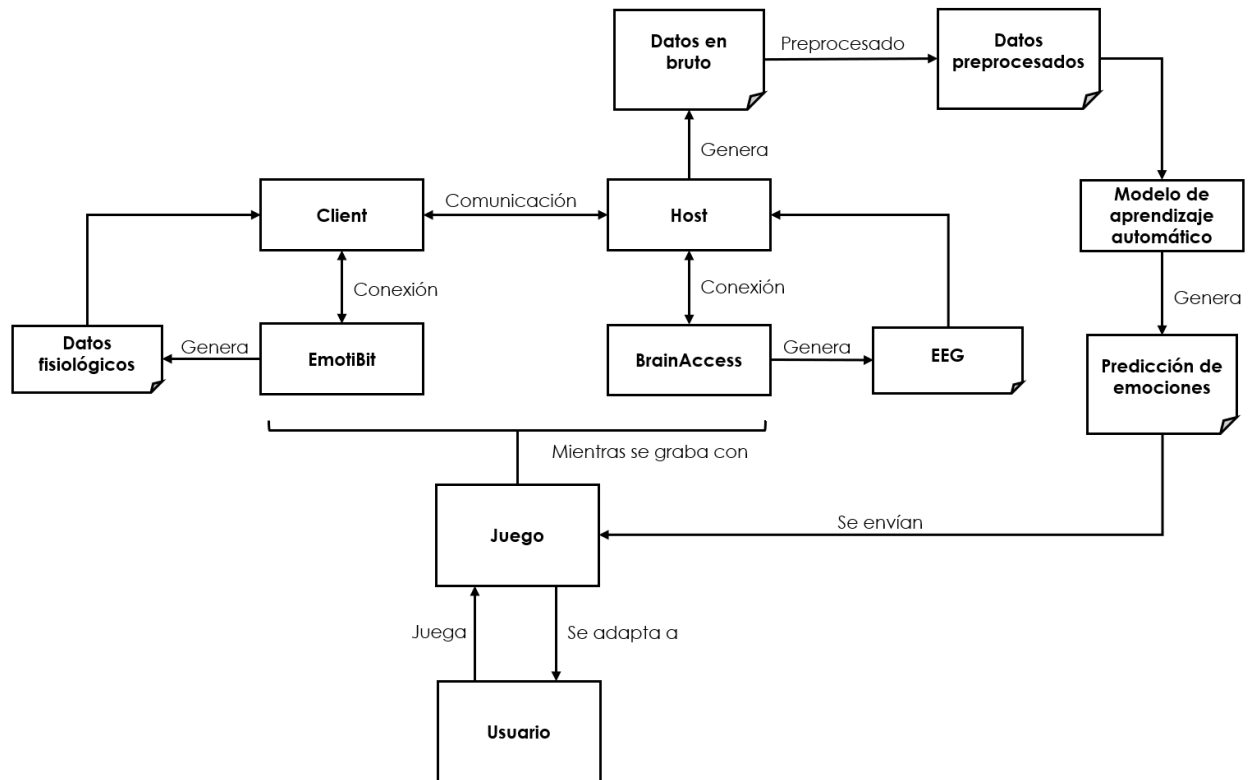


Ilustración 10: Diagrama del proceso de predicción de emociones en tiempo real

Capítulo 4 - Montaje y puesta en marcha del electroencefalógrafo y del sensor biométrico

La primera etapa del proyecto se implementó la captura de datos de ambos dispositivos. Esta incluye la instalación del electroencefalógrafo y del sensor biométrico y la configuración del software necesario para la captura de datos. Además, también incluye una prueba para probar que la captura de datos funcione correctamente.

4.1 Montaje del electroencefalógrafo BrainAccess MIDI y el sensor biométrico EmotiBit

El paquete que contiene el dispositivo BrainAccess MIDI también contiene todos los electrodos y cables necesarios para su montaje. Este dispositivo funciona a través de Bluetooth, así que también cuenta con un adaptador en caso de que el ordenador no posea los respectivos controladores.

El montaje de BrainAccess MIDI consiste en colocar los electrodos en el casco en la posición deseada y conectarlos al puerto correspondiente del dispositivo. El casco cuenta con 32 ranuras que designan las posiciones estandarizadas para un electroencefalógrafo de 32 electrodos. Para configuraciones de 16 electrodos, como es nuestro caso, BrainAccess recomienda la disposición señalada en la Ilustración 11. Sin embargo, al ver la disposición en persona, decidimos mover los electrodos F7 y F8 a T3 y T4, debido a que nos pareció ver demasiada densidad de electrodos en la zona de la frente, y ninguno en el temporal, encima de la oreja.




Ilustración 11: Disposición de electrodos recomendada por BrainAccess para 16 electrodos (Neurotechnology)

Respecto al paquete de EmotiBit, cuenta con dos placas que se unen entre sí con una pila recargable. El montaje es bastante simple y basta con conectar las dos placas entre ellas y dejar la pila en medio de las dos.

Por último, cuenta con una tarjeta SD y un USB adaptable para conectarla tanto al ordenador como al propio dispositivo EmotiBit. Dicha tarjeta sirve como almacenamiento (de las grabaciones) y como configuración.

El EmotiBit funciona a través de Wi-Fi, así que para conectarlo al ordenador necesitas poner las credenciales de la red en un archivo dentro de la SD.

4.2 Obtención y lectura del electroencefalograma

Una vez completado el montaje del electroencefalógrafo y conectado a BrainAccess Board por medio de Bluetooth, el dispositivo está listo para grabar.

Realizamos una grabación de prueba Ilustración 12, para comprobar que todo estaba en orden, que se grababa correctamente y que podríamos visualizar los datos grabados.

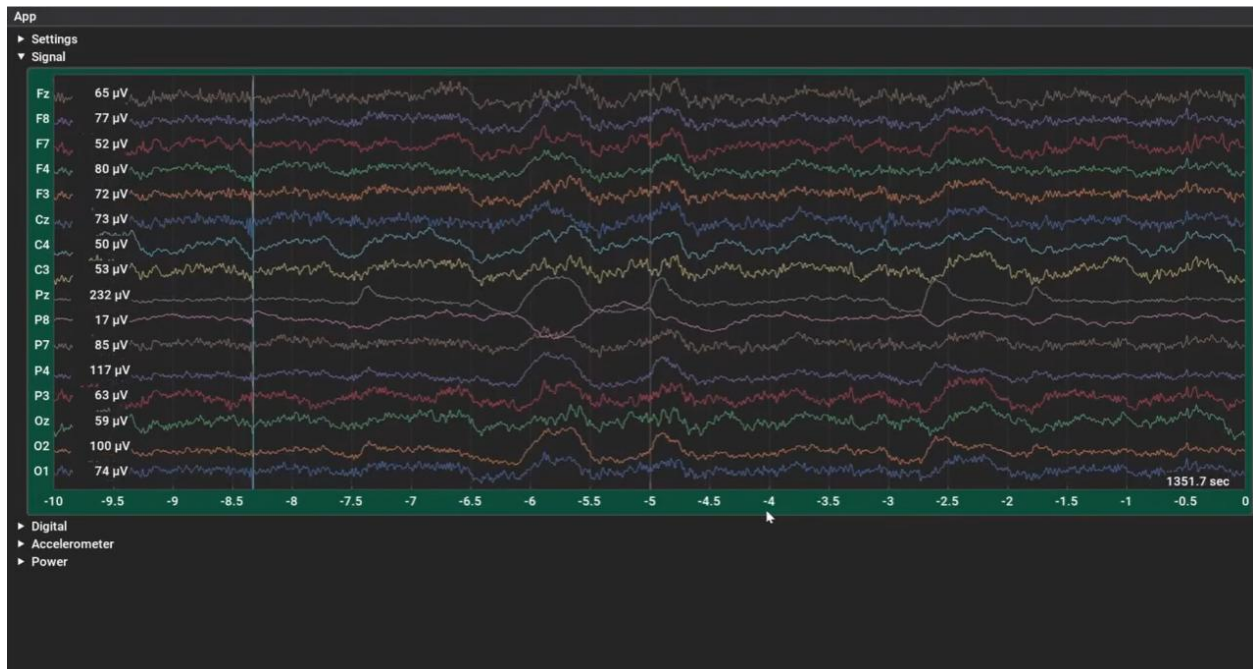


Ilustración 12: Datos de los electrodos de BrainAccess durante una grabación

Después de grabar y guardar correctamente los datos de la prueba, el archivo resultante tiene extensión *db*, así que es necesario convertirlo a otro formato que facilite su lectura. Por ello, decidimos que el formato más legible en este caso era csv (comma-separated value). El propio software de BrainAccess Board permite realizar conversiones de archivo, por ejemplo, permite convertir el archivo *db* a csv.

Los datos recogidos cuentan con las siguientes columnas:

Nombre	Descripción
<i>Time</i>	Tiempo en segundos. Cada valor del electrodo está en unidades de microvoltios y el acelerómetro está en X. El casco graba con una frecuencia de 25hz así que tendremos una fila nueva cada 0.04 segundos.
(Valores de todos los electrodos, cada uno en su propia columna)	Valor leído del electrodo. Independiente a los demás electrodos.
<i>Accel_x</i>	Valor del eje X del acelerómetro del dispositivo.
<i>Accel_y</i>	Valor del eje Y del acelerómetro del dispositivo.
<i>Accel_z</i>	Valor del eje Z del acelerómetro del dispositivo.

Tabla 5 Columnas de los datos recogidos por BrainAccess

Las grabaciones de BrainAccess son regulares y nunca hay ningún tipo de salto temporal, facilitando el preprocesado de los datos.

4.3 Obtención y lectura de los datos fisiológicos

EmotiBit cuenta con una página en GitHub que contiene su documentación y guías de uso (además del código fuente, por si se quieren realizar modificaciones). Para conectar EmotiBit al ordenador, es necesario ambos dispositivos estén conectados a la misma red WI-FI. EmotiBit se conectará a la red WI-FI cuyas credenciales se encuentren dentro de un archivo "config.txt" en la raíz de la tarjeta SD.

Una vez EmotiBit ha sido conectado a la misma red WI-FI que el ordenador que va a realizar la grabación, EmotiBit Oscilloscope (software de EmotiBit, Ilustración 13) comenzará a mostrar los datos grabados en tiempo real. Dicho software permite grabar marcando una casilla en la interfaz además de redirigir los datos a través de un puerto UDP.



Ilustración 13: Datos de los sensores de EmotiBit durante una grabación

Después de grabar y de guardar correctamente los datos de la prueba, el archivo se generará en la raíz de la tarjeta SD. Basta con conectarla al ordenador a través del adaptador para poder leer el archivo, que ya se encuentra en formato csv.

Los datos recogidos cuentan con las siguientes columnas:

Nombre	Descripción
<i>LocalTimestamp</i>	Tiempo en segundos
<i>EmotiBitTimestamp</i>	Tiempo de EmotiBit en milisegundos (el tiempo de EmotiBit se reinicia cada vez que se reinicia el dispositivo).
<i>PacketNumber</i>	Número de paquete del que se extrajo el punto de datos (aumenta secuencialmente).
<i>DataLength</i>	Número de puntos de datos en el paquete.
<i>TypeTag</i>	TypeTag de los datos (véase más abajo).
<i>ProtocolVersion</i>	Reservado para futuras ampliaciones del software (no se usa).
<i>DataReliability</i>	Reservado para futuras ampliaciones del software (no se usa).
<i>Data</i>	Puntos de datos.

Tabla 6: Nombre y descripción de los campos proporcionados por EmotiBit

EmotiBitTimestamp contiene el tiempo en milisegundos. Dicho valor no comienza en 0 (al contrario que en BrainAccess), así que hay que contar con un desplazamiento dado por el primer valor de tiempo recibido (que marca el comienzo de la grabación).

DataLength corresponde con el número de datos que vienen en el paquete, de manera que en un solo instante de tiempo una etiqueta, por ejemplo, AX, puede tener varios valores distintos. Esto puede deberse a que el hardware no es lo suficientemente preciso por lo que realiza varias mediciones de una misma etiqueta en un mismo instante de tiempo.

Dado que la frecuencia de grabación de cada dato es distinta, es decir, la frecuencia de grabación del pulso cardíaco no es la misma que la del acelerómetro, los valores del EmotiBit se guardan en tiempo real a medida que se reciben. Esto ocasiona que la tabla cuente con una columna llamada *TypeTag*, que permite distinguir los identificadores de cada valor recibido. Por ejemplo, en caso del pulso del corazón, la etiqueta será *HR* y en caso de acelerómetro, la etiqueta será *AX* (eje X).

Data contendrá los valores leídos por el dispositivo en ese instante de tiempo. La magnitud del valor depende de su tipo (*TypeTag*).

Capítulo 5 - Sesiones de grabación de datos y captura de datos

Durante este capítulo se presentan todas las fases de las pruebas de capturas de datos con sujetos y el proceso de obtención de dichos datos. Incluye el diseño y el procedimiento de las sesiones de grabación. Durante estas sesiones, los sujetos se ponen el electroencefalógrafo y el sensor biométrico y se llevan a cabo las grabaciones en condiciones controladas, mientras que se graba el videojuego y los datos siendo capturados en tiempo real. Se monitorea constantemente la calidad de la señal y, si algún dispositivo falla, se hacen ajustes en tiempo real para asegurar que los datos sean consistentes y precisos.

5.1 Diseño de las sesiones de grabación de datos

5.1.1 Diseño del esquema de datos orientado a un sistema de aprendizaje automático

En primer lugar, definimos las emociones que se van a medir durante las sesiones de grabación de datos. El modelo de emociones escogido fue el siguiente:

1	2	3	4	5
Muy relajado	Relajado	Neutro	Concentrado	Muy concentrado
Muy frustrado	frustrado	Neutro	Divertido	Muy divertido
Muy anticipado	Anticipado	Neutro	Sorprendido	Muy sorprendido
Muy seguro	Seguro	Neutro	Asustado	Muy asustado
Muy distraído	Distraído	Neutro	Inmerso	Muy inmerso

Tabla 7: Representación de las emociones utilizada en este proyecto

Hemos elegido este rango de emociones porque queríamos grabar datos de emociones fáciles de detectar y asumir. Consideramos que estas cinco emociones (miedo, diversión, sorpresa, concentración e inmersión) cumplen con dichos requisitos. Además, usamos este rango ya que nos permite añadir emociones que pensamos que

son completamente opuestas, es decir, consideramos que si estás relajado no puedes estar concentrado, aumentando así el número de emociones posibles en el modelo de aprendizaje automático.

Por último, utilizamos una escala de Likert (también denominada método de evaluaciones sumarias), un método de valoración bipolar que mide la respuesta positiva o negativa a una declaración (en nuestro caso, a una emoción).

Es importante destacar que, aunque el proyecto haya sido realizado con cinco emociones distintas, nos vamos a centrar principalmente en una de ellas: el miedo. Hemos concluido que el miedo es la emoción más sencilla de detectar de todas, ya que acelera el pulso cardíaco y tiene consecuencias directas en el cuerpo de la persona (temblores, cerrar los ojos, movimientos erráticos...).

5.1.2 Elección del sistema de pruebas

En cuanto a la elección del sistema de pruebas, decidimos utilizar videojuegos porque cuentan con un gran grado de inmersión y permiten reproducir las emociones deseadas fácilmente gracias a esto. Dado que el miedo será la emoción principal que se va a medir en dichas sesiones, se han elegido juegos que permitan recoger datos variados de dicha emoción.

Con esto en mente, buscamos varios títulos del género de terror con el fin de que por lo menos uno de ellos fuera desconocido para el usuario. Si alguno de los juegos propuestos ya había sido visto o jugado por el usuario, la medición no es interesante porque conocería los acontecimientos que ocurren en dicho juego, suprimiendo la mayoría de las emociones que vaya a experimentar alterando los resultados obtenidos.

Los juegos seleccionados fueron: Five Nights at Freddy's 4 (Cawthon, 2015), P.T. (Kojima Productions, 2014) y I'm counting to 6... (EMIKA_GAMES, 2024). Por otro lado, también contamos con juegos que generasen las emociones opuestas, como Minecraft (Mojang Studios, 2011) y Super Mario Bros Wonder (Nintendo, 2023), en caso de haya usuarios que no quieran jugar al género de terror, pero aun así quieran aportar datos para la sesión de grabación. Sin embargo, todos los sujetos se atrevieron a jugar juegos de miedo por lo que no contamos con datos sobre ningún juego que no sea del género.

5.1.3 Simulacro de una sesión de grabación de datos

Antes de realizar las pruebas con usuarios, decidimos realizar simulacros de grabaciones para comprobar que ambos dispositivos grababan sus datos para después ser preprocesados correctamente. Además, durante esta fase se comprobó si efectivamente los juegos elegidos generaban las emociones deseadas.

Durante esta fase la mayoría de las limitaciones deberían haber sido descubiertas, para así evitar problemas en el futuro. Sin embargo, no descubrimos ningún tipo de limitación y decidimos que todo funcionaba correctamente.

5.1.4 Desarrollo de una aplicación para la recogida de emociones

Dado que el objetivo es entrenar un modelo de aprendizaje automático que sea capaz de predecir las emociones del usuario, necesitamos primero una forma de representarlas. La aplicación para la grabación de emociones se ha desarrollado con este propósito.

La aplicación debe permitir la recopilación de datos lo más objetivo posibles mediante la observación de la sesión de grabación. Por ello, necesitamos contar con una manera de registrar de manera rápida y sencilla el nivel de las emociones.

La aplicación fue creada en Unity porque es un entorno con el que estamos familiarizados, permite crear una aplicación multiplataforma, además de acceso a directorios de persistencia con relativa facilidad.



Ilustración 14: Captura de pantalla de la interfaz de EmotionsApp

La aplicación *EmotionsApp* tiene una interfaz dividida en tres secciones, diferenciadas de manera clara por su posición en pantalla. Las distintas zonas son:

ZONA IZQUIERDA:

- Ruta de guardado de la grabación y eventos: Esta opción permite indicar la ruta donde se van a guardar los datos recogidos, además del nombre del archivo.
- Tiempo de *buffer*: Es el tiempo que va a tardar en guardar algún cambio de nivel de emoción. A pesar de tardar "X" segundos en guardar el dato, el instante de tiempo que se guarda es el momento en que el deslizable fue modificado. El tiempo de *buffer* permite que, en caso de que haya varios cambios en un intervalo corto de tiempo, solo se registre un cambio con todo incluido.
- Guardar evento: Aquí es donde se apuntan momentos claves observados para posteriormente preguntar sobre ellos en una entrevista. Se guarda en

el instante de tiempo en el que el probador presiona el botón para guardar el evento.

ZONA CENTRAL:

- Deslizables: Son los niveles modificables de cada emoción. Se corresponden a la tabla de Likert.
- Ver minutos/segundos: Muestra el tiempo que lleva la grabación en minutos o segundos.

ZONA DERECHA:

- Salir: Salir de la aplicación.
- Reiniciar emociones: Botón que permite restablecer los valores de todas las emociones al neutro (3).
- Empezar Grabación: Comienza la grabación para poder empezar a recoger datos. Una vez este botón es pulsado, se convertirá en el botón de "Parar grabación" que permite terminar la grabación de las emociones.

5.1.5 Creación de grupos de sujetos de prueba

Para la creación de grupos de sujetos de prueba, se ha creado un formulario con el fin de que cualquier persona que quisiese pudiese venir a participar en las sesiones de grabación, que se puede consultar desde el Chapter - Apéndice A - .

Además, al terminar la sesión se pide a los sujetos de prueba rellenar un último formulario sobre demografía, disponible en el Chapter - Apéndice B - . Formulario de búsqueda de sujetos de prueba. Utilizamos dicha información para poder clasificar mejor los datos.

5.1.6 Preparación de las sesiones de grabación de datos

Respecto a la disposición de la grabación, contamos con un equipo que graba EEG como EmotiBit, otro equipo se encarga de grabar las emociones con EmotionsApp y el último equipo graba la pantalla del juego. Además, como la aplicación EmotionsApp es multiplataforma, también podemos contar con grabaciones de emociones usando dispositivos móviles.

5.2 Procedimiento de las sesiones de grabación de datos

En cuanto al procedimiento experimental, lo primero es colocar ambos dispositivos (EEG y EmotiBit) en el usuario que jugará al juego. Mientras los dispositivos están siendo colocados, se le leen las instrucciones de la sesión al usuario, que cuentan con algunos consejos para evitar bloqueos dentro del juego.

Después de que los dispositivos se conecten correctamente y EmotionsApp esté lista para grabar, podrá comenzar la grabación.

La sesión dura aproximadamente quince minutos y se realiza en una sala vacía con cristalerías. La sala durante la sesión estará cerrada y nadie podrá entrar durante la duración de este. En el momento de comenzar la grabación, todas las personas menos el sujeto saldrán de la sala y la cerrarán, permitiendo solo observar a través de las cristalerías.

La iluminación es baja para favorecer los sentimientos de miedo y sorpresa del juego. Además, se cuentan con auriculares para ampliar la inmersión durante la sesión.

Con el fin de asegurar la sincronización de las grabaciones de EEG y EmotiBit se comienza a grabar previamente ambos dispositivos. Todas las grabaciones se sincronizarán a través del audio de estas, es decir, basta escuchar la señal de arranque de sesión en el vídeo y restar el desplazamiento de segundos necesario.

Durante la grabación, nos centramos en predecir las emociones del sujeto en base a sus movimientos y a la situación en ese instante de tiempo del juego.

Es importante destacar que siempre tiene que haber una persona vigilando el EEG ya que por alguna razón desconocida (tratado con profundidad en el apartado 5.4) el casco se apaga automáticamente en un instante de tiempo presuntamente aleatorio.

Cuando esto ocurre, se debe parar toda la grabación para reiniciar todos los dispositivos y realizar toda la preparación otra vez. Dado que es el mismo sujeto y es posible que por culpa de reiniciar la sesión se sesguen los datos, se conocerá a las siguientes grabaciones con un identificador *N.º de Toma*.

Una vez cumplido el tiempo de grabación, una persona realiza una cuenta regresiva y se finaliza la grabación de todos los dispositivos a la vez (en la medida de lo posible). Al terminar de grabar, se deben quitar todos los dispositivos sobre el usuario para poder reiniciarlos en caso de realizar otra prueba posteriormente.

Para finalizar, se ingresa a la sala del sujeto para hacer una pequeña entrevista sobre la experiencia y sobre los eventos importantes apuntados con EmotionsApp. Por ejemplo, sobre si efectivamente había sentido miedo en una parte específica del juego.

Ya finalizada la entrevista se le entrega el formulario de demografía mencionado anteriormente para que lo complete, concluyendo así la sesión de grabación.

5.3 Grabación a los sujetos de pruebas

El objetivo de este apartado es conseguir un archivo que cuente con los datos de las tres aplicaciones (EEG, EmotiBit y EmotionsApp) de todos los usuarios.

Lo primero que se hizo fue rellenar la siguiente tabla con información de cada sujeto de las sesiones de captura de datos:

Columna	Descripción
<i>SubjectID</i>	Identificador asignado a cada usuario. Se asignan en orden cronológico desde la realización de la sesión de captura de datos.
<i>Take</i>	Número de toma. Por ejemplo, si se está grabando por primera vez al usuario "A" y hay algo que interrumpa la sesión, como que se apague el casco, entonces la primera grabación tendría el número de toma 1 y si se retoma la sesión la siguiente tendría el número de toma 2.
<i>Age</i>	Edad del sujeto.
<i>Gender</i>	Género del sujeto.
<i>ExperienceWithGames</i>	Nivel de experiencia con videojuegos. El valor será un número del 1 al 5.
<i>GameTime</i>	Rango de tiempo dedicado a los videojuegos a lo largo de una semana. El valor será un número del 1 al 5.
<i>ExperienceWithHorrorGames</i>	Nivel de experiencia con videojuegos del género de terror.
<i>StartTimeEEG</i>	Tiempo en segundos desde la señal de comienzo de la sesión de captura de datos. Todo lo grabado anterior a dicha señal se debe omitir.
<i>StartTimeEmotiBit</i>	Tiempo en segundos desde la señal de comienzo de la sesión. Todo lo grabado anterior a dicha señal se debe omitir.
<i>EndTime</i>	Tiempo en segundos que dura la sesión de captura de datos.

Tabla 8: Columnas de los datos demográficos

Todas las columnas anteriores excepto los *StartTimeEEG*, *StartTimeEmotiBit* y *EndTime* formarán parte de la tabla final de datos en bruto de cada usuario. No obstante, estas columnas siguen teniendo importancia ya que son las que determinarán el comienzo y final de la tabla final de datos en bruto.

`StartTimeEEG` y `StartTimeEmotiBit` se calculan igual; mirando en la grabación de pantalla el tiempo del momento en el que se comienza a grabar el software correspondiente y el momento en el que se da la señal de comienzo de la sesión de captura de datos. Esos dos tiempos se convierten a segundos y se restan, el valor resultante es el tiempo en segundos del comienzo de la grabación, todo lo anterior se omitirá.

`EndTime` se calcula restando el tiempo entre la señal de finalización de la sesión de captura de datos y la señal de comienzo de la sesión de captura de datos en segundos.

El resto de las columnas se completan utilizando la información obtenida en la encuesta de demografía.

Una vez completada la tabla anterior, se deben procesar las tablas obtenidas de todos los demás dispositivos (EEG, EmotiBit y EmotionsApp) para que se puedan unir en una misma tabla. Para ello, se usará Visual Studio Code y un cuaderno de Jupyter cuya finalidad es generar la tabla de datos en bruto de cada usuario.

El notebook contiene tres partes claramente diferenciadas (una para cada dispositivo). A continuación, se explican cada una de las partes con el código más relevante de cada una de ellas.

5.3.1 Organización de los datos brutos de EEG

Respecto al EEG, contamos con un bucle que recorre todas las grabaciones de un sujeto (en caso de que haya varias tomas) y se van añadiendo en el *dataframe* `eeg_combined`. Tras esto, se convierte la columna del tiempo a segundos para poder filtrar las filas en base al `eeg_start_time` calculado previamente. Por último, se requiere que el tiempo inicial sea cero por lo que se resta a todas las filas el valor de `eeg_start_time`.

5.3.2 Organización de los datos brutos de EmotiBit

Al igual que en EEG, se recorren las tomas del usuario y se van añadiendo al *dataframe* `emotibit_dataframe`. Para cada toma se establece el `EmotibitStartTime`

(sacado de la tabla mencionada al comienzo del capítulo), se pasa el tiempo a segundos y se hace un filtro para eliminar todo lo anterior al `EmotibitStartTime` establecido.

Como se ha mencionado en el apartado 4.3, EmotiBit a veces da varios valores para una etiqueta en un mismo instante de tiempo. Debido a que solo podemos tener un valor por columna, hemos optado por hacer una media de todos los valores posibles. Por lo tanto, lo primero que hacemos es dividir `emotibit_dataframe` en grupos divididos por el tiempo a través de la función `GroupBy`. Una vez tenemos todos los valores que se encuentran en el mismo instante temporal, se iteran todas las filas de cada grupo y a cada una de ellas se le hace la media de sus valores.

Por último, se añaden a `final_emotibit_dataframe_data` que es el *dataframe* final. Con esto conseguimos pasar a tener una estructura muy parecida al EEG en la que la primera columna contiene el valor del tiempo, y las demás columnas contienen el valor de cada una de sus etiquetas (en caso de EEG, sus electrodos). Con esta distribución dejamos muchos valores de la mayoría de las columnas como los valores no numéricos, aunque es lo esperado debido a que EmotiBit graba a distintas frecuencias y lo normal es que en un instante de tiempo cualquiera solo conozcas el valor de una determinada etiqueta (o varias).

5.3.3 Organización de los datos brutos de EmotionsApp

Tras todo lo anterior se juntan los *dataframes* `eeg_combined`, `emotibit_combined` y `tableapp_emotions_combined`, se filtran en base al `end_time` calculado y se ordenan las filas por `time`.

Por último, antes de la exportación de los datos en bruto del usuario como `csv` hay que insertar la demografía rellena por el usuario en la encuesta.

Una vez que se completa este proceso para cada usuario, se combinan todas las tablas de datos en bruto individuales en una única tabla para obtener la tabla de datos en bruto completa. A partir de ella, se procede al preprocesamiento de los datos.

5.4 Grabación propia

Durante esta etapa de preprocesamiento, descubrimos que todas las grabaciones de EEG habían sufrido una pérdida de datos significativa pues faltaban segundos de grabación llegando a más de 100 en algunas, lo que provocó un impacto negativo en la calidad de los datos. Esta pérdida de datos era intermitente, es decir, no era una pérdida de solo el final del registro por lo que no se podía hacer una reescala del tiempo.

Al descubrir esto, dejamos a medias el preprocesado e hicimos varias pruebas para investigar el origen del problema. Determinamos que la causa estaba en el hecho de grabar los dispositivos de EEG y EmotiBit en el mismo ordenador. A pesar de que EEG va por Bluetooth y EmotiBit por Wi-Fi suponemos que tienen algún tipo de interferencia y la única solución posible fue grabar cada dispositivo en un ordenador.

Dado que todas las grabaciones eran inservibles había que realizar nuevas sesiones, pero queríamos empezar cuanto antes a entrenar los modelos por lo que para no tener que buscar nuevos sujetos decidimos grabarnos a nosotros mismo.

En estas sesiones, ajustamos un poco el planteamiento de la captura de datos ya que ahora utilizamos un ordenador adicional para grabar los dispositivos. Debido a esto, solo usamos un ordenador para capturar los datos de EmotionsApp porque íbamos a ser nosotros mismos quien nos corrigiéramos. Adicionalmente, durante estas sesiones nos dimos cuenta también de que el voltaje de los electrodos mejoraba significativamente si se apretaba mucho el casco, llegando a ser bastante incómodo, y de que también empeoraba por la presencia de cabello delante de los electrodos Fp1 y Fp2.

5.4.1 Nueva organización de los datos brutos de EmotiBit

Tras hacer las nuevas grabaciones y empezar su preprocesado notamos que había pérdida de datos en las columnas de EmotiBit de las tablas de datos en bruto. Esto se debe a la manera de leer las grabaciones de EmotiBit.

Como se explica en el capítulo anterior, EmotiBit podía dar varios valores para una misma etiqueta, esto hace que haya filas con columnas variables y al usar `read_csv` crea un *dataframe* con el número de columnas que tenga la primera línea, por lo que

el parámetro `on_bad_lines='skip'` hacía que las filas con más columnas que la primera no se añadieran al *dataframe*.

La manera de solucionarlo es hacer un *open* del archivo para poder leer línea a línea e ir añadiéndolas a una lista para posteriormente transformarla en un *dataframe*. Esto hace que el *dataframe* tenga las columnas de la fila con más columnas del csv dejando así filas con columnas sin valores, pero como después se hace la media, se consigue un *dataframe* comprimido con el menor número de columnas posible.

Capítulo 6 - Preprocesamiento de los datos y entrenamiento de los modelos de aprendizaje automático

En este capítulo, el objetivo es generar una nueva tabla de datos preprocesados a partir de la tabla de datos en bruto con la que entrenar varios modelos de aprendizaje. Esta tabla no puede tener valores nulos, por lo que descartamos todas las entradas antes de tener al menos un valor de cada variable de cada toma.

6.1 Preprocesamiento de los datos

El preprocesado busca maximizar la precisión del modelo de aprendizaje automático. Al igual que para generar la tabla de datos en bruto, el preprocesamiento de los datos se hace de manera independiente para cada uno de los tipos de datos. Teniendo en cuenta que la aplicación del modelo es la predicción de emociones en tiempo real, el modelo contará con los datos de BrainAccess y EmotiBit de un fragmento de un tiempo determinado como entrada, y una de las emociones evaluadas como salida. El código del preprocesado se encuentra disponible en nuestro repositorio de GitHub¹.

6.1.1 Preprocesado de los datos de BrainAccess

El preprocesado de BrainAccess se divide a su vez en dos fases: el filtrado de la señal y la aplicación ICA al resultado del filtrado.

Antes de abordar las fases de preprocesamiento de EEG, es importante hacer un breve inciso. Inicialmente, se consideró utilizar MATLAB y EEGLAB para el preprocesamiento, ya que son herramientas que permiten realizar filtrados y aplicar ICA de manera cómoda. Sin embargo, se descartó esta opción porque una parte posterior del TFG involucraba realizar mediciones de EEG y EmotiBit y preprocesarlas en tiempo real, lo que hacía inviable el uso de aplicaciones externas. Por ello, se optó por ejecutar un script de Python creado por nosotros.

¹ <https://github.com/javics2002/EmotionTracker>

6.1.1.1 Filtrado de la señal EEG

Como hemos explicado en apartados anteriores, el filtro de las señales EEG sirve para mejorar la calidad de las mediciones de señales cerebrales registradas mediante encefalografía, en nuestro caso, utilizando BrainAccess.

En nuestro caso, hemos optado por utilizar el filtro de pasa baja Butterworth frente al resto de filtros explicados por un conjunto de razones. Principalmente, nuestro objetivo con el filtrado de los datos recibidos es atenuar las señales, para evitar las interferencias que hayan podido surgir durante la grabación, por ello utilizamos un filtro de pasa baja, porque buscamos atenuar esas frecuencias altas generadas por el ruido e interferencias.

Uno de los principales beneficios del filtro de Butterworth es que proporciona una respuesta de frecuencia más plana en la banda de paso (frecuencias que deja pasar) en comparación con otros tipos de filtros, como los de Chebyshev, que pueden tener oscilaciones o rizado en esa región.

Además, tienen una transición suave entre la banda de paso y la banda de rechazo (frecuencias que atenúa). Esto significa que las frecuencias cercanas al punto de corte del filtro (la frecuencia donde comienza a atenuar las frecuencias) no experimentan un cambio brusco en la amplitud, lo que es importante a la hora de no tener una atenuación brusca en nuestras señales electroencefalográficas, ya que es lo que queremos evitar, para tratar de encontrar un resultado sin ruido aparente.

Además, tiene un diseño muy sencillo y eficaz, y flexible, es decir, es muy sencillo y rápido experimentar con diferentes parámetros para conseguir la opción mejor esperada.

Elegimos una frecuencia de corte baja, dado que las últimas grabaciones experimentales gozaban de unas frecuencias en torno a los 50-100 Hz.

6.1.1.2 Aplicación de la técnica ICA a la señal EEG

Como se ha explicado anteriormente ICA sirve para dividir la señal en componentes, ver cuáles de esos no sirven y eliminarlos.

No obstante, se decidió no eliminar componentes, es decir, solo aplicar *ICA* ya que, a parte de una pérdida inevitable de información, también es un proceso complejo debido a que saber qué componentes corresponden con ruido a menudo requiere de experiencia y conocimiento en el campo de análisis de señales EEG. Sin embargo, el no eliminar componentes no le quita el sentido a aplicar *ICA*, esto se debe a:

1. Descomposición de la señal: La descomposición de la señal en componentes puede ser beneficiosa incluso sin eliminar componentes, ya que aportan una representación más profunda de las señales del cerebro y de las señales no deseadas.
2. Interpretación del modelo de aprendizaje automático: La separación de componentes puede ser útil para la interpretación de los datos y potencialmente puede aumentar la precisión y eficiencia del modelo.
3. Reducción del ruido: Separar diferentes fuentes de señales relacionadas entre sí puede ayudar a disminuir el ruido en los datos, lo que facilita el entrenamiento del modelo para identificar patrones en los datos.

Para comenzar el preprocesado de EEG, primero hay que definir tanto el filtro como *FastICA*. Después, la tabla de los datos en bruto se agrupa según el id del sujeto y el número de toma del sujeto. A continuación, se itera por cada toma de cada usuario para aplicar de forma independiente el filtro e *ICA*. Además, durante este proceso se guarda el valor final de la columna `time` en `eeg_endtimes` para tener la duración de cada grabación que se necesita para escalar *EmotiBit*.

Por último, se añaden nuevas columnas a la tabla final con las medias de activación de cada electrodo.

6.1.2 Preprocesado de los datos de *EmotiBit*

Respecto a *EmotiBit*, el objetivo será eliminar todos los valores no numéricos y, además, convertir todos los datos para que sigan la misma frecuencia que EEG (250hz) y, por último, escalar los datos para favorecer el entrenamiento del modelo de aprendizaje automático:

El primer paso será importar `StandardScaler` de `sklearn.preprocessing`, que se utiliza para estandarizar características eliminando la media y escalando a la varianza unitaria.

Una vez seleccionado el subconjunto de EmotiBit del *dataframe*, omitiremos todos los datos no biométricos o no interesantes para el entrenamiento del modelo de aprendizaje automático, como pueden ser los correspondientes a la etiqueta AK (etiqueta de confirmación), entre otros.

El primer bucle itera sobre cada grupo definido por combinaciones únicas de id del sujeto y su número de toma en el *dataframe* `preprocessed_emotibit`. Además, escala el tiempo en la toma `emotibit_take` en función de los tiempos finales de EEG, con esto conseguimos que ambos tengan la misma frecuencia. Para finalizar el cambio de frecuencia, es necesario rellenar los valores faltantes hacia adelante (`ffill`) y filtrar las entradas para mantener solo los tiempos regulares. Adicionalmente, aquí nos guardamos para cada grabación el tiempo a partir del cual hay valor en todas las columnas de EmotiBit en `valid_start_times`.

Una vez la frecuencia del *dataframe* corresponda a la del EEG y no contenga valores no numéricos, se utiliza `StandardScaler` para estandarizar las columnas biométricas seleccionadas en `emotibit_take`.

Por último, se concatenan todas las tomas procesadas en un solo *dataframe* `preprocessed_emotibit` para su posterior análisis.

6.1.3 Preprocesado de los datos de EmotionsApp

Para preprocesar la grabación de las emociones generada por EmotionsApp se han seguido los siguientes pasos:

1. Reescalar los datos del rango $[1,5]$ al rango $[-1,1]$, ya que los modelos de aprendizaje automático trabajan mejor con valores normalizados en este rango, ayuda a estabilizar y optimizar el proceso de entrenamiento de dichos modelos.

2. Separar los datos en bruto por tomas, de esta manera evitamos un posible fallo al rellenar los valores nulos que puedan ser causados por tomas ajenas.
3. Añadir las entradas de tiempo regular, a una frecuencia de 250 Hz, de manera que el número de filas se ajuste a la captura de datos con mayor frecuencia, EEG.
4. Dado que las entradas de EmotionsApp solo se registran una vez tras un cambio en las emociones, es necesario rellenar todos los valores nulos con el último registro disponible de la grabación.
5. Una vez tenemos los valores rellenados con la última entrada disponible, solo necesitamos las filas que tengan un valor de tiempo regular, es decir, a una frecuencia de 250 Hz, por ello, es necesario eliminar las filas de tiempo irregular.
6. Una vez hemos completado el preprocesamiento, concatenamos todas las tomas para obtener el resultado final.

6.1.4 Generación de la tabla preprocesada

Una vez se tienen las tres partes preprocesadas por separado, se juntan y agrupan por id de sujeto y número de toma. El objetivo ahora es usar los valores guardados anteriormente en `eeg_endtimes` y `valid_start_times` para recortar las tomas.

Tras recortar la grabación de cada usuario se transforman las filas en columnas, el objetivo de esto es conseguir que cada fila represente un fragmento de datos. Definimos fragmento de datos al conjunto de todos los datos recopilados durante un periodo de tiempo del que se pueden predecir emociones, este tiempo viene determinado por la variable `CHUNK_TIME`, en nuestro caso este valor es de diez segundos debido a que el dispositivo de EmotiBit tiene algunos tags como *HR* (heart rate) que no llega hasta pasados aproximadamente ocho segundos desde que se inició la captura de datos.

Por otro lado, la manera de saber las columnas que se necesitan para representar ese fragmento se calcula haciendo una multiplicación entre `CHUNK_TIME` y `SAMPLE_RATE`, que es la frecuencia de muestreo en Hz, dando como resultado

`CHUNK_SIZE`. Sabiendo esta información se procede a eliminar la columna `time` ya que ahora cada columna de la tabla tiene un sufijo “_t” seguido del tiempo. Por ejemplo, si quisiéramos que cada fila representara diez segundos de información el `CHUNK_TIME` sería de diez y la columna del electrodo “P8” de EEG ahora sería “P8_t0.000”, “P8_t0.004” y así sucesivamente hasta llegar hasta 9.996.

6.2 Entrenamiento de los modelos de aprendizaje

Concluido el preprocesamiento de los datos se continua con el entrenamiento de los modelos de aprendizaje para evaluar cual es el que mejor predicción da. Los modelos seleccionados para esta sección han sido *random forest*, *SVM*, *KNN*, *MLP* y *decision tree*. Las librerías correspondientes a estos modelos de `sklearn` han sido: `RandomForestRegressor`, `LinearSVR`, `KNeighborsRegressor`, `MLPRegressor` y `DecisionTreeRegressor`.

Para el entrenamiento lo primero que se hace es dividir la tabla de datos preprocesados en `x`, que son todas las columnas excepto las de emociones, e `y` que son únicamente las columnas de las emociones. A continuación, se itera a través de cada uno de los modelos e internamente cada una de las emociones por lo que cada modelo se entrenará un total de cinco veces.

En el momento de recorrer las emociones, los *dataframes* de `x` e `y[emotion]`, que es la columna de la emoción sobre la que se está iterando, se dividen en `x_train`, `x_test`, `y_train`, `y_test` a través de `train_test_split(X, y[emotion], test_size=0.25, random_state=8)`, esto se hace porque después de entrenar con `x_train` e `y_train` se hace una predicción con `.predict(x_test)` y se utiliza el resultado de esa predicción para calcular el *MSE* con `mean_squared_error(y_test, predictions)` y el R^2 con `r2_score(y_test, predictions)`. El *MSE* indica cuán precisas son las predicciones del modelo en términos de error cuadrático promedio, cuanto más bajo es mejor. Por otro lado, R^2 significa cómo de bien el modelo explica la variabilidad de los datos de salida en un rango de 0 a 1, cuanto más cercano a uno mejor.

Tras esto, se observaron los distintos MSE y R^2 que salieron del entrenamiento de los modelos para cada emoción con el fin elegir el modelo con los mejores resultados. El modelo del que mejores resultados se obtuvieron fue *random forest*.

Por último, el modelo seleccionado se entrenó más en profundidad. Por un lado, se sacaron dos tablas preprocesadas adicionales, cada una con un `CHUNK_TIME` de veinte y treinta segundos respectivamente. Además, para cada tabla de preprocesado se utilizaron dos x distintas en el entrenamiento, la primera era solo de las columnas de EEG y la segunda era solo las columnas de EmotiBit. De manera que ahora se recorren en primer lugar las tablas preprocesadas que se tengan, a continuación, los modelos, que en este caso solo está *random forest* y antes de iterar la emociones se recorren los `hardware` que son EEG y EmotiBit para poder usar distintas x como se ha mencionado antes.

Capítulo 7 - Grabación del electroencefalograma y de los datos fisiológicos y predicción de emociones en tiempo real

En este capítulo se aborda la implementación de una estructura basada en hilos para grabar en tiempo real los datos de los dispositivos BrainAccess y EmotiBit.

Debido a que los dispositivos de BrainAccess y EmotiBit no pueden convivir en el mismo ordenador (explicado en el punto 5.4), se ha diseñado la siguiente estructura con múltiples hilos para grabar estos dispositivos en tiempo real.

Hemos optado por una estructura en la que el servidor sea quién esté en control en todo momento de cuándo se capturan y reenvían los datos. Es decir, será el servidor quién decida que comienza o se detiene la captura de datos.

Debido a que la captura de datos será en tiempo real, hemos decidido que la tasa de actualización será cada diez segundos, aunque es posible cambiarla para cualquier tiempo. Durante la captura de datos en tiempo real, se usarán *dataframes* que cuentan con diez segundos de datos, denominados “trozos” o “fragmentos”.

7.1 Funcionalidad del servidor en la grabación de datos y predicción de emociones en tiempo real

El servidor se encargará de controlar en todo momento cuándo se capturan los datos, además del preprocesamiento y de la predicción del modelo de aprendizaje automático.

Como el cliente se encarga de recibir los mensajes de EmotiBit en tiempo real, será el servidor quién reciba la información de BrainAccess. Para poder recibir la información directamente a nuestro script es necesario importar el SDK de BrainAccess para Python. Una vez contamos con acceso a las funciones de BrainAccess y con un ejemplo sencillo del uso del SDK, se puede capturar la información del dispositivo sin mayor problema.

Debido a que el servidor se encarga de capturar los datos de BrainAccess y de gestionar la parte del cliente, contamos con varios hilos para aprovechar la capacidad de procesamiento del ordenador y así evitar la mayor pérdida de datos posible.

Una vez finalizados los diez segundos, el servidor manda un mensaje al cliente para indicar que finalice la captura de datos de EmotiBit y reenvíe la información obtenida, a la vez que detiene la captura de datos de BrainAccess. Una vez detenidas ambas capturas de datos, se deben convertir los datos en bruto a un formato válido para el preprocesado, en nuestro caso, un *dataframe*. Ambos hilos también se encargan de convertir la información en bruto a un formato válido.

Cuando el servidor cuenta con la información de BrainAccess y EmotiBit dispuesta en *dataframes*, lanza un hilo encargado puramente del preprocesado de ambas variables.

El hilo de preprocesado es asíncrono y se realiza sobre una copia de las variables en el momento de lanzamiento. Es decir, una vez lanzado el hilo, el servidor comienza de nuevo con la captura de datos (mandando el mensaje correspondiente al cliente) para disminuir lo máximo posible el retraso entre la obtención de la información y la respuesta del modelo de aprendizaje automático.

La etapa de preprocesamiento cuenta con la misma estructura (mencionada anteriormente en el *Capítulo 6 -*), es decir, EmotiBit se convertirá a un *dataframe* dispuesto por columnas y las filas estarán dispuestas con la frecuencia usada por BrainAccess (250hz). Una vez el *dataframe* cuente con la frecuencia deseada, se aplica un *StandardScaler* para convertir los valores facilitando la predicción del modelo de aprendizaje automático.

Respecto a BrainAccess, basta con convertir el fichero '.fif' generado por el SDK a un csv para su posterior lectura y conversión a *dataframe*. Además, se aplica un filtro de paso bajo Butterworth para eliminar todos los posibles picos y *FastICA* a todas las columnas. Por último, calculamos la media de activación de cada electrodo para usarse posteriormente en la predicción del modelo de aprendizaje automático.

Después del preprocesamiento, ambas variables cuentan con la misma estructura, permitiendo concatenarlos en el eje de las columnas para contar con los datos de los dispositivos en un rango de diez segundos.

Por último, el hilo de preprocesado importa el modelo de aprendizaje automático elegido (en nuestro caso, *random forest*) y realiza una predicción utilizando el *dataframe* resultante de la concatenación anterior.

7.2 Funcionalidad del cliente en la grabación de datos y predicción de emociones en tiempo real

El cliente se encargará de recibir en tiempo real los mensajes de EmotiBit (que luego reenviará al servidor). Se ha creado un sistema robusto donde, a pesar de que el dispositivo pueda recibir algún valor no numérico o nulo en los sensores, no ocurra ningún fallo y se corrija para la siguiente iteración.

Para recibir los mensajes en tiempo real de EmotiBit es preciso modificar el puerto por el que el software reenvía los datos, en este caso, utilizaremos un puerto *UDP* por red local para conseguir la máxima velocidad en la transmisión de datos. La información sobre los puertos de EmotiBit se encuentra en un archivo *.XML* disponible en los ficheros de la aplicación, donde se puede asignar cualquier número de puerto para que el software reenvíe la información.

Una vez modificado el puerto, utilizamos un script de *Python* que importa la librería *Socket* para poder capturar los mensajes enviados por el software. Como es el servidor quien decide si se capturarán los datos o no, hay que contar con otro *Socket TCP* encargado de la comunicación para evitar que se pierda ningún mensaje.

La justificación de la elección del *protocolo TCP* es debido a que no queremos reenviar los mensajes al servidor en tiempo real (porque volveríamos a tener el mismo problema con el que se contaba originalmente), sino que será el cliente quién procesará los datos recibidos por EmotiBit concatenándolos en una lista para su posterior envío, evitando la pérdida de toda la información almacenada.

Como la frecuencia de la captura de datos de EmotiBit (25hz en la etiqueta más lenta) indica que vamos a tener muchos datos en pocos segundos y el tamaño en bytes de la lista sea considerable, es necesario un `Socket TCP` para asegurarnos de su envío.

Una vez recibido el mensaje por parte del servidor de detener la captura de datos, el cliente serializa la lista con todos los mensajes recibidos por parte de EmotiBit y la envía al servidor.

Después de enviar toda la información, espera a que el servidor vuelva a mandar el mensaje para comenzar de nuevo con la captura de datos.

7.3 Reenvío de datos a un programa externo

Una vez finalizada la predicción, es posible reenviar los resultados a cualquier programa externo con cualquier finalidad. En nuestro caso, reenviamos la información a una demo técnica hecha en Unreal Engine 5.

Nuestra demo técnica consiste en un entorno inspirado en un hospital abandonado con una estética oscura y de terror. En ella se ha implementado el movimiento en primera persona del jugador y el uso de una linterna que se puede recoger desde el suelo.




Ilustración 15: Entorno construido para la demo técnica de predicción de emociones, preparado para inducir miedo

Además, cuenta con un componente que muestra 5 deslizables en la interfaz con las emociones contrapuestas. Para facilitar su lectura al usuario, se han utilizado distintos colores para cada par de emoción, e iconos que simbolizan las emociones de cada extremo. Dicho componente está preparado para reaccionar y mover los deslizables en tiempo real una vez reciba la información de parte del script del servidor.

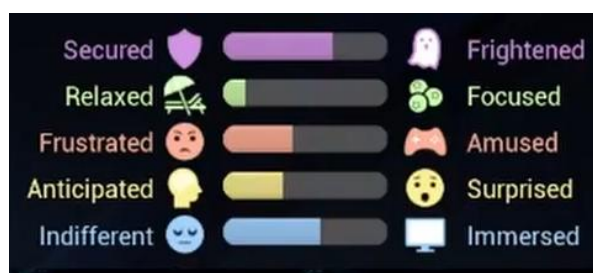


Ilustración 16: marcadores deslizantes que representan los valores de las emociones predichas

Para conseguir recibir los mensajes enviados por nuestro script de Python en Unreal Engine, se ha implementado una clase utilizando la clase `FSocket` de Unreal Engine 5 para poder capturar los mensajes enviados por el servidor. Al ejecutar la demo técnica, este script abre un `socket` en un puerto configurable desde el editor, y queda a la espera de recibir mensajes. Los mensajes recibidos deben tener un formato csv, donde

-1 representa el extremo izquierdo y 1 representa el extremo derecho. Por ejemplo, el mensaje recibido para la Ilustración 16 es “-0.735,-0.15,-0.27,0.335,0.17”. Cabe destacar que la emoción *Fright* ha sido reordenada desde el cuarto lugar al primer lugar debido a que le hemos querido dar más importancia.

De esta manera, conseguimos probar que el juego es capaz de acceder a los valores de las emociones del jugador en tiempo real. En este momento, estos valores sólo se utilizan para cambiar el valor de los marcadores deslizantes, pero, una vez estos datos están disponibles para el juego, podrían ser utilizados para cualquier otra cosa que el diseñador quiera.

Capítulo 8 - Evaluación

Este capítulo trata el método de evaluación y su proceso, donde se cuentan cuáles han sido las grabaciones válidas realizadas, así como el número de usuarios. Además, se muestran los resultados tanto de los entrenamientos de los modelos como de las predicciones del modelo en tiempo.

Finalmente, se presenta un análisis de los resultados obtenidos en función de la hipótesis inicialmente propuesta.

8.1 Método de evaluación

El método de evaluación utilizado en este proyecto se centra en la validación de un modelo de aprendizaje automático que ha sido entrenado para predecir emociones a partir de señales EEG y datos fisiológicos. Para llevar a cabo esta evaluación, se ha diseñado un proceso que incluye la recolección de datos durante sesiones controladas, el preprocesamiento de los datos, el entrenamiento de distintos modelos y la posterior aplicación de datos obtenidos en tiempo real en los modelos entrenados para comprobar su precisión y eficacia.

Un componente crucial de este método es la aplicación de anotación de emociones EmotionsApp. Esta herramienta es fundamental pues proporciona la salida que se va a utilizar para entrenar los modelos de aprendizaje.

8.2 Primer piloto de evaluación

Antes de comenzar con el proceso de evaluación final, hay que hablar del primer proceso de evaluación que hubo pero que tuvo que cancelarse debido a los problemas expuestos en el apartado 5.4, es decir, estos datos no se tuvieron en cuenta para el entrenamiento del modelo. Sin embargo, esas grabaciones se llevaron a cabo y se recogieron datos tanto de los dispositivos como de las encuestas demográficas.

Esta primera selección de la muestra se realizó vía Google Forms, promocionado dentro de la Facultad de Informática de la UCM. La muestra consistió en 18 sujetos que jugaron a juegos de miedo durante aproximadamente 15 minutos cada uno. En las siguientes gráficas se representa la demografía de la muestra.




Ilustración 17: Edad y género de la muestra



Ilustración 18: Experiencia jugando a videojuegos de la muestra




Ilustración 19: Tiempo de juego semanal y familiaridad del sujeto con el género de terror en los videojuegos de la muestra

8.3 Proceso de evaluación

En este proceso, nosotros, los autores, hemos realizado las sesiones para obtener datos en bruto válidos para continuar el trabajo. Contamos con 48 minutos y 11 segundos de datos en bruto, obtenidos al jugar 3 usuarios a 3 juegos diferentes, con el objetivo de suscitar las distintas emociones que queremos entrenar.

Las sesiones de captura de datos han sido 3 y estas se han realizado en la misma sala que se comenta en el apartado 5.2. Las sesiones han sido las siguientes:

1. Hollow Knight (Team Cherry, 2017) - 16 minutos y 13 segundos: Juego de acción que el sujeto conoce completamente y puede jugar en alto nivel de dificultad. Las emociones esperadas con este juego son: concentración, diversión, anticipación, seguridad e inmersión.
2. The Explorer (Cano Salcedo, 2020) - 9 minutos y 38 segundos: Juego de plataformas tranquilo desarrollado por el sujeto. Las emociones esperadas con este juego son: tranquilidad, anticipación, seguridad y distracción.
3. Psalm 5:9-13 (Ranwog, Nortex, alesska, 2024) - 22 minutos y 20 segundos: Juego de miedo desconocido por el sujeto. Las emociones esperadas con este juego son: frustración, sorpresa, miedo e inmersión.

Los datos en bruto se han preprocesado para entrenar distintos modelos de aprendizaje automático con el 75% de ellos. El desempeño de los modelos se evalúa

con el error cuadrático medio (MSE) y el coeficiente de determinación (R^2) al comparar las predicciones del 25% restante de los datos con el valor real. Cada modelo predice una única emoción, por lo que, para predecir las 5 emociones, se entrenan grupos de 5 modelos de aprendizaje automático. Los modelos seleccionados para su evaluación son: *SVM*, *MLP*, *decision tree*, *random forest* y *KNN*.

El modelo que ha dado mejores resultados ha sido *random forest*, por lo que se ha continuado evaluando con él. Durante la etapa de preprocesado, se elige la duración de los fragmentos de tiempo de los que el modelo es capaz de predecir una emoción, por lo que se va a evaluar *random forest* con distintos valores para la duración de los fragmentos. Se han escogido los valores de duración de los fragmentos de 10 segundos, 20 segundos y 30 segundos. También queremos evaluar el desempeño del EEG y los datos biométricos por separado. Esto resulta en la predicción de un grupo de *random forest* por duración de fragmento seleccionada para EEG, para los datos biométricos, y para EEG combinado con los datos biométricos.

Se considera el grupo de modelos *random forest* que combina EEG y los datos biométricos con fragmentos de tiempo de 10 segundos como el grupo estándar con el que se realizaron las sesiones de predicción de emociones en tiempo real. Para medir la precisión de estos modelos se comparan los datos predichos por ellos en tiempo real con los valores de emociones registrados por los propios usuarios tras la sesión de juego, y se calculan el error cuadrático medio y el coeficiente de determinación. De nuevo, estos usuarios hemos sido nosotros mismos, los autores.

Las sesiones de predicción de emociones en tiempo real fueron 4, y tuvieron una duración total de 31 minutos y 51 segundos. De nuevo, el objetivo era abarcar distintas emociones para comprobar la predicción de todos los modelos en ambos extremos.

1. Inscryption (Daniel Mullins Games, 2021) – 4 minutos y 51 segundos: juego de estrategia conocido por el sujeto. Con este juego se esperan valores para concentración, diversión, anticipación, ni seguridad ni miedo, e inmersión.

2. Outlast (Red Barrels, 2013) – 8 minutos y 42 segundos: juego de miedo desconocido por el sujeto. Con este juego se esperan valores para concentración, ni diversión ni frustración, sorpresa, miedo e inmersión.
3. Bubble Cat (Cano Salcedo y otros, 2021) – 8 minutos y 18 segundos: juego de plataformas desarrollado por el sujeto. Con este juego se esperan valores para ni concentración ni relajación, ni diversión ni frustración, anticipación, seguridad y distracción.
4. Stardew Valley (ConcernedApe, 2016) – 10 minutos: juego de gestión odiado por el sujeto. Con este juego se esperan valores de relajación, frustración, ni anticipación ni sorpresa, seguridad y distracción.

8.4 Resultados

En este apartado se recogen los valores de MSE y R^2 con cuatro decimales de precisión para cada modelo entrenado. Además, el grupo estándar de modelos se va a volver a validar prediciendo las emociones de nuevos datos que no son pertenecientes a las sesiones de entrenamiento.

8.4.1 Resultados del entrenamiento de los modelos

Primero se exponen los resultados obtenidos por cada tipo de modelo de aprendizaje automático evaluado: *SVM*, *MLP*, *decision tree*, *random forest* y *KNN*.

SVM con fragmentos de 10 segundos con BrainAccess y EmotiBit					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	1.9790	0.1996	7.8666	3.3033	2.1486
R^2	-3.0811	0.3941	-29.6160	-5.8717	-4.9499

Tabla 9: MSE y R^2 de los modelos SVM con fragmentos de 10 segundos con BrainAccess y EmotiBit

MLP con fragmentos de 10 segundos con BrainAccess y EmotiBit					
Capas usadas (1024,512,256,128,64)					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	0.7005	173665363500.7394	1.1342	1.0500	13482827001.7673
R²	-0.445	-527173909756.1851	-3.4142	-1.1842	-37337059388.5095

Tabla 10: MSE y R² de los modelos MLP con fragmentos de 10 segundos con BrainAccess y EmotiBit

Decision tree con fragmentos de 10 segundos con BrainAccess y EmotiBit					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	0.2951	0.0833	0.0660	0.0729	0.1528
R²	0.3913	0.7470	0.7432	0.8483	0.5769

Tabla 11: MSE y R² de los modelos decision tree con fragmentos de 10 segundos con BrainAccess y EmotiBit

Random forest con fragmentos de 10 segundos con BrainAccess y EmotiBit					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	0.0849	0.0641	0.0436	0.0360	0.1085
R²	0.8249	0.8055	0.8305	0.9252	0.6997

Tabla 12: MSE y R² de los modelos random forest con fragmentos de 10 segundos con BrainAccess y EmotiBit

KNN con fragmentos de 10 segundos con BrainAccess y EmotiBit, donde K = 5					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	0.2401	0.1063	0.0799	0.1782	0.1860
R²	0.5048	0.6775	0.6892	0.6293	0.4850

Tabla 13: MSE y R² de los modelos KNN con fragmentos de 10 segundos con BrainAccess y EmotiBit

En segundo lugar, se exponen los resultados del mejor grupo de modelos, random forest, variando su tamaño de fragmento.

Random forest con fragmentos de 20 segundos con BrainAccess y EmotiBit					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	0.1217	0.1362	0.0718	0.0739	0.2668
R²	0.7782	0.6068	0.7667	0.8442	0.3724

Tabla 14: MSE y R² de los modelos random forest con fragmentos de 20 segundos con BrainAccess y EmotiBit

Random forest con fragmentos de 30 segundos con BrainAccess y EmotiBit					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	0.0869	0.0949	0.1602	0.1031	0.2475
R²	0.7767	0.7360	0.5684	0.8349	0.3829

Tabla 15: MSE y R² de los modelos random forest con fragmentos de 30 segundos con BrainAccess y EmotiBit

Finalmente, se muestran los resultados de random forest al utilizar sólo BrainAccess y sólo EmotiBit, para los 3 tamaños de fragmentos distintos evaluados anteriormente.

Random forest con fragmentos de 10 segundos con BrainAccess					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	0.0810	0.0846	0.0445	0.0371	0.1364
R²	0.8330	0.7431	0.8267	0.9229	0.6223

Tabla 16: MSE y R² de los modelos random forest con fragmentos de 10 segundos con BrainAccess

Random forest con fragmentos de 20 segundos con BrainAccess					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	0.1277	0.1448	0.0711	0.0854	0.2940
R²	0.7671	0.5820	0.7689	0.8199	0.3084

Tabla 17: MSE y R² de los modelos random forest con fragmentos de 20 segundos con BrainAccess

Random forest con fragmentos de 30 segundos con BrainAccess					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	0.0818	0.0786	0.1626	0.1229	0.2799
R²	0.7897	0.7813	0.5618	0.8033	0.3019

Tabla 18: MSE y R² de los modelos random forest con fragmentos de 30 segundos con BrainAccess

Random forest con fragmentos de 10 segundos con EmotiBit					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	0.1103	0.1475	0.0860	0.0716	0.1542
R²	0.7726	0.5523	0.6654	0.8511	0.5729

Tabla 19: MSE y R² de los modelos random forest con fragmentos de 10 segundos con EmotiBit

Random forest con fragmentos de 20 segundos con EmotiBit					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	0.2789	0.2327	0.2031	0.2676	0.3429
R²	0.4914	0.3284	0.3400	0.4359	0.1935

Tabla 20: MSE y R² de los modelos random forest con fragmentos de 20 segundos con EmotiBit

Random forest con fragmentos de 30 segundos con EmotiBit					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	0.1995	0.2612	0.3376	0.2646	0.3150
R²	0.4871	0.2732	0.0902	0.5764	0.2146

Tabla 21: MSE y R² de los modelos random forest con fragmentos de 30 segundos con EmotiBit

8.4.2 Resultados de las predicciones en tiempo real

El grupo estándar, considerado como el de *random forest* con fragmentos de 10 segundos combinando los datos de BrainAccess y EmotiBit ha sido testeado con nuevos datos que no son pertenecientes a las sesiones de entrenamiento. En la siguiente tabla se recogen los valores de *MSE* y *R²* al comparar las emociones predichas por el modelo

en las últimas grabaciones en tiempo real y la tabla de emociones obtenida al usar EmotionsApp por cada sujeto sobre su propia grabación.

Random forest con fragmentos de 10 segundos con BrainAccess y EmotiBit al predecir nuevos datos en tiempo real					
	Focus	Amusement	Surprise	Fright	Immersion
MSE	0.5665	0.4968	1.2127	1.2765	2.7064
R²	0.1023	-1.3988	-0.1440	-0.4153	-1.2875

Tabla 22: MSE y R² de los modelos random forest con fragmentos de 10 segundos con BrainAccess y EmotiBit al predecir datos en tiempo real

8.5 Análisis de los resultados

En este apartado, se analizan los resultados obtenidos en el apartado anterior, utilizando el parámetro estadístico t de Student para comparar los distintos modelos y usando la raíz del error cuadrático medio ($RMSE$) para obtener el error medio que podemos esperar de los modelos en nuestra escala. Para *random forest*, se comparan los resultados obtenidos al variar el tamaño del fragmento y al separar BrainAccess de EmotiBit.

Finalmente se evalúa si los modelos estándar tienen diferencias significativas al predecir las emociones con los datos de validación o con los nuevos datos en tiempo real, y se usa el $RMSE$ para determinar la precisión que se puede esperar de ellos.

Es importante mencionar que la prueba t de Student es un método estadístico utilizado para comparar las medias de dos conjuntos de datos y determinar si las diferencias observadas entre ellos son significativas (Fisher, 1925). Este parámetro estadístico considera la varianza de los resultados en relación con la media y evalúa si las diferencias son atribuibles a la variabilidad natural de los datos o si son suficientemente grandes como para ser consideradas significativas.

8.5.1 Análisis de los resultados del entrenamiento de los modelos

En esta sección, el objetivo es determinar cuál de los modelos evaluados: *random forest*, *decision tree*, *SVM*, *KNN* y *MLP* ofrece un mejor desempeño en la predicción de datos recogidos de ambos dispositivos y con fragmentos de 10 segundos. Para ello, se

va a utilizar el *RMSE* para medir, en nuestra escala de emociones, el error medio que se puede esperar utilizando cada modelo. Un valor de *RMSE* mayor a 0,25 significaría que de media, un valor predicho podría estar completamente equivocado. Un modelo que se pudiera considerar bueno debería tener un valor menor a 0,25 de *RMSE*.

	Focus	Amusement	Surprise	Fright	Immersion	Media
SVM	1.4068	0.4468	2.8047	1.8175	1.4658	1.5883
MLP	0.8370	416731.7644	1.0650	1.0247	116115.5761	106570.0534
Decision tree	0.5432	0.2886	0.2569	0.2700	0.3909	0.3499
Random forest	0.2914	0.2532	0.2088	0.1897	0.3294	0.2545
5NN	0.4900	0.3260	0.2827	0.4221	0.4313	0.3904

Tabla 23: *RMSE* para cada modelo y emoción

En la Tabla 23, se puede observar que ninguno de los modelos presenta una media de *RMSE* menor de 0,25, aunque *random forest* se queda muy cerca. En primer lugar, *random forest* presenta la menor raíz del error cuadrático medio, con un *RMSE* de 0,2545 de media entre todas las emociones. Destacan sobre todo las emociones *Surprise* y *Fright*, que presentan el menor error de todos, y son los únicos que tienen una precisión aceptable, es decir, que el valor más cercano al predicho es realmente el más probable. En segundo lugar, *decision tree* tiene un comportamiento adecuado, sobre todo en *Surprise*, *Fright* y *Amusement*. *KNN* tiene resultados cercanos a *decision tree*. El modelo *SVM* por su parte no es para nada adecuado para la predicción de emociones pues la media de sus *RMSE* supera la unidad, que es la totalidad del rango: 1,5883. Esto quiere decir que cualquier valor que nos dé podría ser completamente erróneo, ya que en nuestro modelo las emociones cambian drásticamente cada media unidad. Por último, tenemos *MLP* el cuál muestra los peores resultados. En las emociones *Focus*, *Surprise* y *Fright* ha superado los *RMSE* de *SVM*, pero en las emociones *Amusement* e *Immersion* presenta una completa falla en el ajuste del modelo.

A continuación, se utiliza la prueba t de Student para comprobar si estos modelos presentan diferencias significativas. Se proporcionan la estadística t y el p-valor entre

cada modelo de cada emoción. La estadística t indica cuánto difieren las medidas entre los dos modelos, y el p-valor indica la probabilidad de obtener los datos observados si la hipótesis nula es cierta.

Estadística t entre 2 modelos distintos para la emoción Focus				
	5NN	Random forest	Decision tree	MLP
SVM	-27.2762	30.5256	-27.2762	-40.6109
MLP	-0.4655	0.6116	-0.4655	
Decision tree	0.0000	0.7497		
Random forest	0.7497			

Tabla 24: Estadística t entre modelos distintos para la emoción Focus

p-valor entre 2 modelos distintos para la emoción Focus				
	5NN	Random forest	Decision tree	MLP
SVM	0.0000	0.0000	0.0000	0.0000
MLP	0.6418	0.5411	0.6418	
Decision tree	1.0000	0.4538		
Random forest	0.4538			

Tabla 25: p-valor entre modelos distintos para la emoción Focus

Estadística t entre 2 modelos distintos para la emoción Amusement				
	5NN	Random forest	Decision tree	MLP
SVM	-17.7560	21.3289	-17.7560	-16.7161
MLP	-16.7160	-16.7160	-16.7160	
Decision tree	0.0000	1.0585		
Random forest	1.0585			

Tabla 26: Estadística t entre modelos distintos para la emoción Amusement

<i>p</i>-valor entre 2 modelos distintos para la emoción Amusement				
	5NN	Random Forest	Decision tree	MLP
SVM	0.0000	0.0000	0.0000	0.0000
MLP	0.0000	0.0000	0.0000	
Decision tree	1.0000	0.2903		
Random forest	0.2903			

Tabla 27: *p*-valor entre modelos distintos para la emoción Amusement

Estadística <i>t</i> entre 2 modelos distintos para la emoción Surprise				
	5NN	Random forest	Decision tree	MLP
SVM	-26.9125	27.6000	-26.9125	-11.5534
MLP	43.2419	50.0937	43.2419	
Decision tree	0.0000	0.4652		
Random forest	0.4652			

Tabla 28: Estadística *t* entre modelos distintos para la emoción Surprise

<i>p</i>-valor entre 2 modelos distintos para la emoción Surprise				
	5NN	Random forest	Decision tree	MLP
SVM	0.0000	0.0000	0.0000	0.0000
MLP	0.0000	0.0000	0.0000	
Decision tree	1.0000	0.6420		
Random forest	0.6420			

Tabla 29: *p*-valor entre modelos distintos para la emoción Surprise

Estadística t entre 2 modelos distintos para la emoción Fright				
	5NN	Random forest	Decision tree	MLP
SVM	-13.1045	12.1025	-13.1045	2.5100
MLP	25.2669	23.0022	25.2669	
Decision tree	0.0000	-0.9709		
Random forest	-0.9709			

Tabla 30: Estadística t entre modelos distintos para la emoción Fright

p-valor entre 2 modelos distintos para la emoción Fright				
	5NN	Random forest	Decision tree	MLP
SVM	0.0000	0.0000	0.0000	0.0123
MLP	0.0000	0.0000	0.0000	
Decision tree	1.0000	0.3320		
Random forest	0.3320			

Tabla 31: p-valor entre modelos distintos para la emoción Fright

Estadística t entre 2 modelos distintos para la emoción Immersion				
	5NN	Random forest	Decision tree	MLP
SVM	-33.8291	32.5557	-33.8291	-36.0942
MLP	-36.0928	-36.0930	-36.0928	
Decision tree	0.0000	0.7497		
Random forest	-8.0132			

Tabla 32: Estadística t entre modelos distintos para la emoción Immersion

<i>p</i>-valor entre 2 modelos distintos para la emoción <i>Immersion</i>				
	<i>5NN</i>	<i>Random forest</i>	<i>Decision tree</i>	<i>MLP</i>
<i>SVM</i>	0.0000	0.0000	0.0000	0.0000
<i>MLP</i>	0.0000	0.0000	0.0000	
<i>Decision tree</i>	1.0000	0.0000		
<i>Random forest</i>	0.0000			

Tabla 33: *p*-valor entre modelos distintos para la emoción *Immersion*

Estos resultados no son lo suficientemente concluyentes para decidir si es preferible usar *decision tree* o *KNN* donde $K = 5$, pues sus *p*-valores para todas las emociones son extremadamente altos. Además, para la emoción *Focus*, no tenemos los suficientes datos para concluir la importancia de si usar *MLP*, *decision tree*, *random forest* o *5NN*, pues sus *p*-valores son muy altos. Para las emociones *Amusement*, *Surprise* y *Fright* tampoco se puede concluir nada sobre las diferencias entre *decision tree*, *random forest* o *5NN*. Las diferencias entre el resto de los modelos son muy significativas, porque presentan *p*-valores muy cercanos a 0.

Tras analizar los resultados de los distintos modelos con fragmentos de 10 segundos de BrainAccess y EmotiBit, se concluye que el modelo *random forest* con BrainAccess y EmotiBit es el más efectivo para *Immersion*, para las demás emociones, no es posible determinarlo con los datos actuales. A continuación, se comparan los resultados de *random forest* con distintos tamaños de los fragmentos, de 10, 20 y 30 segundos respectivamente.




Ilustración 20: RMSE de los modelos random forest según el tamaño de los fragmentos

Los fragmentos de 10 segundos tienden a mostrar un mejor rendimiento en términos de *RMSE* para todas las emociones en comparación con los fragmentos de 20 y 30 segundos a excepción de *Focus*, que muestra una raíz de error cuadrático medio menor con fragmentos de 30 segundos. Utilizando la prueba *t* de Student se comprueban si las diferencias entre tamaños de fragmentos son significativas.

Estadística <i>t</i> entre modelos random forest con BrainAccess y EmotiBit entrenados con distintos tamaños de fragmentos					
	Focus	Amusement	Surprise	Fright	Immersion
10 s comparado con 20 s	-0.5892	-0.7327	0.8871	1.9569	1.3792
20 s comparado con 30 s	-0.6270	1.2493	1.0493	-0.3989	-0.7488
10 s comparado con 30 s	-1.1850	0.5972	1.8823	1.2957	0.6074

Tabla 34: Estadística *t* entre modelos random forest entrenados con distintos tamaños de fragmentos

<i>p-valor entre modelos random forest con BrainAccess y EmotiBit entrenados con distintos tamaños de fragmentos</i>					
	Focus	Amusement	Surprise	Fright	Immersion
10 s comparado con 20 s	0.5560	0.4642	0.3755	0.0510	0.1686
20 s comparado con 30 s	0.5313	0.2128	0.2951	0.1959	0.4548
10 s comparado con 30 s	0.2368	0.5507	0.0606	0.6904	0.5439

Tabla 35: p-valor entre modelos random forest entrenados con distintos tamaños de fragmentos

La prueba t de Student muestra que, pese a que los fragmentos de 10 segundos parecen dar mejores resultados, los resultados no son válidos para concluir ninguna preferencia sobre el tamaño de los fragmentos.

Para finalizar el apartado, se comparan los *RMSE* modelos de *random forest* de fragmentos de 10 segundos al eliminar las columnas de BrainAccess y EmotiBit respectivamente con los modelos estándar.




Ilustración 21: RMSE de los modelos random forest según los dispositivos utilizados

Las raíces de los errores cuadráticos medios son menores al combinar BrainAccess y EmotiBit, a excepción de Focus, cuyo rendimiento es ligeramente mayor utilizando únicamente BrainAccess. Estos resultados indican que, al combinar estos dos dispositivos, se mejora la precisión de los modelos más de lo que cualquiera de ellos por separado puede conseguir. Una vez más se utiliza la prueba t de Student para determinar si estas diferencias son significativas.

Estadística t entre modelos random forest de fragmentos de 10 segundos entrenados con distintos dispositivos					
	Focus	Amuse- ment	Surprise	Fright	Immersion
BrainAccess y EmotiBit comparado con sólo BrainAccess	1.3653	3.9737	0.1680	1.1777	0.9205
BrainAccess y EmotiBit comparado con sólo EmotiBit	-11.2146	1.2493	9.2804	10.7522	4.0200
Sólo BrainAccess comparado con sólo EmotiBit	-13.4599	0.5972	9.2722	10.4094	3.7651

Tabla 36: Estadística t entre modelos random forest entrenados con distintos dispositivos

p-valor entre modelos random forest de fragmentos de 10 segundos entrenados con distintos dispositivos					
	Focus	Amuse- ment	Surprise	Fright	Immer- sion
BrainAccess y EmotiBit comparado con sólo BrainAccess	0.1727	0.0001	0.8667	0.2394	0.3577
BrainAccess y EmotiBit comparado con sólo EmotiBit	0.0000	0.7186	0.0000	0.0000	0.0001
Sólo BrainAccess comparado con sólo EmotiBit	0.0000	0.0001	0.0000	0.0000	0.0002

Tabla 37: p-valor entre modelos random forest entrenados con distintos dispositivos

Para todas las emociones excepto *Amusement*, no se obtienen resultados significativamente diferentes como para asegurar si es mejor grabar con BrainAccess y EmotiBit o sólo con BrainAccess. Para *Amusement*, grabar con BrainAccess y EmotiBit o sólo con EmotiBit tampoco produce diferencias significativas. Para todas las emociones, elegir si grabar sólo con BrainAccess y sólo con EmotiBit produce resultados con diferencias muy significativas.

8.5.2 Análisis de los resultados de las predicciones en tiempo real

Las sesiones en tiempo real han mostrado una raíz del error cuadrático medio mayor al obtenido con los datos de validación, con diferencias de 0,4612, 0,4516, 0,8924, 0,9401 y 1,3157 unidades respectivamente.

Random forest con fragmentos de 10 segundos con BrainAccess y EmotiBit al predecir nuevos datos en tiempo real, es decir, no pertenecientes a los datos de entrenamiento ni a los de validación						
	Focus	Amusement	Surprise	Fright	Immersion	Media
RMSE	0.7526	0.7048	1.1012	1.1298	1.6451	1.0667

Tabla 38: Grupo estándar de modelos al predecir nuevos datos en tiempo real

Estos valores se acercan más a lo que podemos esperar del modelo. Estos errores son demasiado altos como para poder afirmar que ninguna de las emociones se ha predicho correctamente, pues superan el valor límite de 0,25. El *RMSE* medio de todas las emociones es aproximadamente 1, lo que quiere decir, que, en nuestra escala de Likert, con valores de -1 a 1, un valor 0 predicho podría equivaler a cualquiera de los extremos.

Prueba t de Student comparando la predicción del grupo estándar de modelos de los datos de validación y la predicción de los nuevos datos en tiempo real					
	Focus	Amusement	Surprise	Fright	Immersion
Estadística t	0.0393	0.7834	-9.0314	-5.6026	2.7507
p-valor	0.9687	0.4339	0.0000	0.0000	0.0062

Tabla 39: Prueba t de Student comparando las predicciones de los datos de validación y de los nuevos datos en tiempo real

Al comparar las predicciones de los datos de validación y las de los nuevos datos en tiempo real con la prueba *t* de Student, se comprueba que las predicciones hechas en tiempo real para las emociones *Focus* y *Amusement* no tienen diferencias significativas con las predicciones de validación del modelo, mientras que las emociones *Surprise*, *Fright* e *Immersion* presentan diferencias muy significativas.

Esto quiere decir que, con los datos disponibles, no podemos demostrar que las predicciones para *Focus* y *Amusement* al predecir en tiempo real y al usar los datos de validación tengan relación o no. Para las demás emociones podemos demostrar que predicen mucho peor gracias a los bajos *p*-valores y por el momento, son inviables para un comportamiento funcional.

Capítulo 9 - Discusión

En este capítulo se presentan las limitaciones y ventajas del proyecto. Entre las limitaciones se incluyen el uso de hardware de gama media que afecta la calidad de la señal, el retraso introducido por Bluetooth y un volumen de datos insuficiente para el entrenamiento del modelo de aprendizaje automático. Sin embargo, se presentan ventajas como la publicación del proyecto en GitHub (que permite su uso y modificación), datos de ejemplo y modelos ya entrenados para facilitar las pruebas y la robustez de los scripts desarrollados para una captura y preprocesamiento de datos fiable a pesar de los posibles fallos de los dispositivos.

9.1 Limitaciones encontradas durante el proyecto

Una de las limitaciones principales de nuestro trabajo reside en el hardware utilizado. El casco empleado en nuestras sesiones de captura de datos no es de gel, lo que resulta en una señal de los electrodos de menor calidad. Los cascos de gel ofrecen una mejor conductividad y una mayor precisión en la captura de datos electroencefalográficos, a pesar de que son más incómodos. La elección de un casco seco fue principalmente por consideraciones de costo y comodidad en la captura de datos.

Además, el casco utilizado es de gama media. Se puede adquirir un casco con hardware de mayor calidad, mejorando la precisión y fiabilidad de los datos recogidos ya que los cascos de alta gama ofrecen una mejor estabilidad y resolución en la captura de señales EEG.

Otra limitación técnica importante es que el casco no está conectado por cable, sino que utiliza Bluetooth para la transmisión de datos. Esta elección de conectividad introduce un retraso considerable en la recepción de datos, afectando negativamente al análisis en tiempo real y la sincronización con otros dispositivos. La transmisión inalámbrica, a pesar de ser más conveniente y menos restrictiva, no ofrece la misma velocidad y fiabilidad que la conexión por cable.

Debido a que el casco es de baja gama, hemos observado que es necesario ajustarlo extremadamente fuerte para asegurar que los voltajes registrados sean válidos.

Como resultado, los datos de todos los sujetos no pudieron ser utilizados en el entrenamiento del modelo de aprendizaje automático debido a la inconsistencia o la falta de calidad en las lecturas obtenidas. Además, la necesidad de mantener el casco tan apretado ha afectado a la captura de datos disminuyendo la inmersión debido a la falta de confort de los sujetos.

Por otro lado, el modelo de aprendizaje automático con el que trabajamos ha sido entrenado con una cantidad limitada de datos, lo que restringe su capacidad para generalizar y ofrecer predicciones precisas. Con menos de un millón de entradas, el conjunto de datos actual no es suficiente para alcanzar niveles de rendimiento óptimos.

Respecto a EmotiBit, la precisión y fiabilidad de los datos capturados por la pulsera podrían mejorarse significativamente con dispositivos de mayor calidad. Esta limitación impacta directamente en la capacidad de la aplicación para analizar y correlacionar estos datos con las señales EEG de manera efectiva.

Una limitación adicional que hemos identificado es la interferencia entre dispositivos. Creemos que los dispositivos están enviando señales a los mismos puertos, lo que provoca que se pisen entre ellos y generen conflictos en la recepción y procesamiento de datos. Esta colisión de señales complica el análisis y puede resultar en pérdidas de información, además de retrasar significativamente la captura de datos en tiempo real, lo que conlleva a tener que desarrollar la captura de datos en tiempo real en dos ordenadores distintos conectados a través de una red local.

9.2 Ventajas que tiene el proyecto

Una de las principales ventajas de nuestro trabajo es su disponibilidad en GitHub. Esto permite que cualquier persona interesada pueda acceder al código, utilizarlo y modificarlo según sus necesidades.

Nuestro trabajo también incluye un conjunto de datos de ejemplo y modelos ya entrenados. Los usuarios pueden utilizar estos datos para realizar pruebas en sus propios proyectos y evaluar su rendimiento sin necesidad de recopilar sus propios datos desde el inicio.

Nuestros scripts se diseñaron para que, pese a posibles fallos en los dispositivos, la captura de datos y el preprocesamiento estén configurados para funcionar sin interrupciones. Esta robustez garantiza la fiabilidad del sistema y minimiza las pérdidas de datos.

No hemos implementado técnicas de aprendizaje profundo debido a que los métodos actuales ya ofrecen un rendimiento satisfactorio para nuestras necesidades, aunque si se contase con más tiempo, la incorporación de técnicas de aprendizaje profundo son una posibilidad abierta para futuros desarrollos. Tiene el potencial de mejorar la precisión y la capacidad de nuestros modelos al manejar grandes volúmenes de datos y captar patrones más complejos en las señales emocionales.

Aunque en el apartado de limitaciones se habla de que la conectividad por Bluetooth es una limitación, hay que destacar que es una ventaja en cuanto a comodidad de uso para los sujetos de las sesiones de grabaciones de datos pudiendo moverse libremente en caso de que la sesión lo requiera.

Capítulo 10 - Conclusiones y trabajo futuro

Este capítulo presenta las conclusiones nacidas de las hipótesis de este proyecto, y expone posibles líneas que futuros trabajos pueden explorar con la finalidad de completar y mejorar esta investigación.

10.1 Conclusiones

En este trabajo se ha logrado integrar y configurar un electroencefalógrafo y un sensor biométrico, se ha diseñado una representación numérica de los grados de emociones y llevado a cabo sesiones de grabación con ambos dispositivos. Se han entrenado distintos modelos de aprendizaje automático, y se ha seleccionado el más efectivo para la predicción en tiempo real. Por último, se ha diseñado una demo técnica para probar la implementación de envío/recibimiento de datos a un programa externo.

10.1.1 Objetivos específicos

Objetivo A: Comprender el funcionamiento del electroencefalógrafo y el sensor biométrico y estudiar sobre modelos de aprendizaje automático.

El objetivo consiste en tener BrainAccess y EmotiBit operativos, comprendiendo su funcionamiento y sus características, además de estudiar los posibles modelos de aprendizaje automático compatibles con el proyecto.

Este objetivo ha sido cumplido con éxito. Se han adquirido conocimientos sobre ambos dispositivos, incluyendo su montaje y la captura de datos. A la vez, se ha realizado un estudio sobre modelos de aprendizaje automático, evaluando todos los posibles modelos y cuál se podría comportar mejor en este determinado caso.

Objetivo B: Diseñar una representación de los grados de emociones que deseamos predecir.

El objetivo consiste en diseñar la representación cuantitativa de las emociones, facilitando la interpretación y manipulación de sus datos.

El objetivo ha sido completado. Para ello, se ha desarrollado una escala numérica que asigna valores del uno al cinco utilizando la escala de Likert (explicado en el apartado 5.1.1), que hace que los valores en los extremos sean contrarios. La escala permite convertir experiencias emocionales subjetivas en datos cuantitativos, necesarios para la predicción mediante modelos de aprendizaje automático.

Objetivo C: Llevar a cabo sesiones de grabación en las que obtengamos los datos del electroencefalógrafo y el sensor biométrico y las asociemos a las emociones detectadas.

El objetivo consiste en obtener la tabla de datos en bruto de ambos dispositivos, que en el futuro se utilizará para el entrenamiento del modelo de aprendizaje automático.

Se ha completado el objetivo de realizar las sesiones de grabación. Durante estas sesiones, los sujetos se ponen el electroencefalógrafo y el sensor biométrico y se llevan a cabo las grabaciones en condiciones controladas, mientras que se graba el videojuego y se capturan los datos. Además, se monitorea constantemente la calidad de la señal y, si algún dispositivo falla, se hacen ajustes en tiempo real para asegurar que los datos sean consistentes y precisos. Las emociones experimentadas por los sujetos son reportadas por los miembros del grupo usando EmotionsApp (diseñada con la escala de Likert) y luego se realizan correcciones en la fase posterior (entrevista). Siguiendo esta estructura, se han guardado aproximadamente tres millones de entradas de datos de varios sujetos

Sin embargo, por las limitaciones descritas en el apartado 9.1, se han desechado todos los datos recogidos de todos los sujetos, ya que se consideran no válidos (pueden encontrarse en el repositorio en caso de que se necesiten datos de ejemplo, pero no se recomienda concluir ningún tipo de hipótesis u objetivo usando dichos datos).

Al haber desechado todos los datos, hemos capturado y entrenado el modelo de aprendizaje automático con nuestros propios datos para poder realizar los siguientes objetivos. Cabe destacar que, en caso de se obtengan más datos, se podría entrenar un nuevo modelo que tenga mejoras en la precisión de las predicciones y que varíe los resultados obtenidos en nuestro proyecto.

Objetivo D: Entrenar distintos modelos de aprendizaje automático para predecir las emociones dados los datos del electroencefalógrafo y el sensor biométrico.

El objetivo consiste en el entrenamiento de todos los modelos posibles utilizando los datos grabados en las sesiones por los sujetos, así como la obtención el MSE y R^2 de todos los modelos.

Antes de predecir las emociones se necesitan los datos preprocesados para un entrenamiento fiable y preciso. Se han adaptado los datos, escalándolos y filtrándolos para facilitar el entrenamiento del modelo de aprendizaje. Después, se han entrenado distintos modelos de aprendizaje automático para predecir las emociones a partir de los datos preprocesados anteriormente.

Se han evaluado varios modelos de aprendizaje, comparando la precisión y rendimiento entre ellos, incluyendo los algoritmos supervisados de *SVM*, *random forest*, *decision tree*, *KNN* y *MLP*. Cada modelo se entrenó separando los datos de entrenamiento y los datos de prueba. Todos los modelos son capaces de predecir y, por tanto, se da por cumplido el objetivo.

Objetivo E: Aplicar el mejor modelo para predecir las emociones de un jugador en tiempo real.

El objetivo consiste en elegir el mejor modelo para la realización de una demo técnica que cuente con una captura de datos en tiempo real.

Observando los resultados del apartado 8.5.1, se concluye que *random forest* es el modelo que más precisión obtiene al predecir las emociones combinando los datos de BrainAccess y EmotiBit. Además, también se ha concluido que el tamaño de los fragmentos no es una condición significativa a la hora de predecir las emociones.

Para realizar la captura de datos en tiempo real se ha diseñado una estructura cliente-servidor que permite capturar los datos de ambos dispositivos con la menor latencia posible, mientras que se preprocesan los datos y se predice utilizando el modelo escogido.

Según los resultados expuestos en la sección 8.5.2, en las emociones *Focus* y *Amusement* no existe evidencia suficiente para concluir nada dado su elevado valor de p-

valor, sin embargo, para el resto de las emociones las diferencias son muy significativas. Esto puede deberse a la falta de datos, ya que el modelo ha sido entrenado con únicamente 48 minutos y 11 segundos de grabación.

Las predicciones de las emociones son luego utilizadas para ajustar dinámicamente cinco deslizables en un programa externo, permitiendo exportar la información de la predicción a cualquier motor/programa externo. Con la aplicación exitosa del mejor modelo en un entorno de tiempo real, se ha logrado cumplir con el objetivo propuesto.

10.1.2 Objetivos generales

Gracias a los objetivos específicos se han cumplido los siguientes objetivos generales:

1. Entrenar un modelo capaz de predecir las emociones a partir del electroencefalograma y los datos biométricos de un usuario.

El primer objetivo general engloba de los objetivos específicos A-D.

2. Ofrecer un sistema de predicción de datos que una aplicación o un videojuego puedan utilizar para reaccionar al estado anímico del usuario en tiempo real.

El segundo objetivo general consiste en el objetivo específico E.

10.1.3 Hipótesis general

Es posible predecir las emociones del jugador de forma robusta a partir de su electroencefalograma y sus datos biométricos.

La hipótesis expuesta implica, por una parte, una definición de emociones cuantitativa, con la que poder probar la eficacia de la predicción. Por la otra parte, sugiere que, al combinar el electroencefalograma con los datos biométricos, se puede construir un modelo que prediga con precisión las emociones del jugador. La predicción robusta implica que este modelo sería fiable y consistente, capaz de manejar la variabilidad inherente en los datos fisiológicos de diferentes jugadores y en diferentes contextos de juego.

En conclusión, la hipótesis de partida no se puede confirmar. Hemos conseguido un sistema de grabación y predicción de emociones en tiempo real, pero su precisión ha sido muy pobre. Sin embargo, tampoco se puede desmentir, ya que se requieren de más datos que posiblemente puedan mejorar la precisión de los modelos. Por nuestra parte, hemos completado todos los objetivos de la investigación con éxito, hemos demostrado que el funcionamiento del sistema es viable, y su uso queda completamente generalizado para cualquier aplicación, juego, u otro ámbito; y disponible al público mediante el repositorio de GitHub.

10.2 Líneas de trabajo futuro

Se podría evaluar si la demografía de los sujetos influye en los datos capturados y en la precisión de los modelos. Si influye, se podría valorar el desarrollo/implementación de modelos específicos para cada grupo de usuarios.

Otro aspecto para el trabajo futuro sería contar con un conjunto de datos mucho más amplio para el entrenamiento de los modelos de aprendizaje automático. Dichos datos aumentarían la precisión de las predicciones y la generalización del modelo.

Se podría probar un casco seco de mayor gama y con mayor número de canales. Además, se debería comparar la precisión de un casco de gel frente a un casco seco (que es el usado en esta investigación). Los cascos de gel, aunque más incómodos, suelen proporcionar una mejor calidad de señal debido a su superior conductividad. Se pueden hacer pruebas comparativas entre los datos obtenidos con cascos secos y de gel para ver si existe una mejora en la precisión de los modelos, y, si existe, ver si esa mejora de precisión justifica el uso del casco de gel.

Otra línea de trabajo a futuro es la implementación de modelos de aprendizaje profundo. Aunque es posible que los modelos actuales ofrezcan buenos resultados si se incrementa el número de datos de entrenamiento, el aprendizaje profundo también tiene el potencial para ofrecer resultados competitivos en la precisión de las predicciones. Se podrían comparar modelos con arquitecturas de redes neuronales profundas frente a modelos de aprendizaje automático para ver si existe alguna diferencia de rendimiento entre ellos.

Por último, se comentan algunos cambios que se podrían aplicar a un juego dependiendo de las emociones captadas del jugador a través de nuestro sistema:

- El juego podría encender o subir la intensidad de las luces si detecta que el usuario tiene demasiado miedo. De forma contraria, el juego podría subir la intensidad de los sustos y la frecuencia de los ruidos si este detecta que el jugador se siente seguro.
- Se podría disminuir la dificultad de un enemigo si se detecta que este produce frustración en el jugador para disminuir la posibilidad de abandono.
- El juego podría cambiar su funcionamiento para sorprender a usuarios más anticipados, que crean que ya conocen el comportamiento del mismo.
- La música del juego se podría adaptar al nivel de relajación y concentración del usuario.
- Un juego podría llamar la atención de un jugador distraído mediante la activación de líneas de diálogo especiales o mediante el aumento de experiencia recibida que te permita avanzar más rápidamente.

Como el script del servidor implementa el reenvío de la información predicha por el modelo, se puede implementar la capacidad de recibirla en cualquier programa externo compatible con el envío/recibimiento por sockets, independientemente del lenguaje de programación utilizado. Esto permite que otro tipo de programas aparte de los videojuegos puedan utilizar este sistema con otro tipo de finalidades no lúdicas. Algunos usos serios a los que les podría ser útil la predicción de emociones en tiempo real son:

- Entrenamiento de bomberos, médicos, pilotos y demás profesionales cuya formación sea costosa o peligrosa en entornos seguros en realidad virtual que simulen situaciones de alto estrés o peligro.
- Monitorización de pacientes durante sesiones terapéuticas, especialmente para terapias de exposición o para el tratamiento de trastornos como la ansiedad y el estrés postraumático.

Chapter - Conclusions and future work

This chapter presents the conclusions drawn from the hypotheses of this project and sets out possible avenues for future work to explore in order to complete and improve this research.

Conclusions

In this work, an electroencephalograph and a biometric sensor have been integrated and configured, a numerical representation of the degrees of emotions has been designed and recording sessions have been carried out with both devices. Different machine learning models have been trained, and the most effective one has been selected for real-time prediction. Finally, a technical demo has been designed to test the implementation of sending/receiving data to an external program.

Specific Objectives

Objective A: To understand the functioning of the electroencephalograph and the biometric sensor and to study about machine learning models.

The objective is to have BrainAccess and EmotiBit operational, understanding their operation and characteristics, as well as studying possible machine learning models compatible with the project.

This objective has been successfully achieved. Knowledge has been acquired about both devices, including their assembly and data capture. At the same time, a study on machine learning models has been carried out, evaluating all the possible models and which one could behave better in this particular case.

Objective B: To design a representation of the degrees of emotions we wish to predict.

The objective is to design the quantitative representation of emotions, facilitating the interpretation and manipulation of your data.

The objective has been completed. For this purpose, a numerical scale has been developed that assigns values from one to five using the Likert scale (explained in section 5.1.1), which makes the values at the extremes opposite. The scale makes it possible to convert subjective emotional experiences into quantitative data, necessary for prediction using machine learning models.

Objective C: To carry out recording sessions in which we obtain the data from the electroencephalograph and the biometric sensor and associate them to the detected emotions.

The objective is to obtain the raw data table from both devices, which in the future will be used for training the machine learning model.

The objective of performing the recording sessions has been completed. During these sessions, the subjects put on the electroencephalograph and the biometric sensor and the recordings are carried out under controlled conditions, while the video game is recorded and the data are captured. In addition, the quality of the signal is constantly monitored and, if any device fails, adjustments are made in real time to ensure that the data are consistent and accurate. The emotions experienced by the subjects are reported by the group members using EmotionsApp (designed with the Likert scale) and then corrections are made in the subsequent phase (interview). Following this structure, approximately three million data entries from various subjects have been stored.

However, due to the limitations described in section 9.1, all data collected from all subjects have been discarded, as they are considered invalid (they can be found in the repository in case example data are needed, but it is not recommended to conclude any kind of hypothesis or objective using such data).

Having discarded all the data, we have captured and trained the machine learning model with our own data in order to realize the following objectives. It should be noted that, in case more data is obtained, a new model could be trained that has improvements in prediction accuracy and varies the results obtained in our project.

Objective D: Train different machine learning models to predict emotions given electroencephalograph and biometric sensor data.

The objective consists in training all possible models using the data recorded in the sessions by the subjects, as well as obtaining the MSE and R^2 of all models.

Before predicting emotions, the preprocessed data are needed for reliable and accurate training. The data have been adapted, scaled and filtered to facilitate the training of the learning model. Then, different machine learning models have been trained to predict emotions from the previously preprocessed data.

Several learning models have been evaluated, comparing the accuracy and performance among them, including supervised *SVM*, *random forest*, *decision tree*, *KNN* and *MLP* algorithms. Each model was trained by separating training data and test data. All models are able to predict and therefore the objective is considered to be met.

Objective E: To apply the best model to predict the emotions of a player in real time.

The objective is to choose the best model for the realization of a technical demo with real-time data capture.

Looking at the results of section 8.4.1, it is concluded that *random forest* is the model that obtains the best accuracy in predicting emotions by combining BrainAccess and EmotiBit data. In addition, it is also concluded that fragment size is not a significant condition when predicting emotions.

To perform real-time data capture, a client-server framework has been designed to capture data from both devices with the lowest possible latency, while preprocessing the data and predicting using the chosen model.

According to the results presented in section 8.5.2, for the emotions Focus and Amusement there is not enough evidence to conclude anything given their high p-value, however, for the rest of the emotions the differences are very significant. This may be due to the lack of data, since the model has been trained with only 48 minutes and 11 seconds of recording.

The emotion predictions are then used to dynamically adjust five sliders in an external program, allowing the prediction information to be exported to any external engine/program. With the successful application of the best model in a real-time environment, the proposed objective has been achieved.

General Objectives

Thanks to the specific objectives, the following general objectives have been met:

1. To train a model capable of predicting emotions from electroencephalogram and biometric data of a user.

The first general objective encompasses the specific objectives A-D.

2. To provide a data prediction system that an application or a video game can use to react to the user's mood in real time.

The second general objective consists of the specific objective E.

General Hypothesis

It is possible to predict the player's emotions in a robust way from his electroencephalogram and biometric data.

The stated hypothesis implies, on the one hand, a quantitative definition of emotions, with which to test the effectiveness of the prediction. On the other hand, it suggests that, by combining EEG and biometric data, a model can be constructed that accurately predicts player emotions. Robust prediction implies that this model would be reliable and consistent, capable of handling the inherent variability in the physiological data of different players and in different game contexts.

In conclusion, the starting hypothesis cannot be confirmed. We have achieved a real-time emotion recording and prediction system, but its accuracy has been very poor. However, it cannot be disproved either, as more data are required that could possibly improve the accuracy of the models. For our part, we have successfully completed all the research objectives, we have demonstrated that the operation of the system is viable, and its use is completely generalized for any application, game, or other field; and available to the public through the GitHub repository.

Future Work

It could be evaluated whether subject demographics influence the data captured and the accuracy of the models. If it does influence, the development/implementation of specific models for each user group could be assessed.

Another aspect for future work would be to have a much larger data set for training machine learning models. Such data would increase prediction accuracy and model generalization.

A higher range dry hull with a larger number of channels could be tested. In addition, the accuracy of a gel helmet versus a dry helmet (which is the one used in this research) should be compared. Gel helmets, although more uncomfortable, usually provide better signal quality due to their superior conductivity. Comparative tests can be done between the data obtained with dry and gel helmets to see if there is an improvement in the accuracy of the models, and, if there is, to see if that improved accuracy justifies the use of the gel helmet.

Another line of future work is the implementation of deep learning models. While it is possible that current models may perform well if the amount of training data is increased, deep learning also has the potential to provide competitive results in prediction accuracy. Models with deep neural network architectures could be compared against machine learning models to see if there is any performance difference between them.

Finally, some changes that could be applied to a game depending on the emotions captured from the player through our system are discussed:

- The game could turn on or turn up the intensity of the lights if it detects that the user is too scared. Conversely, the game could increase the intensity of scares and the frequency of noises if it detects that the player feels safe.
- The difficulty of an enemy could be lowered if it detects that the enemy is frustrating the player in order to reduce the possibility of fanfare.
- The game could change its operation to surprise early adopters who think they already know the game's behavior.

- The game's music could be adapted to the user's level of relaxation and concentration.
- A game could attract the attention of a distracted player by activating special lines of dialog or by increasing the amount of experience received to allow you to advance more quickly.

Since the server script implements the forwarding of the information predicted by the model, the ability to receive it can be implemented in any external program that supports sending/receiving over sockets, regardless of the programming language used. This allows programs other than video games to use this system for other non-game purposes. Some serious uses for which real-time emotion prediction could be useful are:

- Training firefighters, doctors, pilots and other professionals whose training is costly or dangerous in safe environments in virtual reality that simulate high-stress or dangerous situations.
- Monitoring of patients during therapeutic sessions, especially for exposure therapies or for the treatment of disorders such as anxiety and post-traumatic stress.

Capítulo 11 - Contribución

11.1 Rodrigo Cabello Hernández

Rodrigo ha llevado a cabo un extenso estudio bibliográfico sobre el cerebro, la electroencefalografía, los sensores biométricos, las emociones, el filtrado en señales, los modelos de aprendizaje automático y redes neuronales, con el objetivo de transmitir los conocimientos necesarios para la comprensión de gran parte del trabajo al resto del equipo, para proceder con la implementación abarcando todas las posibles soluciones para llevarlo a cabo.

A comienzos de la investigación, Rodrigo se encargó de estudiar e investigar sobre los filtrados y preprocesados de una señal electroencefalográfica, utilizando la herramienta de MATLAB, en ella, conseguimos plasmar por primera vez gráficas sobre las grabaciones de prueba, y la comparación tras aplicarles filtros e ICA, sin embargo, esto no nos daba la posibilidad de llevar a cabo el trabajo en tiempo real, pero si para comprender como podría ser el estado de una señal aplicando filtros.

El rol principal de Rodrigo fue preparar las grabaciones de la aplicación Emotion-sApp, para su posterior uso en el preprocesado de los datos capturados. Aunque no fue su rol principal, realizó alguna entrevista y se encargó de comprobar que ambas tecnologías funcionasen correctamente, esto lo realizamos todos los participantes en alguna ocasión. Con respecto a la misma, se encargó de preparar los guiones de los juegos previstos para las sesiones, de manera que, si un sujeto quedaba atascado en cierta parte del juego, pudiesen ayudarlo a continuar la experiencia de juego sin demora ni intervención humana.

Tras ellas, se encargó de la transcripción de algunas entrevistas para la corrección de las emociones recaudadas por los investigadores durante cada sesión, sin embargo, no era su rol principal y no se terminó de completar debido al fallo de la pérdida de datos al grabar simultáneamente ambas tecnologías en un mismo ordenador, nombrado anteriormente en la discusión.

Durante el primer periodo de grabaciones, Rodrigo se encargó de generar un script de Python, cuyo funcionamiento consiste en sincronizar las grabaciones del electroencefalógrafo, y del sensor biométrico, dados unos tiempos sacados del audio de las propias tomas, donde se reflejaba el margen de tiempo entre el inicio de ambas grabaciones, dado que al filmar en el mismo ordenador no se podía iniciar ambos de manera simultánea. Además, generó un script cuya función es mezclar ambas tablas de datos.

Durante el preprocesamiento, él fue el encargado de estudiar y generar un script de Python con diferentes filtros, para comprobar cual daba mejor resultado en nuestros datos, para su posterior agregación al preprocesado.

También programó los scripts encargados de agregar los datos corregidos tras las entrevistas a la tabla global de datos, además de los scripts encargados de ajustar estos valores para su posterior comparación y análisis de los resultados.

Participó en la programación del movimiento de las sliders en la demo técnica de Unreal Engine una vez llegados los mensajes en tiempo real.

Al final del proceso, corrigió un fallo en el script de host del tiempo real, que no permitía recibir más de 3 o 4 mensajes del cliente, y, dado un número específico de tiempo de grabación de cada mensaje. Gracias a esto, los mensajes en tiempo real son enviados correctamente entre cliente y host, pudiendo variar la duración de grabación de cada mensaje sin fallos, recibiendo mensajes hasta que alguno de los dos decida interrumpir.

Tras esto, programó en este mismo script la sincronización de los hilos de preprocesamiento y captura de datos, de manera que no hace falta esperar a terminar el preprocesamiento del mensaje para iniciar la grabación del siguiente. Con esto, se consiguió el resultado esperado en el tiempo real, donde los datos están en continua grabación, a la vez que los mensajes se procesan, se predicen con el modelo de aprendizaje, y se transmiten a la demo de Unreal Engine. Una vez completada esta tarea, se encargó del rol de cliente para hacer simulacros comprobando que todo el proceso funcionase correctamente, para las posteriores pruebas finales.

Al igual que el resto de los miembros, participó en el proceso de comprobación de la fiabilidad del modelo en la sesión de predicciones en tiempo real.

11.2 Javier Cano Salcedo

Javier es el miembro que más experiencia tiene con los proyectos de investigación, por lo que ha sido el que inicialmente, estructuró este documento y estableció las hipótesis de partida y los objetivos de este proyecto.

Javier ha sido el encargado del calendario. Ha planificado el desarrollo del proyecto asignando los objetivos principales a ciertos meses del curso, y semana a semana ha establecido las subtarefas a completar. Ha llevado registro de todas las reuniones realizadas junto con una breve descripción de los avances realizados, que han ayudado a no olvidar ningún detalle del proceso y han permitido que este proyecto pueda completarse a tiempo.

Él ha realizado un extenso estudio bibliográfico para investigar sobre los electroencefalogramas, con el objetivo de comprender su naturaleza desde cero y plasmarla correctamente en este documento.

Javier ha diseñado la representación de las emociones, escogiendo qué emociones eran interesantes y viables de predecir, así como sus valores. La representación escogida supone que las emociones emparejadas no pueden coexistir.

Él comprobó la viabilidad del proyecto inicialmente con datos de prueba, para asegurar que un modelo de aprendizaje automático podía ser entrenado suponiendo que tuviésemos los datos que esperábamos obtener tras la sesión de captura de datos.

La puesta en marcha de cada grabación de juego la realizó de forma conjunta con los demás miembros del grupo, repartiéndonos los roles de grabador de BrainAccess, grabador de EmotiBit, grabador de EmotionsApp; y al repetir las sesiones de capturas de datos, también el de jugador. Dependiendo de la necesidad, estos roles pueden asignarse a varios miembros, o un mismo miembro puede tener 2 roles.

Javier ha elaborado el formulario de búsqueda de participantes, y se ha encargado de planificar cada una de las sesiones de grabación poniéndose en contacto con ellos. También ha elaborado el formulario de la demografía de los participantes, recabando información relevante de su grupo demográfico.

Él ha programado un script para concatenar todas las grabaciones en bruto y así generar la tabla final de datos en bruto.

Javier ha programado el preprocesamiento de los datos. Ha separado la tabla de datos en bruto en BrainAccess, EmotiBit y EmotionsApp. Ha programado el preprocesamiento de EmotionsApp y ha corregido el preprocesamiento final de BrainAccess y EmotiBit. Después, ha juntado las 3 partes para generar la tabla preprocesada final, reestructurando la forma de los datos para encajar con el modelo de aprendizaje.

Realizó con la ayuda de los demás miembros una sesión de captura de datos para comprobar la sincronización entre los relojes internos de BrainAccess y EmotiBit. Tras varias pruebas, descubrimos que estos dispositivos no pueden convivir en el mismo ordenador durante una grabación.

Él ha sido quien ha utilizado Unreal Engine para desarrollar la demo técnica de predicción de emociones en tiempo real. Ha gestionado el proyecto en el repositorio, que es extremadamente grande y requiere de cierta configuración; ha utilizado sus assets del Marketplace para crear un entorno de pruebas; ha programado una linterna interactuable para dar un ambiente tenebroso; ha configurado una solución de C++ para el proyecto, que requiere de pasos extra para su compilación y correcto funcionamiento de este; ha diseñado e implementado el HUD en el que se muestran los controles deslizantes para la representación de cada emoción; y ha programado el script que recibe los datos mandados por el programa de predicción de emociones y actualiza sus valores en los controles deslizantes del HUD.

La comprobación de la fiabilidad del modelo en las sesiones de predicción de emociones en tiempo real la realizó junto a los demás miembros del grupo.

Javier ha editado los vídeos que utilizarán en la presentación, sincronizando las grabaciones del juego, de la cámara, del electroencefalograma, de los datos biométricos y la predicción de emociones en un único vídeo que muestre la totalidad de la sesión de captura de datos.

Él ha programado el script que transforma los datos predichos por el modelo de la escala $[-1, 1]$ a la escala $[1, 5]$, para compararlos con los valores definidos por el usuario.

Finalmente, ha sido el encargado de realizar el análisis de los resultados, calculando las raíces de los errores cuadráticos medios y calculando los valores de la estadística *t* de Student y del *p*-valor para cada par de modelos que se deseaban comparar.

11.3 Diego Rol Sánchez

Diego se ha encargado de que los dispositivos de EEG y EmotiBit realizaran la toma de datos durante las sesiones de capturas de datos. También gestionó esas grabaciones convirtiéndolas al formato *csv*, organizándolas, en sus respectivas carpetas y compartiéndolas con el resto del grupo. Además, relacionado con las grabaciones ha realizado la mayoría de las transcripciones de las entrevistas realizadas a los usuarios al final de las sesiones de captura de datos, las cuales servían para corregir lo captado por EmotionsApp y conseguir la mejor salida para el entrenamiento del modelo.

Al principio del proyecto Diego investigó la limpieza y representación de señales de EEG a través del plugin *eeglab* de *MATLAB*, descubriendo que este programa ya cuenta con un filtrado de señales además de poder aplicar el algoritmo *ICA*. También, descubrió un plugin de *eeglab* llamado *ICLabel* el cuál permitía tras aplicar *ICA* ver en cada componente qué porcentaje de la actividad registrada corresponde con actividad cerebral, ocular, muscular, entre otras, estimando así qué componente podría ser considerado como no deseado. No obstante, se tuvo que dejar de lado ya que *MATLAB* no servía para la parte del proyecto relacionada con el tiempo real, fue aquí cuando se decidió usar Python en su lugar.

Durante la generación de la tabla de datos en bruto de cada usuario, corrigió un problema por el cual EmotiBit acababa perdiendo datos. Este ocurría por la forma en la que se leían los datos de la grabación de EmotiBit, pues esta tenía filas con columnas variables. Si se leía con *Pandas* el *dataframe* se creaba con las columnas que tuviera la primera línea leída, lo que causaba una pérdida en varias líneas. Diego solucionó el problema leyendo línea a línea la grabación de EmotiBit.

En la programación del preprocesamiento, se encargó de limpiar las señales de EEG usando *FastICA*. Además, añadió las columnas de las medias de activación de cada electrodo, que serían de ayuda para el entrenamiento de los modelos. En esta parte también corrigió algunos problemas.

Diego estuvo presente durante el experimento que pretendía afirmar si los dispositivos de EEG y EmotiBit tenían una pérdida de datos al ser grabados desde el mismo ordenador.

Él ha sido el encargado de programar el notebook que entrena a todos los modelos de aprendizaje automáticos seleccionados en este proyecto para determinar cuál es el que mejor resultados da. Esto incluye, por un lado, cambiar el código del preprocesado para que los fragmentos sean de diez segundos en lugar de uno, y por otro, experimentar con distintas formas de dividir los datos de entrenamiento, así como probar varias configuraciones en modelos como el *MLP*, cambiando el número de capas y de neuronas por capa. Además, para el entrenamiento más exhaustivo del modelo escogido, *random forest*, generó nuevas tablas de preprocesado con distintos segundos de fragmentos. También modificó el código de entrenamiento para probar el uso de datos exclusivamente de EEG o exclusivamente de EmotiBit, en lugar de utilizar ambos conjuntos de datos. Todo ello con el fin de poder hacer el mayor número de comparaciones estadísticas en el apartado de los resultados. Por último, tuvo que realizar un reentrenamiento de todos los modelos al notar que las columnas del acelerómetro faltaban en la tabla preprocesada que se había usado para entrenar a los modelos.

Respecto al tiempo real, en primer lugar, investigó y añadió cómo hacer grabaciones de EEG desde Python sin hacer uso del programa usado en las sesiones de captura de datos. En segundo lugar, ha sido el que ha adaptado el código implementado en el preprocesado para que funcione en el *script* del tiempo real. Ayudó a montar la estructura para captar datos de los dos dispositivos y de forma paralela preprocesarlos, juntarlos, predecir con el modelo y mandarlo a Unreal Engine. Durante este proceso también intervino en la resolución de un problema por el cual el host no era capaz de recibir varios mensajes seguidos del cliente.

Al igual que el resto de los miembros, participó en el proceso de comprobación de la fiabilidad del modelo en la sesión de predicciones en tiempo real. Aquí, se encargó del ser el *host* y de realizar las grabaciones de la escena de Unreal Engine. Sin embargo, antes de realizar esa comprobación realizó un simulacro con el fin de comprobar que todo el sistema de tiempo real funcionara correctamente.

11.4 José Miguel Villacañas Díaz-Hellín

José Miguel se ha encargado de la creación y desarrollo de EmotionsApp, diseñando la arquitectura de la aplicación e integrando los valores de las emociones descritos previamente utilizando una escala de Likert. También diseñó una interfaz de usuario intuitiva y accesible, priorizando la facilidad de uso y la claridad en la presentación de los datos, facilitando la captura de datos y el posterior preprocesamiento para el entrenamiento del modelo de aprendizaje automático. También ha programado las opciones de personalización de la aplicación, pudiendo nombrar los archivos generados, anotar eventos y modificar parámetros de la aplicación. Además, se ha encargado de las actualizaciones de la aplicación y de las correcciones necesarias para el preprocesamiento de las sesiones con sujetos. Por último, se ha encargado de compatibilizar la aplicación con Android, para que funcione correctamente en dispositivos móviles, permitiendo realizar las sesiones de captura de datos con menos ordenadores en caso de que algún miembro del grupo no estuviese presente.

Ha llevado a cabo las fases de captura de datos utilizando EmotionsApp, ha monitorizado que todos los dispositivos estuviesen grabando correctamente para evitar señales no deseadas y se ha encargado de la fase de la entrevista de la mayoría de los sujetos, detalladas después de cada sesión de captura de datos. La fase de entrevistas es esencial para validar las emociones registradas del sujeto para posteriormente, minimizar los errores en el entrenamiento del modelo de aprendizaje automático.

José Miguel también ha participado en un experimento para comprobar la sincronización entre los relojes internos de BrainAccess y EmotiBit. Tras varias pruebas, se llegó a la conclusión que estos dispositivos no pueden convivir en el mismo ordenador durante una captura de datos.

Ha participado en el diseño del plan de pruebas, trabajando con el resto para definir los objetivos de las pruebas y la fase de preprocesamiento. Además, se encargó de corregir los guiones de los juegos previstos para las sesiones, con el objetivo de evitar el máximo número de atascos posibles durante la sesión de captura de datos.

José Miguel también ha colaborado en el preprocesado de los datos, especialmente en los datos de EmotiBit, aplicando filtros y escalando los datos para mejorar la

calidad de las señales para el futuro entrenamiento del modelo de aprendizaje automático. Además, trabajó en la conversión de frecuencias de grabación para asegurar la compatibilidad con BrainAccess (ya que ambos dispositivos capturan los datos con distinta frecuencia), facilitando la fase de preprocesado de los datos y permitiendo concatenarlos de forma sencilla. Por último, ha generado varios scripts para concatenar los datos en bruto y los datos preprocesados en un mismo fichero para facilitar el entrenamiento.

En el desarrollo de la captura de datos en tiempo real, diseñó y desarrolló la estructura de cliente-servidor, debido al problema mencionado en las limitaciones, que impide que ambos dispositivos sean capturados en un mismo ordenador. Esta arquitectura permite la comunicación entre ambos dispositivos minimizando la pérdida de datos y utilizando varios hilos para maximizar el rendimiento del preprocesamiento en tiempo real de los datos. Además del preprocesamiento, también cuenta con la predicción del modelo de aprendizaje automático previamente entrenado y con el envío de los resultados a una aplicación externa. Durante su desarrollo, José Miguel se ha encargado de monitorizar todas las pruebas realizadas maximizar el rendimiento de la estructura en tiempo real, supervisando en todo momento los resultados y generando nuevas pruebas para conseguir un modelo de aprendizaje automático que predijese y reenviase la información a una aplicación externa.

Además, ha implementado la recepción de datos en Unreal Engine, utilizando la clase `FSocket` para recibir los mensajes enviados por el servidor. Esta integración permitió que la demo técnica en Unreal Engine recibiera en tiempo real la predicción del modelo de aprendizaje automático realizada desde otro ordenador.

José Miguel, junto al resto, ha comprobado la fiabilidad del modelo en las sesiones de predicción de emociones en tiempo real y se ha encargado de la creación de un nuevo repositorio, que cuenta con toda la información usada y desarrollada de forma organizada para el uso público. Dicho repositorio también cuenta con los datos grabados a los sujetos de prueba y se pueden usar en caso de necesitar datos de ejemplo, pero no es recomendable concluir ningún tipo de resultados con ellos porque se consideran datos no válidos.

BIBLIOGRAFÍA

- Abeer Al-Nafjan, M. H.-O.-W. (2017). Review and Classification of Emotion Recognition Based on EEG Brain-Computer Interface System Research: A Systematic Review. 7(12), 1239. Emotion classification.
- Acuña Llamas, F. J., Cano Guadiana, A., Guerra Ford, O. M., Kurczyn Villalobos, M. P., Monterrey Chepov, R., Puente de la Mora, X., & Salas Suárez, J. (2018). *Guía para el tratamiento de datos biométricos*.
- Aha, D. W. (1991). Instance-based learning algorithms. *Machine Learning*, 6(1), 37-66.
- Anju, M. K. (2012). Design of Butterworth and Chebyshev1 Lowpass. *International Journal of Advanced*, 2(5), 524-528.
- Bisio, I., Delfino, A., Lavagetto, F., & Marchese, M. (2013). Opportunistic detection methods for emotion-aware smartphone applications. En B. Guo, D. Riboni, P. Hu, & I. Global (Ed.), *Creating personal, social, and urban awareness through pervasive computing* (págs. 53-85). doi10.4018/978-1-4666-4695-7.ch003
- BrightFocus® Foundation. (4 de junio de 2015). *Brain anatomy and limbic system*. Recuperado el 17 de mayo de 2024, de BrightFocus® Foundation: <https://www.bright-focus.org/alzheimers/infographic/brain-anatomy-and-limbic-system>
- Bustamante Rojas, P. M., Kato Kobashigawa, C., Marroquín Venero, P. C., & Yánac Huanis, S. E. (2019). *Las emociones como predictoras del engagement laboral en docentes de una institución educativa privada del Perú*.
- Cabredo, R., Legaspi, R., Inventado, P. S., & Numao, M. (7 de enero de 2013). Discovering emotion-inducing music features using EEG signals. *Journal of Advanced Computational Intelligence*, 17(3), 362-370. doi10.20965/jaciii.2013.p0362
- Cacioppo, J. T. (1993). The psychophysiology of emotion. *New York: Guilford*, 2, 173-191.
- Canli, T., Desmond, J. E., Zhao, Z., Glover, G., & Gabriely, J. D. (5 de octubre de 1998). Hemispheric asymmetry for emotional stimuli detected with fMRI. *NeuroReport*, 9(14), 3233-3239.

Cano Salcedo, J. (12 de febrero de 2020). *The Explorer*. Recuperado el 24 de mayo de 2024, de The Explorer: <https://sites.google.com/view/javier-cano/the-explorer>

Cano Salcedo, J., Villacañas Díaz-Hellín, J. M., Cabello Hernández, R., Rol Sánchez, D., & Carrera Santamaria, J. A. (7 de junio de 2021). *Bubble Cat*. Recuperado el 24 de mayo de 2024, de itch.io: <https://javics.itch.io/bubble-cat>

Cawthon, S. (23 de julio de 2015). *Five Nights at Freddy's 4*. Recuperado el 27 de mayo de 2024, de Steam: https://store.steampowered.com/app/388090/Five_Nights_at_Freddys_4/?l=spanish

Cohen, M. X. (20 de diciembre de 2019). *Complete neural signal processing and analysis: Zero to hero*. Recuperado el 25 de noviembre de 2023, de Udemy: <https://www.udemy.com/course/solved-challenges-ants/>

ConcernedApe. (26 de febrero de 2016). *Stardew Valley*. Recuperado el 24 de mayo de 2024, de Stardew Valley: <https://www.stardewvalley.net>

Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20, 273-297.

Daniel Mullins Games. (19 de octubre de 2021). *Inscription*. Recuperado el 24 de mayo de 2024, de Inscription: <https://www.inscription.com>

de la Rosa Centella, M. D. (19 de julio de 2019). ¿Qué sucede en nuestro cerebro cuando sentimos emociones? *Revistadigital INESEM*. Recuperado el 9 de mayo de 2024, de <https://www.inesem.es/revistadigital/educacion-sociedad/anatomia-de-las-emociones/>

Ekman, P. (1992). *An argument for basic emotions*.

EMIKA_GAMES. (26 de enero de 2024). *I'm counting to 6...* Steam: https://store.steampowered.com/app/2717260/Im_counting_to_6/

EmotiBit. (s.f.). *EmotiBit_Docs*, f9db26b63e8b38d0b864d52956c747fa6a87b74a. Recuperado el 09 de 05 de 2024, de GitHub: https://github.com/EmotiBit/EmotiBit_Docs

Fisher, R. A. (1925). Statistical methods for research workers. En A. W. Edwards, I. Grattan-Guinness, R. Cooke, L. Corry, P. Crépel, & N. Guicciardini (Edits.), *Landmark Writings in Western Mathematics 1640-1940* (págs. 856-870). Elsevier Science. doi10.1016/B978-044450871-3/50148-0

- G. Trejo Alcantara, N. C. (2017). Efecto del pre-procesamiento del EEG en el Análisis por Componentes. *ARTÍCULO DE INVESTIGACIÓN - EDICIÓN ESPECIAL CNIB 2016*, 38(1), 382-389.
- Grave-de Peralta, R., González-Andino, S., & Gómez-González, C. M. (2004). Bases biofísicas de la localización de los generadores cerebrales. *REV NEUROL*, 39(8), 748-756.
- Guadamuz, D., Miranda, S., & Mora, M. (2022). Trastornos del sueño: prevención, diagnóstico y tratamiento. *Revista Médica Sinergia*, 7(07).
- Guzmán Álvarez, J. J. (2015). *La actividad cerebral*. Recuperado el 17 de mayo de 2024, de Internet Archive Wayback Machine: <https://web.archive.org/web/20160710152043/http://neurofisiologiagranada.com/eeg/eeg-actividadcerebral.htm>
- Haykin, S. H. (1999). *Neural Networks.: A Comprehensive Foundation*. Pearson.
- Hinrichs, H., Scholz, M., Katrin Baum, A., W. Y. Kam, J., T. Knight, R., & Heinze, H.-J. (23 de marzo de 2020). Comparison between a wireless dry electrode EEG system with a conventional wired wet electrode EEG system for clinical applications. *Scientific Reports*, 10(5218). <https://doi.org/10.1038/s41598-020-62154-0>
- Izard, C. E. (1977). *Human Emotions*.
- Jatupaiboon, N., Pan-ngum, S., & Israsena, P. (15 de julio de 2013). Real-Time EEG-Based Happiness Detection System. (B. W. Chen, S. Hsieh, & C. H. Wu, Edits.) *The Scientific World Journal*, 2013(618649). doi10.1155/2013/618649
- Kirschstein, T., & Köhling, R. (2009). What is the Source of the EEG? *Clinical EEG and Neuroscience*, 40(3), 146–149. doi10.1177/155005940904000305
- Kojima Productions. (12 de agosto de 2014). *P.T.* Recuperado el 27 de mayo de 2024, de Wikipedia: [https://es.wikipedia.org/wiki/P.T._\(videojuego\)](https://es.wikipedia.org/wiki/P.T._(videojuego))
- Kreibig, S. D. (2010). Autonomic nervous system activity in emotion. *Biological Psychology*, 84(3), 394-421.

- Manjit Sandhu, S. K. (2016). A Study on Design and Implementation of Butterworth, Chebyshev and Elliptic Filter with MatLab. *International Journal of Emerging Technologies in Engineering Research*, 4(6).
- Manshad, M., & Petrovich, A. (2019). La rueda de las emociones de Robert Plutchik: ¿qué es y qué muestra? *Summarizing Emotions from Text Using Plutchik's Wheel of Emotions. Advances in Intelligent System Research*(166), 291 - 294.
- Medina, B., Sierra, J. E., & Barrios Ulloa, A. (2018). Técnicas de extracción de características de señales EEG en la imaginación de movimiento para sistemas BCI. *Revista Espacios*, 39(22), 36.
- Melia, U., Clariá, F., Vallverdú, M., & Caminal, P. (2014). Filtering and thresholding the analytic signal envelope in order to improve peak and spike noise reduction in EEG signals. *Medical Engineering & Physics*, 36(4), 547-553. doi10.1016/j.medengphy.2013.11.014
- Mojang Studios. (18 de noviembre de 2011). *Minecraft*. Recuperado el 27 de mayo de 2024, de Minecraft: <https://www.minecraft.net/es-es>
- Netsky, M. G. (20 de diciembre de 1986). What is a brain, and who said so? (B. Med J, Ed.) *BRITISH MEDICAL JOURNAL*, 293(6562), 1670-1672. 10.1136/bmj.293.6562.1670
- BrainAccess: <https://www.brainaccess.ai/hardware/brainaccess-cap/>
- Neurotechnology. (s.f.). *BrainAccess MIDI*. Recuperado el 09 de mayo de 2024, de BrainAccess: <https://www.brainaccess.ai/hardware/brainaccess-midi/>
- Neurotechnology. (s.f.). *EEG (Electroencephalography)*. Recuperado el 9 de mayo de 2024, de BrainAccess: <https://www.brainaccess.ai/eeg-electroencephalography/>
- Nintendo. (20 de octubre de 2023). *Super Mario Bros. Wonder*. Nintendo: <https://www.nintendo.com/es-es/Juegos/Juegos-de-Nintendo-Switch/Super-Mario-Bros-Wonder-2404150.html>
- Ortiz Bonilla, F. J. (2019). *Detección automática de emociones mediante el análisis del electroencefalograma*. Sevilla.

- Palacios Sánchez, L. (2002). Breve historia de la electroencefalografía. *Acta Neurológica Colombiana*, 18(2), págs. 104-107. <https://repository.urosario.edu.co/server/api/core/bitstreams/4d39b6f5-f803-47b0-a4a6-9c6351653396/content#:~:text=El%20EEG%20fue%20inventado%20por,observaciones%20sobre%20la%20electricidad%20animal>
- Parrott, W. G. (2001). *Emotions in Social Psychology: Key Readings*.
- Perrikaryal. (17 de mayo de 2023). *Hands-free mind control gaming explained*. Recuperado el 26 de julio de 2023, de YouTube: <https://www.youtube.com/watch?v=k5mSSEiu6BI>
- Plutchik, R. (2001). The Nature of Emotions. *American Scientist*. 4(89), 344 - 350.
- Ramos-Argüelles, F., Morales, G., Egozcue, S., Pabón, R. M., & Alonso, M. T. (2009). Técnicas básicas de electroencefalografía: principios y aplicaciones. *An. Sist. Sanit. Navar*, 32(Supl. 3), 69-82. <https://scielo.isciii.es/pdf/asisna/v32s3/original6.pdf>
- Random forests. (2001). *Machine Learning*, 45(1), 5-32.
- Ranwog, Nortex, alesska. (13 de marzo de 2024). *Psalm 5:9-13*. Recuperado el 24 de mayo de 2024, de Steam: https://store.steampowered.com/app/1837220/Psalm_5913/?l=spanish
- Red Barrels. (4 de septiembre de 2013). *Outlast*. Recuperado el 24 de mayo de 2024, de Red Barrels: <https://redbarrelsgames.com/games/outlast/>
- Rodríguez Álvarez, M. C. (29 de mayo de 2020). *¿Cómo afectan las emociones a nuestro cerebro?* Recuperado el 9 de mayo de 2024, de Ábaco: <https://psi-coabaco.es/como-afectan-las-emociones-a-nuestro-cerebro/>
- Russell, J. A. (1980). A Circumplex Model of Affect. *Journal of Personality and Social Psychology*, 39(6), 1161-1178.
- S. W. Loh, Y.-S. S.-W. (2003). Decision Trees: An Overview and Their Use in Medicine. *Artificial Intelligence in Medicine*, 28(2), 121-136.
- Seeck, M., Koessler, L., Bast, T., Leijten, F., Michel, C., Baumgartner, C., . . . Beniczky, S. (20 de junio de 2017). The standardized EEG electrode array of the IFCN. *Clin Neurophysiol*, 128(10), 2070-2077. doi10.1016/j.clinph.2017.06.254

- Team Cherry. (24 de febrero de 2017). *Hollow Knight*. Recuperado el 24 de mayo de 2024, de Hollow Knight: <https://www.hollowknight.com>
- Teplan, M. (2002). Fundamentals of EEG measurement. *Measurement Science Review*, 2.
- Wichakam, I., & Vateekul, P. (2014). An evaluation of feature extraction in EEG-based emotion prediction with support vector machines. *International Joint Conference on Computer Science and Software Engineering*, 11, 106-110. doi10.1109/JCSSE.2014.6841851
- Wundt, G. (1896). *Compendio de psicología*. (J. González Alonso, Trad.) La España Moderna.
- Zamora García, R. (2023). *Reconocimiento de Emociones a partir de la Actividad Eléctrica Cerebral con Técnicas de Deep Learning*. Valladolid, Valladolid, España.

Apéndice A - Formulario de búsqueda de sujetos de prueba

Grabación fisiológica durante una partida

Somos unos estudiantes del 4º curso del GDV. Para nuestro TFG queremos **recoger datos fisiológicos usando una pulsera y un casco**. El objetivo es entrenar un modelo de aprendizaje automático que sea **capaz de predecir el estado anímico del jugador en tiempo real**, y con él, permitir que videojuegos puedan adaptarse al estado anímico del jugador, por ejemplo, bajando la dificultad al detectar frustración o ajustando el nivel de miedo dinámicamente.

Nos sería de mucha ayuda si pudieras ayudarnos a recoger datos. Para ello, tendrías que venir a la tercera planta de la biblioteca de la facultad, ponerte el casco y la pulsera, y jugar durante 15 minutos como máximo a un juego de tu elección de nuestro catálogo. Como buscamos generar emociones, te animamos a elegir un juego de miedo. Después de jugar, **te haremos algunas preguntas** sobre algunos momentos de tu gameplay. El experimento será individual y **durará aproximadamente 30 minutos en total**. No hay ningún requisito especial para poder participar.

** Indica que la pregunta es obligatoria*

1. Correo *

Confidencialidad de datos

Los datos de la grabación y de esta encuesta serán anónimos en el TFG. Recopilamos la dirección de correo electrónico sólo para que podamos contactar contigo.

Sobre los aparatos de grabación

El casco es BrainAccess, un sistema de electroencefalografía que graba el voltaje del cuero cabelludo. Se puede poner sobre el pelo sin problema, mientras se lleve suelto. La pulsera es EmotiBit, que recoge datos como las pulsaciones por minuto, temperatura y la actividad electrodérmica.



2. **¿Quieres jugar a un juego de miedo?** Como buscamos generar emociones, te animamos a elegir un juego de miedo. *

Marca solo un óvalo.

- ☐ Sí
- ☐ No

3. **Dinos cuándo te vendría bien asistir a la biblioteca.** Te mandaremos un correo lo antes posible para confirmar tu asistencia. *

Ejemplo: "Puedo los lunes y los miércoles de 18:00 a 20:00"

4. **¿Alguna duda? (opcional)**

Apéndice B - Formulario de demografía de los participantes

Demografía del participante

Finalmente, recogeremos tus datos demográficos para analizar los resultados, de forma completamente anónima.

** Indica que la pregunta es obligatoria*

1. **Escribe tu edad (opcional, solo números)**

2. **Selecciona tu género (opcional)**

Marca solo un óvalo.

☐ Femenino

☐ Masculino

☐ No binario

☐ Otro

3. **¿Cuánta experiencia tienes jugando a videojuegos? ***

Marca solo un óvalo.

☐ Mucha, juego videojuegos desde hace años y es mi entretenimiento principal

☐ Bastante, es un hobby para mí pero no es mi entretenimiento principal

☐ Media, juego de vez en cuando para desconectar

☐ Poca, sé lo básico pero no me interesa mucho el tema

☐ Ninguna, no suelo jugar ni ver nada relacionado con los videojuegos

4. Durante una semana lectiva estándar, **¿cuántas horas juegas juegas aproximadamente?** *

Marca solo un óvalo.

- ☐ Entre 0 y 5 horas
- ☐ Entre 5 y 10 horas
- ☐ Entre 10 y 15 horas
- ☐ Entre 15 y 20 horas
- ☐ Más de 20 horas

5. **¿Estás familiarizado o familiarizada con el género de terror en los videojuegos?** *

Marca solo un óvalo.

- ☐ Sí, me gusta jugarlos
- ☐ Sí, me gusta ver jugar a otros
- ☐ No

Recomendación de títulos de terror

6. **Para terminar, ¿nos recomiendas algún juego de miedo? (opcional)**
